

Estado del Arte: Feynman AI Models (Regresión Simbólica Interpretable e IA Feynman)

Ricardo Luis Urretxo Riofrancos

23 de agosto de 2026

Índice

1. Fundamentos: El Framework AI Feynman y sus Precursores	2
1.1. Toward an AI Physicist for Unsupervised Learning	2
1.2. AI Feynman: a Physics-Inspired Method for Symbolic Regression	2
1.3. AI Feynman 2.0: Pareto-optimal symbolic regression exploiting graph modularity . .	3
1.4. AI-Descartes: Combining Data and Theory for Derivable Scientific Discovery	3
2. Interpretabilidad y Explicabilidad en Regresión Simbólica	5
2.1. Interpretable Scientific Discovery with Symbolic Regression: A Review	5
2.2. Interpretability in Symbolic Regression: a benchmark of Explanatory Methods using the Feynman data set	5
2.3. Call for Action: towards the next generation of symbolic regression benchmark . . .	6
2.4. Symbolic Regression is NP-hard	6
2.5. From Kepler to Newton: Explainable AI for Science	7
3. Arquitecturas de Deep Learning para Regresión Simbólica	8
3.1. Deep symbolic regression: Recovering mathematical expressions from data via risk- seeking policy gradients	8
3.2. Neural Symbolic Regression that Scales	8
3.3. End-to-end symbolic regression with transformers	9
3.4. Deep symbolic regression for physics guided by units constraints (PhySO)	9
3.5. SymFormer: End-to-end symbolic regression using transformer-based architecture . .	10
3.6. A Neural-Guided Dynamic Symbolic Network for Exploring Mathematical Expres- sions from Data	10
4. Modelos de Lenguaje y Búsqueda Evolutiva	11
4.1. LLM-SR: Scientific Equation Discovery via Programming with Large Language Models	11
4.2. LLM-SRBench: A New Benchmark for Scientific Equation Discovery with Large Language Models	11
4.3. Controllable Neural Symbolic Regression	12
5. Benchmarks, Datasets y Herramientas	13
5.1. Contemporary Symbolic Regression Methods and their Relative Performance (SR- Bench)	13

5.2. Rethinking Symbolic Regression Datasets and Benchmarks for Scientific Discovery (SRSD)	13
5.3. Interpretable Machine Learning for Science with PySR and SymbolicRegression.jl . .	14
5.4. Exploring Multi-view Symbolic Regression methods in physical sciences	14
6. Aplicaciones Científicas	16
6.1. Discovering Symbolic Models from Deep Learning with Inductive Biases	16
6.2. Learning Interpretable Network Dynamics via Universal Neural Symbolic Regression	16
6.3. Symbolic Regression for Beyond the Standard Model Physics	17
6.4. Symbolic regression for precision LHC physics	17
6.5. Discovering physical laws with parallel symbolic enumeration	18
6.6. Evolving Scientific Discovery by Unifying Data and Background Knowledge with AI-Hilbert	18

1. Fundamentos: El Framework AI Feynman y sus Precursores

1.1. Toward an AI Physicist for Unsupervised Learning

Fecha: 2019 (Publicado en *Physical Review E*)

Citación: Wu, T., & Tegmark, M. (2019). Toward an AI Physicist for Unsupervised Learning. *Physical Review E*, 100(3), 033311.

Área de aplicación: Machine Learning Científico (Descubrimiento Automatizado de Teorías Físicas)

Resumen:

El aprendizaje no supervisado en entornos físicos complejos exige que un único modelo capture múltiples regímenes dinámicos (gravedad, electromagnetismo, oscilador armónico, elasticidad) simultáneamente; los modelos de caja negra convencionales generalizan mal y no logran delimitar los dominios de validez de cada régimen.

Los autores proponen el “AI Physicist”, un marco inspirado en heurísticas clásicas de la física: divide y vencerás, la navaja de Occam, la unificación de teorías y el aprendizaje continuo. En lugar de una red monolítica, el sistema aprende múltiples “teorías” candidatas que compiten por explicar distintas regiones del espacio de datos.

Técnicamente, se introduce una función de pérdida de media generalizada que empuja a cada teoría a especializarse en la región donde predice mejor, junto con un objetivo diferenciable de longitud de descripción que descarta datos atípicos y presiona a las teorías aprendidas a colapsar en expresiones simbólicas simples. Las teorías se almacenan en un “hub” central que las unifica y genera candidatas para nuevos entornos.

Evaluable sobre simulaciones con combinaciones de fuerzas gravitatorias, electromagnéticas, armónicas y elásticas, además de un péndulo doble caótico, el sistema alcanzó una precisión predictiva hasta mil millones de veces superior a redes neuronales estándar, recuperando con frecuencia parámetros exactos enteros o racionales. Su ventaja cualitativa es sentar las bases conceptuales de AI Feynman, demostrando que imponer heurísticas físicas sobre el proceso de aprendizaje mejora simultáneamente precisión e interpretabilidad.

1.2. AI Feynman: a Physics-Inspired Method for Symbolic Regression

Fecha: Abril de 2020 (Publicado en *Science Advances*)

Citación: Udrescu, S.-M., & Tegmark, M. (2020). AI Feynman: a Physics-Inspired Method for Symbolic Regression. *Science Advances*, 6(16), eaay2631.

Área de aplicación: Machine Learning Científico (Regresión Simbólica y Descubrimiento de Leyes Físicas)

Resumen:

La regresión simbólica –encontrar la expresión matemática exacta que genera un conjunto de datos– es un problema NP-difícil en el caso general; los algoritmos clásicos basados en programación genética escalan mal y fracasan ante funciones con múltiples variables.

Los autores presentan AI Feynman, un algoritmo recursivo que combina el ajuste mediante redes neuronales con un conjunto de técnicas inspiradas en la física para detectar propiedades estructurales de la función objetivo (simetrías, separabilidad aditiva/multiplicativa, invariancia composicional) y así descomponer el problema en subproblemas progresivamente más simples.

En cada paso, la red neuronal entrenada sobre los datos actúa como un oráculo diferenciable para detectar simetrías de traslación y permutación mediante pruebas de gradiente, así como dependencias multiplicativas o aditivas separables; el problema se divide recursivamente hasta que los subproblemas restantes son suficientemente simples para aplicar fuerza bruta o ajuste polinómico.

Evaluated on 100 equations extracted from the *Feynman Lectures on Physics*, the method recovered all correctly, against only 71 recovered by the commercial reference software (Eureqa); in a data base more exigent with noise and higher dimensionality, the success rate passed from 15 % to 90 %. The authors publish the code and the “Feynman Symbolic Regression Database”, which would become the physical standard benchmark of the field.

1.3. AI Feynman 2.0: Pareto-optimal symbolic regression exploiting graph modularity

Fecha: Diciembre de 2020 (Publicado en NeurIPS 2020)

Citación: Udrescu, S.-M., Tan, A., Feng, J., Neto, O., Wu, T., & Tegmark, M. (2020). AI Feynman 2.0: Pareto-optimal symbolic regression exploiting graph modularity. *Advances in Neural Information Processing Systems*, 33 (NeurIPS 2020).

Área de aplicación: Machine Learning Científico (Extensión del Framework AI Feynman)

Resumen:

The original version of AI Feynman returns a unique expression and depends on exact symmetries and clean data; many real scientific problems require comparing multiple hypotheses with different precision-complexity trade-off and tolerate noise or generative non-deterministic data.

The authors generalize the framework to produce a complete Pareto front of formulas (precision vs complexity) instead of a unique solution, expanding the catalog of detectable symmetries to “generalized symmetries” and computational graph modularity.

The system analyzes the computational graph induced by the neural network adjusted to the data – using gradient information – to discover which subsets of variables interact in a modular way; incorporates normalizing flows to extend the method to probability distributions known only through samples, and uses hypothesis contrast to accelerate the combinatorial search of operators.

The new architecture demonstrates robustness to noise of various orders of magnitude superior to the original AI Feynman and discovers formulas that the previous approach could not identify, consolidating the Pareto front interpretability-precision as a central criterion to evaluate the quality of a symbolic expression discovered automatically.

1.4. AI-Descartes: Combining Data and Theory for Derivable Scientific Discovery

Fecha: Septiembre de 2021 (Publicado en *Nature Communications*, 2023)

Citación: Cornelio, C., Dash, S., Austel, V., Josephson, T. R., Goncalves, J., Clarkson, K. L., Megiddo, N., El Khadir, B., & Horesh, L. (2023). Combining data and theory for derivable scientific discovery with AI-Descartes. *Nature Communications*, 14, 1777.

Área de aplicación: Machine Learning Científico (Razonamiento Lógico-Simbólico y Descubrimiento Axiomático)

Resumen:

Scientists traditionally derive laws by combining prior axiomatic knowledge with experimental observation; automatic learning methods purely based on data ignore that theoretical knowledge, while incorporating logical axioms –not only simple functional constraints– into the discovery process was still an open problem.

The authors propose AI-Descartes, which combines symbolic regression with formal logic: first it generates a set of candidate formulas adjusted to the data, and then it uses

demostración automática de teoremas sobre una base de axiomas físicos para validar y clasificar cuáles son derivables de la teoría conocida.

El sistema formula la búsqueda de la fórmula “correcta” entre varias con error empírico similar como un problema de satisfacibilidad lógica, aportando además una prueba formal de la derivación cuando la encuentra, en lugar de limitarse a un ajuste numérico.

El método recuperó con éxito la tercera ley de Kepler, la dilatación temporal relativista de Einstein y la isoterma de adsorción de Langmuir, demostrando que la incorporación de razonamiento lógico permite discriminar la fórmula físicamente correcta usando muy pocos puntos de datos – una ventaja directa de interpretabilidad y confiabilidad frente a la regresión simbólica puramente estadística.

2. Interpretabilidad y Explicabilidad en Regresión Simbólica

2.1. Interpretable Scientific Discovery with Symbolic Regression: A Review

Fecha: Noviembre de 2022 (Publicado en *Artificial Intelligence Review*, 2024)

Citación: Makke, N., & Chawla, S. (2024). Interpretable scientific discovery with symbolic regression: a review. *Artificial Intelligence Review*, 57, 2.

Área de aplicación: Machine Learning Científico (Revisión Sistemática de Métodos de Regresión Simbólica)

Resumen:

La interpretabilidad de los modelos de aprendizaje automático es un requisito creciente en ciencia, donde entender el “por qué” de una predicción es tan importante como su precisión; la regresión simbólica ha resurgido como alternativa transparente frente a las redes neuronales de caja negra.

Los autores realizan una revisión estructurada de los métodos de regresión simbólica existentes, desde los enfoques clásicos de programación genética hasta las arquitecturas de aprendizaje profundo recientes (autorregresivas, basadas en refuerzo y en *transformers*).

La revisión organiza los métodos según su estrategia de búsqueda en el espacio de expresiones (evolutiva, basada en gradientes, basada en secuencias), analiza sus mecanismos de control de complejidad y discute cómo cada familia gestiona el compromiso entre bondad de ajuste y legibilidad de la fórmula resultante.

Los autores concluyen identificando las fortalezas y limitaciones relativas de cada paradigma y señalan como reto abierto la falta de métricas estandarizadas de interpretabilidad, motivando gran parte de la investigación posterior en *benchmarking* centrado en el usuario humano recogida en el resto de esta sección.

2.2. Interpretability in Symbolic Regression: a benchmark of Explanatory Methods using the Feynman data set

Fecha: Abril de 2024 (Preprint arXiv)

Citación: Aldeia, G. S. I., & de França, F. O. (2024). Interpretability in Symbolic Regression: a benchmark of Explanatory Methods using the Feynman data set. *arXiv preprint* arXiv:2404.05908.

Área de aplicación: Machine Learning Científico (Benchmarking de Métodos de Explicabilidad)

Resumen:

Aunque la regresión simbólica se presenta habitualmente como “interpretable por diseño”, la interpretabilidad carece de una definición formal y rara vez se mide de forma sistemática; en paralelo existen numerosos métodos de explicación agnósticos al modelo (SHAP, gradientes integrados, efectos parciales) diseñados originalmente para modelos de caja negra.

Los autores diseñan un marco de *benchmarking* que aplica estos explicadores tanto a modelos de regresión simbólica como a modelos no interpretables, evaluados sobre el conjunto de 100 ecuaciones físicas del *dataset* Feynman, para comparar de forma cuantitativa qué tan fieles y estables son las explicaciones generadas.

Se evalúan métricas de fidelidad, estabilidad y coste computacional de cada explicador sobre distintas familias de modelos (árboles de expresión, ensambles, redes neuronales), incluyendo un análisis adicional sobre cuatro *benchmarks* ya existentes de la comunidad de programación genética.

Los resultados muestran que los efectos parciales (*Partial Effects*) y SHAP ofrecen las explicaciones más robustas y consistentes, mientras que los gradientes integrados resultan inestables sobre modelos basados en árboles; el estudio aporta el primer marco cuantitativo reproducible para comparar explicabilidad entre regresión simbólica y otros modelos, confirmando empíricamente

que la interpretabilidad “por diseño” de la SR no es uniforme y depende del método de búsqueda utilizado.

2.3. Call for Action: towards the next generation of symbolic regression benchmark

Fecha: Mayo de 2025 (GECCO 2025, Workshop de Regresión Simbólica)

Citación: Aldeia, G. S. I., Zhang, H., Bomarito, G., Cranmer, M., Fonseca, A., Burlacu, B., La Cava, W. G., & de França, F. O. (2025). Call for Action: towards the next generation of symbolic regression benchmark. *Proceedings of the Genetic and Evolutionary Computation Conference Companion* (GECCO '25).

Área de aplicación: Machine Learning Científico (Estandarización de Evaluación y Reproducibilidad)

Resumen:

Pese a la existencia de SRBench, la comunidad carece de consenso sobre cómo evaluar de forma justa y reproducible decenas de algoritmos de regresión simbólica con hiperparámetros, entornos de ejecución y presupuestos computacionales heterogéneos.

Un consorcio de autores de las principales herramientas del campo (incluyendo PySR y SR-Bench) propone convertir el *benchmark* en un recurso comunitario vivo, casi duplicando el número de algoritmos evaluados respecto a la versión original y refinando las métricas y visualizaciones de resultados.

Establecen prácticas estandarizadas de ajuste de hiperparámetros, especificación de recursos computacionales y protocolos de “deprecación” de métodos obsoletos, además de proponer mecanismos de optimización adaptativa de parámetros para reducir el coste de comparar nuevos algoritmos.

El hallazgo central es que ningún algoritmo domina de forma consistente en todos los conjuntos de datos, evidenciando compromisos inherentes entre precisión, complejidad de la fórmula y coste computacional; el artículo funciona como hoja de ruta de la comunidad hacia una segunda generación de *benchmarks* más rigurosos y transparentes.

2.4. Symbolic Regression is NP-hard

Fecha: Julio de 2022 (Publicado en *Transactions on Machine Learning Research*)

Citación: Virgolin, M., & Pissis, S. P. (2022). Symbolic Regression is NP-hard. *Transactions on Machine Learning Research*.

Área de aplicación: Teoría Computacional (Complejidad Algorítmica de la Regresión Simbólica)

Resumen:

Aunque numerosos trabajos habían sugerido informalmente que la regresión simbólica es computacionalmente difícil, no existía una demostración formal de su clase de complejidad, dejando sin fundamento teórico riguroso la justificación de por qué se recurre sistemáticamente a heurísticas (programación genética, aprendizaje profundo) en lugar de algoritmos exactos.

Los autores demuestran formalmente que el problema de decisión asociado a la regresión simbólica –determinar si existe una expresión de tamaño acotado que ajusta los datos dentro de un error dado– es NP-difícil, mediante una reducción desde un problema NP-completo conocido.

La prueba se construye sobre el espacio de expresiones representadas como árboles con un conjunto finito de operadores, mostrando que incluso instancias restringidas del problema heredan la dureza computacional.

El resultado no invalida los métodos heurísticos existentes, pero establece que no cabe esperar un algoritmo exacto de tiempo polinómico general para regresión simbólica, justificando teóricamente el uso de búsqueda evolutiva, aprendizaje por refuerzo y modelos generativos como aproximaciones necesarias –y reforzando la relevancia de que dichas aproximaciones prioricen soluciones interpretables ante la imposibilidad de garantizar optimalidad exacta.

2.5. From Kepler to Newton: Explainable AI for Science

Fecha: Noviembre de 2021 (ICML 2022, Workshop AI for Science)

Citación: Li, Z., Ji, J., & Zhang, Y. (2022). From Kepler to Newton: Explainable AI for Science. *Proceedings of the ICML 2022 Workshop on AI for Science*.

Área de aplicación: Machine Learning Científico (IA Explicable Aplicada al Método Científico)

Resumen:

Los autores argumentan que a medida que los conjuntos de datos científicos crecen exponencialmente, la generación manual de hipótesis se vuelve inviable, y que la IA explicable (XAI) –frente a los modelos de caja negra– es la única vía compatible con el método científico, donde entender el “por qué” de un hallazgo es tan valioso como el hallazgo mismo.

Proponen un caso de estudio histórico como prueba de concepto: partiendo únicamente de las observaciones astronómicas originales de Tycho Brahe, aplican técnicas de IA explicable para redescubrir de forma automática las leyes de Kepler del movimiento planetario y, a partir de ellas, la ley de gravitación universal de Newton.

El proceso reproduce computacionalmente la cadena de razonamiento histórica –de datos observacionales a leyes empíricas, y de estas a un principio unificador– usando herramientas de descubrimiento simbólico interpretables en cada etapa, en lugar de un único modelo extremo a extremo opaco.

El trabajo defiende que la trazabilidad del razonamiento (el “saber por qué”) debe ser un objetivo de diseño explícito en la IA para la ciencia, y no una propiedad emergente accidental, posicionando la explicabilidad como condición necesaria –no solo deseable– para que la IA sea aceptada como herramienta de descubrimiento científico genuino.

3. Arquitecturas de Deep Learning para Regresión Simbólica

3.1. Deep symbolic regression: Recovering mathematical expressions from data via risk-seeking policy gradients

Fecha: Diciembre de 2019 (Publicado en ICLR 2021)

Citación: Petersen, B. K., Landajuela, M., Mundhenk, T. N., Santiago, C. P., Kim, S. K., & Kim, J. T. (2021). Deep symbolic regression: Recovering mathematical expressions from data via risk-seeking policy gradients. *International Conference on Learning Representations (ICLR)*.

Área de aplicación: Machine Learning Científico (Aprendizaje por Refuerzo aplicado a Regresión Simbólica)

Resumen:

Recuperar la ecuación matemática subyacente a partir de observaciones es un problema donde el aprendizaje profundo convencional apenas se había explorado, pues los objetivos habituales de las redes neuronales (minimizar el error promedio) no se alinean bien con encontrar una única expresión óptima entre un espacio combinatorio enorme.

Los autores entrenan una red neuronal recurrente que genera distribuciones de probabilidad sobre expresiones matemáticas representadas como secuencias, y proponen un gradiente de política “*risk-seeking*” (buscador de riesgo) que optimiza explícitamente el mejor resultado obtenido en cada lote, en lugar del resultado promedio.

La arquitectura admite objetos jerárquicos de longitud variable bajo métricas de caja negra e incorpora restricciones sintácticas (por ejemplo, evitar operadores redundantes) directamente en el proceso de generación secuencial, evitando así gran parte del espacio de búsqueda inválido.

El método (conocido como DSO/DSR) supera a Eureka –el estándar comercial de referencia– y a otras líneas base en la recuperación exacta de expresiones simbólicas en *benchmarks* con y sin ruido, estableciendo el gradiente de política *risk-seeking* como técnica de referencia adoptada por trabajos posteriores del campo.

3.2. Neural Symbolic Regression that Scales

Fecha: Junio de 2021 (Publicado en ICML 2021)

Citación: Biggio, L., Bendinelli, T., Neitz, A., Lucchi, A., & Parascandolo, G. (2021). Neural Symbolic Regression that Scales. *Proceedings of the 38th International Conference on Machine Learning (ICML)*.

Área de aplicación: Machine Learning Científico (Preentrenamiento a Gran Escala para Regresión Simbólica)

Resumen:

Los métodos de regresión simbólica tradicionales reinician la búsqueda desde cero para cada nuevo conjunto de datos; los autores plantean si, igual que en procesamiento de lenguaje natural, el preentrenamiento a gran escala puede sustituir la búsqueda heurística por inferencia directa.

Presentan NeSymReS (*Neural Symbolic Regression that Scales*), que genera de forma sintética millones de ecuaciones aleatorias junto con sus conjuntos de datos, y entrena un modelo *Transformer* para predecir directamente la expresión simbólica subyacente a partir de los pares entrada-salida observados.

En inferencia, las predicciones del modelo no se toman como respuesta final sino como guía (*prior*) para un algoritmo de búsqueda posterior, combinando así la velocidad del modelo neuronal preentrenado con el refinamiento de un procedimiento de búsqueda clásico.

Los experimentos muestran que el rendimiento del modelo mejora de forma consistente al aumentar los datos de entrenamiento sintéticos y el cómputo, replicando el patrón de escalado obser-

vado en grandes modelos de lenguaje, y logra recuperar ecuaciones físicas conocidas con inferencia órdenes de magnitud más rápida que los métodos evolutivos clásicos.

3.3. End-to-end symbolic regression with transformers

Fecha: Abril de 2022 (Preprint arXiv)

Citación: Kamienny, P.-A., d’Ascoli, S., Lample, G., & Charton, F. (2022). End-to-end symbolic regression with transformers. *arXiv preprint* arXiv:2204.10532.

Área de aplicación: Machine Learning Científico (Generación Conjunta de Estructura y Constantes Numéricas)

Resumen:

El flujo de trabajo estándar en regresión simbólica separa dos fases –encontrar el “esqueleto” estructural de la ecuación y después ajustar sus constantes numéricas mediante optimización no convexa– lo que introduce errores de propagación entre fases y ralentiza el proceso.

Los autores proponen un modelo *Transformer* extremo a extremo que genera simultáneamente la estructura simbólica completa de la ecuación y sus constantes numéricas en un único paso de inferencia, en lugar de seguir el procedimiento en dos etapas.

Las constantes numéricas predichas por la red pueden usarse directamente como salida final o como punto de partida informado para un refinamiento posterior mediante optimización local, acelerando la convergencia frente a una inicialización aleatoria.

Los estudios de ablación confirman que la generación conjunta produce mejores resultados que el enfoque en dos fases, funcionando en muchos casos incluso sin necesidad de refinamiento posterior; evaluado en SRBench, el modelo alcanza una precisión cercana a los mejores métodos de programación genética, pero con una inferencia varios órdenes de magnitud más rápida.

3.4. Deep symbolic regression for physics guided by units constraints (PhySO)

Fecha: Marzo de 2023 (Publicado en *The Astrophysical Journal*)

Citación: Tenachi, W., Ibata, R., & Diakogiannis, F. I. (2023). Deep symbolic regression for physics guided by units constraints: toward the automated discovery of physical laws. *The Astrophysical Journal*, 959(2), 99.

Área de aplicación: Astrofísica y Física Computacional (Regresión Simbólica con Restricciones Dimensionales)

Resumen:

La mayoría de los algoritmos de regresión simbólica ignoran que las magnitudes físicas tienen unidades, generando frecuentemente expresiones dimensionalmente absurdas (por ejemplo, sumar una longitud con una velocidad) que resultan inaceptables para uso en física, además de desperdiciar cómputo explorando un espacio de expresiones innecesariamente amplio.

Los autores desarrollan PhySO (*Physical Symbolic Optimization*), que combina aprendizaje por refuerzo profundo con un sistema de reglas de análisis dimensional que actúa como una “gramática” física, restringiendo la generación de expresiones a aquellas que son dimensionalmente consistentes por construcción.

Al incorporar las unidades directamente en el proceso generativo secuencial (en lugar de como penalización posterior en la función de pérdida), el espacio de búsqueda efectivo se reduce drásticamente, mejorando tanto la velocidad de convergencia como la robustez frente al ruido.

Evaluado sobre el *benchmark* de las Feynman Lectures, PhySO mantiene un rendimiento superior con niveles de ruido de hasta el 10 %, y los autores demuestran aplicaciones astrofísicas reales,

tanto derivando propiedades analíticas de modelos físicos conocidos como obteniendo aproximaciones analíticas a partir de datos observacionales ruidosos.

3.5. SymFormer: End-to-end symbolic regression using transformer-based architecture

Fecha: Mayo de 2022 (Preprint arXiv)

Citación: Vastl, M., Kulhánek, J., Kubalík, J., Derner, E., & Babuška, R. (2022). SymFormer: End-to-end symbolic regression using transformer-based architecture. *arXiv preprint arXiv:2205.15764*.

Área de aplicación: Machine Learning Científico (Arquitecturas Transformer para Regresión Simbólica)

Resumen:

Los modelos *Transformer* aplicados a regresión simbólica suelen generar únicamente la estructura simbólica de la fórmula sin sus coeficientes numéricos, delegando el ajuste de constantes a un procedimiento de optimización externo que con frecuencia converge a soluciones subóptimas.

Los autores presentan SymFormer, una arquitectura *Transformer* que predice simultáneamente los símbolos matemáticos y sus constantes numéricas asociadas durante la misma pasada de inferencia, eliminando la necesidad de una optimización de coeficientes completamente independiente.

El diseño combina una cabeza de clasificación para los operadores/símbolos con una cabeza de regresión para los valores numéricos, de forma que las constantes generadas sirven además como inicialización de alta calidad para un afinamiento posterior por gradiente si se desea mayor precisión.

En *benchmarks* estándar, SymFormer supera a dos métodos competidores de referencia tanto en precisión como en velocidad de inferencia, confirmando que la predicción conjunta de símbolos y constantes produce ajustes de mayor calidad que los enfoques secuenciales.

3.6. A Neural-Guided Dynamic Symbolic Network for Exploring Mathematical Expressions from Data

Fecha: Septiembre de 2023 (Publicado en ICML 2024)

Citación: Li, W., Li, W., Yu, L., Wu, M., Sun, L., Liu, J., Li, Y., Wei, S., Deng, Y., & Hao, M. (2024). A Neural-Guided Dynamic Symbolic Network for Exploring Mathematical Expressions from Data. *Proceedings of the 41st International Conference on Machine Learning (ICML)*.

Área de aplicación: Machine Learning Científico (Redes Simbólicas de Arquitectura Dinámica)

Resumen:

Los métodos generativos de regresión simbólica basados en búsqueda exhaustiva de expresiones escalan mal frente a problemas de alta dimensionalidad, donde el espacio combinatorio de posibles fórmulas crece de forma explosiva y la optimización de constantes se vuelve inestable.

Los autores proponen DySymNet, que en lugar de buscar directamente en el espacio de expresiones, explora un espacio de arquitecturas de “redes simbólicas” de forma y tamaño variables, cuyas conexiones y funciones de activación codifican operaciones matemáticas interpretables.

Un controlador de aprendizaje por refuerzo guía la búsqueda sobre las posibles arquitecturas simbólicas, mientras los parámetros internos de cada arquitectura candidata se ajustan mediante descenso de gradiente estándar para maximizar el ajuste a los datos.

DySymNet supera de forma sustancial a las líneas base comparables tanto en *benchmarks* de baja dimensión estándar como en SRBench (que incluye problemas de mayor dimensionalidad), demostrando que separar la búsqueda arquitectónica del ajuste numérico mejora la escalabilidad sin sacrificar interpretabilidad, gracias a que cada red simbólica final sigue siendo traducible a una expresión matemática explícita.

4. Modelos de Lenguaje y Búsqueda Evolutiva

4.1. LLM-SR: Scientific Equation Discovery via Programming with Large Language Models

Fecha: Abril de 2024 (Publicado en ICLR 2025, Oral)

Citación: Shojaei, P., Meidani, K., Gupta, S., Barati Farimani, A., & Reddy, C. K. (2025). LLM-SR: Scientific Equation Discovery via Programming with Large Language Models. *International Conference on Learning Representations (ICLR)*.

Área de aplicación: Machine Learning Científico (Descubrimiento de Ecuaciones Guiado por LLMs)

Resumen:

Los métodos clásicos de regresión simbólica ignoran el conocimiento científico previo, tratando cada problema como una búsqueda ciega sobre árboles de expresión, y suelen representar las ecuaciones con estructuras rígidas que limitan la expresividad del espacio de búsqueda.

Los autores proponen LLM-SR, que trata las ecuaciones como programas ejecutables y combina el conocimiento científico latente de un modelo de lenguaje grande (LLM) con búsqueda evolutiva: el LLM propone iterativamente nuevas hipótesis de “esqueletos” de ecuación informadas por su conocimiento de dominio, que después se optimizan numéricamente contra los datos.

El sistema mantiene una población de hipótesis de programas-ecuación, usa los resultados de ajuste como señal de *fitness* evolutivo, y realimenta al LLM con los mejores candidatos y su rendimiento para generar la siguiente generación de hipótesis, integrando así *prior* científico y optimización basada en datos en un mismo bucle.

Evaluable en problemas de física y biología, LLM-SR descubre ecuaciones más precisas que las líneas base de regresión simbólica estándar, con una ventaja particularmente marcada en generalización fuera de distribución; los autores destacan que incorporar *prior* científico permite explorar el espacio de ecuaciones de forma mucho más eficiente que la búsqueda evolutiva sin guía, con el añadido de que cada hipótesis generada es legible como código y por tanto inspeccionable por un científico.

4.2. LLM-SRBench: A New Benchmark for Scientific Equation Discovery with Large Language Models

Fecha: Abril de 2025 (Publicado en ICML 2025, Oral)

Citación: Shojaei, P., Nguyen, N.-H., Meidani, K., Barati Farimani, A., Doan, K. D., & Reddy, C. K. (2025). LLM-SRBench: A New Benchmark for Scientific Equation Discovery with Large Language Models. *Proceedings of the 42nd International Conference on Machine Learning (ICML)*.

Área de aplicación: Machine Learning Científico (Benchmarking de Descubrimiento Científico con LLMs)

Resumen:

Los LLM muestran capacidades prometedoras para el descubrimiento de ecuaciones gracias al conocimiento científico memorizado durante su preentrenamiento, pero esto mismo dificulta evaluarlos de forma justa: los *benchmarks* existentes usan ecuaciones ampliamente conocidas que el modelo puede simplemente recordar, inflando artificialmente el rendimiento reportado.

Los autores diseñan un *benchmark* de 239 problemas distribuidos en cuatro dominios científicos, compuesto por dos subconjuntos: uno que reformula ecuaciones físicas conocidas en formas matemáticas poco convencionales para evitar el simple reconocimiento memorístico, y otro con problemas sintéticos que exigen razonamiento genuino guiado por datos.

El diseño experimental separa explícitamente la capacidad de “recordar” fórmulas de la capacidad de “descubrir las” a partir de evidencia empírica, evaluando distintos LLM de última generación bajo condiciones controladas de acceso a los datos.

Los resultados muestran que incluso el sistema con mejor desempeño solo alcanza un 31.5 % de precisión simbólica, revelando que la capacidad de descubrimiento genuino de los LLM está muy por debajo de lo que sugerían los *benchmarks* anteriores, y estableciendo LLM-SRBench como herramienta de referencia para medir progreso real –no memorización– en este subcampo emergente.

4.3. Controllable Neural Symbolic Regression

Fecha: Abril de 2023 (Preprint arXiv)

Citación: Bendinelli, T., Biggio, L., & Kamienny, P.-A. (2023). Controllable Neural Symbolic Regression. *arXiv preprint* arXiv:2304.10336.

Área de aplicación: Machine Learning Científico (Incorporación de Conocimiento Experto en el Proceso Generativo)

Resumen:

Los algoritmos neuronales de regresión simbólica generan expresiones rápidamente, pero no ofrecen ningún mecanismo directo para incorporar el conocimiento de un experto de dominio sobre la forma esperada de la ecuación (por ejemplo, “debe contener un término exponencial” o “debe ser simétrica en dos variables”), un tipo de información habitualmente disponible y valiosa en ciencia e ingeniería.

Los autores proponen NSRwH (*Neural Symbolic Regression with Hypothesis*), un marco condicionado que permite inyectar explícitamente hipótesis estructurales sobre la expresión objetivo dentro del propio proceso de generación del modelo neuronal.

La red se entrena para condicionar su distribución de salida sobre restricciones estructurales especificadas por el usuario, de modo que las expresiones generadas respetan por construcción las hipótesis indicadas, en lugar de filtrarse a posteriori.

La evaluación experimental muestra que NSRwH supera en precisión a las líneas base no condicionadas, a la vez que permite un control deliberado sobre la arquitectura de la expresión predicha, tendiendo un puente directo entre los métodos neuronales de caja gris y el conocimiento aportado por el científico –una forma explícita de mejorar la interpretabilidad orientando la búsqueda hacia formas funcionales ya comprensibles para el usuario.

5. Benchmarks, Datasets y Herramientas

5.1. Contemporary Symbolic Regression Methods and their Relative Performance (SRBench)

Fecha: Julio de 2021 (Publicado en NeurIPS 2021, Datasets and Benchmarks Track)

Citación: La Cava, W., Orzechowski, P., Burlacu, B., de Franca, F. O., Virgolin, M., Jin, Y., Kommenda, M., & Moore, J. H. (2021). Contemporary Symbolic Regression Methods and their Relative Performance. *Advances in Neural Information Processing Systems*, 34 (NeurIPS Datasets and Benchmarks Track).

Área de aplicación: Machine Learning Científico (Benchmarking Estandarizado de Regresión Simbólica)

Resumen:

El campo de la regresión simbólica carecía de un estándar de evaluación común: cada nuevo método reportaba resultados sobre conjuntos de datos y protocolos distintos, dificultando comparar objetivamente el progreso del campo.

Los autores construyen SRBench, una plataforma de código abierto que evalúa 14 métodos de regresión simbólica y 7 métodos de *machine learning* de referencia sobre 252 problemas heterogéneos, incluyendo tanto *datasets* del mundo real con modelo desconocido como problemas sintéticos con verdad fundamental conocida (ecuaciones físicas, sistemas de ecuaciones diferenciales) bajo distintos niveles de ruido.

La plataforma define protocolos reproducibles de ejecución, tiempos límite y métricas comparables (precisión, complejidad de la expresión, tasa de recuperación exacta), y se publica junto con el código necesario para reproducir cada experimento y añadir nuevos métodos.

Los resultados muestran que los enfoques híbridos que combinan algoritmos genéticos con estimación de parámetros o búsqueda semántica logran el mejor rendimiento en problemas del mundo real, mientras que en la recuperación exacta de ecuaciones con ruido los métodos de aprendizaje profundo igualan a los genéticos; SRBench se convertiría en el *benchmark* de facto adoptado por la mayoría de los trabajos posteriores del campo, incluyendo varios recogidos en este documento.

5.2. Rethinking Symbolic Regression Datasets and Benchmarks for Scientific Discovery (SRSD)

Fecha: Junio de 2022 (Publicado en *Journal of Data-centric Machine Learning Research*, 2024)

Citación: Matsubara, Y., Chiba, N., Igarashi, R., & Ushiku, Y. (2024). Rethinking Symbolic Regression Datasets and Benchmarks for Scientific Discovery. *Journal of Data-centric Machine Learning Research*.

Área de aplicación: Machine Learning Científico (Rediseño de Datasets Físicos para Descubrimiento Científico)

Resumen:

El *dataset* Feynman original de AI Feynman, pese a ser el estándar de facto, muestrea las variables de entrada en rangos arbitrarios que no reflejan las magnitudes físicamente plausibles de cada ecuación, y evalúa el éxito con criterios binarios (recuperación exacta) o solo con error numérico, ambos insuficientes para capturar si un método realmente “descubrió” la ley física subyacente.

Los autores rediseñan el *benchmark* Feynman creando 120 *datasets* con rangos de muestreo físicamente realistas (SRSD), y añaden otros 120 *datasets* con variables irrelevantes deliberadamente incluidas, para evaluar si los métodos identifican correctamente solo las variables verdaderamente necesarias.

Proponen además la distancia de edición normalizada (NED) como nueva métrica, que mide la similitud estructural entre el árbol de expresión descubierto y el árbol de la ecuación verdadera, en lugar de depender únicamente de éxito binario o error numérico.

Un estudio con evaluadores humanos confirma que la métrica NED se correlaciona significativamente mejor con el juicio humano de “cuán correcta” es una fórmula descubierta que las métricas previas del campo; los 240 *datasets* y el código se publican abiertamente, ofreciendo una evaluación mucho más realista y rigurosa de la capacidad de descubrimiento científico –no solo de ajuste numérico– de los métodos de regresión simbólica.

5.3. Interpretable Machine Learning for Science with PySR and SymbolicRegression.jl

Fecha: Mayo de 2023 (Preprint arXiv)

Citación: Cranmer, M. (2023). Interpretable Machine Learning for Science with PySR and SymbolicRegression.jl. *arXiv preprint* arXiv:2305.01582.

Área de aplicación: Machine Learning Científico (Herramienta de Código Abierto para Regresión Simbólica)

Resumen:

Gran parte de la comunidad científica necesita modelos legibles por humanos, no predicciones de caja negra; sin embargo, hasta la publicación de esta herramienta, faltaba una implementación de regresión simbólica que fuera simultáneamente accesible (Python), de alto rendimiento (para escalar a *datasets* científicos reales) e interoperable con el ecosistema de aprendizaje profundo.

El autor presenta PySR, una biblioteca de código abierto construida sobre un *backend* en Julia de alto rendimiento (SymbolicRegression.jl), que implementa un algoritmo evolutivo multi-población con un novedoso ciclo “evolucionar-simplificar-optimizar” para refinar las constantes escalares de cada expresión candidata.

El motor en Julia aprovecha compilación *just-in-time*, *kernels* vectorizados (SIMD), diferenciación automática y computación distribuida en clúster, mientras que la interfaz en Python se integra directamente con PyTorch y otros *frameworks* de *deep learning* para su uso combinado con redes neuronales.

Los autores introducen además “EmpiricalBench”, un nuevo *benchmark* que mide qué tan bien los métodos de regresión simbólica recuperan ecuaciones empíricas históricas a partir de datos originales y sintéticos, cuantificando la utilidad práctica de la herramienta más allá de *benchmarks* puramente sintéticos; PySR se ha convertido en una de las herramientas de regresión simbólica más utilizadas en física y astronomía computacional.

5.4. Exploring Multi-view Symbolic Regression methods in physical sciences

Fecha: Septiembre de 2025 (Publicado en *Philosophical Transactions A*)

Citación: Russeil, E., de França, F. O., Malanchev, K., Moinard, G., & Cherrey, M. (2025). Exploring Multi-view Symbolic Regression methods in physical sciences. *Philosophical Transactions of the Royal Society A*.

Área de aplicación: Machine Learning Científico (Regresión Simbólica Multi-Vista)

Resumen:

La regresión simbólica estándar ajusta una única función a un único *dataset*, lo que la hace vulnerable al sobreajuste y a la escasez de datos cuando se dispone de múltiples conjuntos de observaciones relacionados que comparten la misma forma funcional pero con parámetros distintos (por ejemplo, la misma ley física medida en distintos experimentos).

Los autores evalúan la Regresión Simbólica Multi-Vista (MvSR), una extensión que busca una única función paramétrica capaz de explicar simultáneamente varios *datasets* relacionados, compartiendo la estructura funcional pero permitiendo que los parámetros varíen entre vistas.

Comparan cuatro implementaciones representativas del estado del arte –Operon, PySR, PhySO y eggp– sobre conjuntos de datos reales, analizando qué características de cada herramienta favorecen consistentemente la obtención de modelos más parsimoniosos.

Todas las implementaciones evaluadas logran una precisión razonable proponiendo modelos con un número mínimo de parámetros libres; los autores concluyen con recomendaciones concretas para el desarrollo futuro de MvSR, señalando la fusión de múltiples fuentes de evidencia como una vía prometedora para mejorar la robustez y generalización de la regresión simbólica en ciencias físicas.

6. Aplicaciones Científicas

6.1. Discovering Symbolic Models from Deep Learning with Inductive Biases

Fecha: Junio de 2020 (Publicado en NeurIPS 2020)

Citación: Cranmer, M., Sanchez-Gonzalez, A., Battaglia, P., Xu, R., Cranmer, K., Spergel, D., & Ho, S. (2020). Discovering Symbolic Models from Deep Learning with Inductive Biases. *Advances in Neural Information Processing Systems*, 33 (NeurIPS 2020).

Área de aplicación: Astrofísica Computacional (Destilación Simbólica de Redes Neuronales de Grafos)

Resumen:

Las Redes Neuronales de Grafos (GNN) generalizan bien a sistemas físicos de muchos cuerpos gracias a sus sesgos inductivos relacionales, pero siguen siendo modelos de caja negra cuyas representaciones internas no son directamente interpretables por un físico.

Los autores proponen un procedimiento de dos etapas: primero entrenan una GNN con fuerte regularización de dispersión (L1) sobre una tarea supervisada, forzando a que solo unas pocas componentes de los mensajes internos de la red se activen; después aplican regresión simbólica sobre esas componentes para extraer expresiones matemáticas explícitas equivalentes a la función interna aprendida.

La técnica se valida recuperando leyes físicas conocidas (fuerzas gravitatorias, funciones de energía) codificadas implícitamente en los pesos de una GNN entrenada, confirmando que la regularización de dispersión facilita después la extracción simbólica limpia de esas funciones.

Aplicado a un problema cosmológico real –predecir la sobredensidad de materia oscura a partir de la distribución de masa circundante en simulaciones de estructura a gran escala–, el método descubre una fórmula analítica novedosa no reportada previamente en la literatura; notablemente, el modelo simbólico extraído generaliza mejor a datos no vistos que la GNN original, demostrando que la destilación simbólica no solo añade interpretabilidad sino que puede mejorar la capacidad de generalización del modelo.

6.2. Learning Interpretable Network Dynamics via Universal Neural Symbolic Regression

Fecha: Noviembre de 2024 (Preprint arXiv)

Citación: Hu, J., Cui, J., & Yang, B. (2024). Learning Interpretable Network Dynamics via Universal Neural Symbolic Regression. *arXiv preprint* arXiv:2411.06833.

Área de aplicación: Sistemas Complejos (Descubrimiento de Ecuaciones de Dinámica de Redes)

Resumen:

Entender las ecuaciones que gobiernan la evolución temporal de sistemas complejos en red – desde epidemias hasta ecosistemas – permitiría revelar mecanismos ocultos, pero los métodos de regresión simbólica genéricos no están adaptados a la estructura relacional propia de las dinámicas sobre redes ni generalizan bien entre dominios muy distintos.

Los autores desarrollan un marco híbrido que combina la capacidad de las redes neuronales para ajustar patrones dinámicos complejos con la de la regresión simbólica para inferir las ecuaciones explícitas subyacentes, diseñado como un modelo “universal” transferible entre múltiples dominios de dinámica de redes.

El sistema se entrena sobre una amplia variedad de dinámicas sintéticas (físicas, bioquímicas, ecológicas, epidemiológicas) para aprender una representación común de cómo los estados de los nodos evolucionan en función de su vecindario en el grafo, que después se traduce en una expresión simbólica interpretable específica del sistema evaluado.

Validado sobre datos reales de propagación de pandemias globales y de movimiento de multitudes, el método supera a los métodos de regresión simbólica existentes específicos de dinámica de redes, confirmando su utilidad práctica para revelar mecanismos ocultos en sistemas complejos del mundo real y avanzar la interpretabilidad en modelado de redes dinámicas.

6.3. Symbolic Regression for Beyond the Standard Model Physics

Fecha: Mayo de 2024 (Publicado en *Physical Review D*)

Citación: AbdusSalam, S. S., Abel, S., & Crispim Romão, M. (2024). Symbolic Regression for Beyond the Standard Model Physics. *Physical Review D*.

Área de aplicación: Física de Partículas (Modelado Simbólico de Física Más Allá del Modelo Estándar)

Resumen:

Explorar el espacio de parámetros de modelos teóricos de física más allá del Modelo Estándar –como el Modelo Estándar Supersimétrico Mínimo Restrungido (CMSSM)– requiere evaluar observables costosos computacionalmente (masa del bosón de Higgs, anomalía del momento magnético del muón, abundancia de materia oscura) para cada punto candidato, lo que hace prohibitivo un muestreo exhaustivo del espacio de parámetros de alta dimensión.

Los autores aplican regresión simbólica para obtener fórmulas analíticas explícitas que relacionan los cuatro parámetros del CMSSM definidos a la escala de Gran Unificación con cada uno de esos observables físicos.

Una vez obtenidas las expresiones simbólicas, las emplean directamente en un análisis de inferencia de parámetros (obtención de distribuciones posteriores), sustituyendo así las costosas evaluaciones numéricas del modelo original por evaluaciones instantáneas de las fórmulas descubiertas.

El enfoque permite obtener las distribuciones posteriores de los parámetros del modelo significativamente más rápido que las técnicas computacionales convencionales, demostrando que las expresiones simbólicas descubiertas por IA pueden acelerar sustancialmente los flujos de trabajo de inferencia en física de altas energías, a la vez que ofrecen una relación funcional explícita e interpretable entre teoría y observables –en contraste con los emuladores de caja negra habituales en este campo.

6.4. Symbolic regression for precision LHC physics

Fecha: Diciembre de 2024 (NeurIPS 2024, Workshop Machine Learning and the Physical Sciences)

Citación: Morales-Alvarado, M., Conde, D., Bendavid, J., Sanz, V., & Ubiali, M. (2024). Symbolic regression for precision LHC physics. *Machine Learning and the Physical Sciences Workshop, NeurIPS 2024*.

Área de aplicación: Física de Partículas (Fenomenología de Precisión en el LHC)

Resumen:

La fenomenología de precisión del Gran Colisionador de Hadrones (LHC) necesita fórmulas analíticas compactas que sean simultáneamente precisas e interpretables; los emuladores numéricos de caja negra habituales, aunque precisos, no ofrecen la transparencia funcional que los físicos requieren para validar e interpretar resultados.

Los autores emplean regresión simbólica para generar fórmulas analíticas concisas, validando primero el enfoque con electrodinámica cuántica –donde existen predicciones teóricas exactas conocidas que sirven de referencia objetiva– antes de extender la metodología a un problema sin solución analítica cerrada.

Aplican después la técnica a las funciones de estructura en procesos Drell-Yan con fotones virtuales, un caso donde no existen soluciones analíticas de primeros principios disponibles, evaluando la capacidad de la regresión simbólica para producir aproximaciones funcionales útiles en ese régimen.

Los resultados confirman que la regresión simbólica combina la transparencia de las expresiones matemáticas con la capacidad predictiva del aprendizaje automático, posicionándose como una herramienta valiosa para la física de altas energías de precisión allí donde los cálculos de primeros principios son intratables o inexistentes.

6.5. Discovering physical laws with parallel symbolic enumeration

Fecha: Julio de 2024 (Preprint arXiv)

Citación: Ruan, K., Xu, Y., Gao, Z.-F., Guo, Y., Sun, H., Wen, J.-R., & Liu, Y. (2024). Discovering physical laws with parallel symbolic enumeration. *arXiv preprint* arXiv:2407.04405.

Área de aplicación: Machine Learning Científico (Búsqueda Eficiente del Espacio de Expresiones)

Resumen:

Durante la última década, los métodos de regresión simbólica han seguido enfrentando dificultades ante problemas complejos, con tiempos de búsqueda elevados y baja tasa de recuperación exacta, lo que limita su adopción como herramienta científica de uso general.

Los autores proponen la Enumeración Simbólica Paralela (PSE), una técnica que explora de forma más eficiente el espacio de expresiones matemáticas posibles a partir de conjuntos de datos limitados, paralelizando la enumeración de estructuras candidatas en lugar de realizar una búsqueda evolutiva o secuencial.

El método se evalúa sobre más de 200 problemas, combinando ecuaciones sintéticas de referencia con datos experimentales reales, comparando sistemáticamente tiempo de ejecución y tasa de recuperación frente a los métodos de referencia establecidos del campo.

PSE logra mejoras de hasta el 99 % en la tasa de recuperación exacta de expresiones, reduciendo además el tiempo de ejecución en un orden de magnitud respecto a las líneas base, lo que representa un avance significativo en la escalabilidad práctica de la regresión simbólica para el descubrimiento de leyes físicas interpretables a partir de datos limitados.

6.6. Evolving Scientific Discovery by Unifying Data and Background Knowledge with AI-Hilbert

Fecha: Agosto de 2023 (Publicado en *Nature Communications*, 2024)

Citación: Cory-Wright, R., Cornelio, C., Dash, S., El Khadir, B., & Horesh, L. (2024). Evolving scientific discovery by unifying data and background knowledge with AI-Hilbert. *Nature Communications*, 15, 5922.

Área de aplicación: Machine Learning Científico (Optimización Polinómica y Razonamiento Axiomático)

Resumen:

Los métodos híbridos que combinan regresión con razonamiento (como AI-Descartes) demostraron que excluir fórmulas inconsistentes con la teoría mejora el descubrimiento científico, pero buscar de forma eficiente en todo el espacio de ecuaciones teóricamente consistentes seguía sin resolverse de forma escalable, especialmente cuando la evidencia experimental es ruidosa o limitada.

Los autores presentan AI-Hilbert, aplicable cuando los axiomas y leyes científicas de partida pueden expresarse como igualdades y desigualdades polinómicas, codificando el problema de

búsqueda con variables binarias y restricciones lógicas que limitan la complejidad de la expresión resultante.

El sistema resuelve el problema resultante mediante optimización mixta entera lineal o semidefinida, y valida cada descubrimiento aportando un certificado formal basado en el Positivstellensatz, con una complejidad computacional que va de tiempo polinómico (con teoría de fondo completamente correcta) a NP (con teoría parcialmente correcta).

El método deriva con éxito leyes científicas históricas –la tercera ley de Kepler, la ecuación de Hagen-Poiseuille y la potencia radiada por ondas gravitacionales– directamente a partir de axiomas fundacionales y datos experimentales, aportando además, a diferencia de la mayoría de métodos de esta lista, una certificación matemática formal de que la ley descubierta es consistente con la teoría subyacente.