

Estado del Arte: Hamiltonian Neural Networks (HNN)

Ricardo Luis Urretxo Riofrancos

30 de agosto de 2026

Índice

Introducción	1
1. Fundamentos y Arquitecturas Base	2
2. Port-Hamiltonian Neural Networks	5
3. Extensiones Arquitectónicas	9
4. Dinámica No Lineal y Caos	11
5. Aplicaciones Físicas Reproducibles	12
6. Explicabilidad e Interpretabilidad	14
7. Evaluación y Comparativas	16
8. Optimización Inspirada en Dinámica Hamiltoniana	17
9. Catálogo de Implementaciones Open-Source	18
10. Lista de Ejemplos y Sistemas Físicos de Referencia	19

Introducción

Este documento presenta una revisión del estado del arte de las Hamiltonian Neural Networks (HNN) y su familia de arquitecturas relacionadas (redes lagrangianas, port-hamiltonianas y simpléticas), clasificadas por su área de aplicación. La biblioteca reunida cubre los fundamentos matemáticos del campo, sus principales extensiones arquitectónicas, aplicaciones concretas a sistemas físicos reproducibles, y un bloque específico dedicado a la explicabilidad e interpretabilidad de la dinámica hamiltoniana aprendida, dado su papel central en la adopción de estos modelos en dominios científicos de alto riesgo. Los artículos y sus PDF correspondientes se organizan en la carpeta **papers/** del proyecto, en subcarpetas numeradas que replican las secciones de este documento. Tras la biblioteca de papers (secciones 1-8), el documento incorpora un catálogo de implementaciones de código abierto disponibles para estas arquitecturas (sección 9) y una lista de sistemas físicos y ejemplos de referencia utilizados en la literatura, con su correspondencia a los papers de este documento (sección 10).

1. Fundamentos y Arquitecturas Base

Hamiltonian Neural Networks

Fecha: 5 de septiembre de 2019 (Preprint arXiv v3; NeurIPS 2019)

Citación: Greydanus, S., Dzamba, M., & Yosinski, J. (2019). Hamiltonian Neural Networks. *Advances in Neural Information Processing Systems (NeurIPS 2019)*, 32. arXiv preprint arXiv:1906.01563.

Área de aplicación: Fundamentos (Mecánica Hamiltoniana Aplicada a Redes Neuronales)

Resumen:

A pesar del uso extendido de las redes neuronales, estas tienen dificultades para aprender las leyes básicas de la física de forma implícita. Para dotar a los modelos de un sesgo inductivo más adecuado, los autores proponen las Hamiltonian Neural Networks (HNN), que se inspiran en la mecánica hamiltoniana clásica para aprender —de forma no supervisada— una función escalar $H_\theta(q, p)$ cuyas derivadas parciales, a través de las ecuaciones de Hamilton ($\dot{q} = \partial H / \partial p$, $\dot{p} = -\partial H / \partial q$), generan el campo vectorial del sistema dinámico. A diferencia de una red neuronal estándar que aprende directamente el campo vectorial, este diseño garantiza que la cantidad H_θ , análoga a la energía total, se conserve exactamente a lo largo de las trayectorias predichas, en lugar de solo aproximadamente. Los autores validan el modelo en el problema de los dos cuerpos y en observaciones de píxeles de un péndulo, mostrando que la HNN entrena más rápido y generaliza mejor que una red base convencional. Un efecto colateral interesante es que el modelo resulta perfectamente reversible en el tiempo, una propiedad intrínseca de los sistemas hamiltonianos. Este trabajo es el artículo fundacional que da origen a toda la familia de arquitecturas de redes neuronales hamiltonianas.

Symplectic ODE-Net: Learning Hamiltonian Dynamics with Control

Fecha: Septiembre de 2019 (Preprint arXiv:1909.12077; publicado en ICLR 2020)

Citación: Zhong, Y. D., Dey, B., & Chakraborty, A. (2020). Symplectic ODE-Net: Learning Hamiltonian Dynamics with Control. *International Conference on Learning Representations (ICLR 2020)*. arXiv preprint arXiv:1909.12077.

Área de aplicación: Fundamentos y Control (Sistemas Dinámicos con Actuación)

Resumen:

Este trabajo introduce Symplectic ODE-Net (SymODEN), un marco de aprendizaje profundo capaz de inferir la dinámica de un sistema físico —descrita como una ecuación diferencial ordinaria— a partir de trayectorias de estado observadas, incorporando además señales de control externas. Para lograr mejor generalización con menos muestras de entrenamiento, SymODEN incorpora un sesgo inductivo apropiado al diseñar el grafo de cómputo de manera informada por la física: impone dinámica hamiltoniana con control, lo que permite extraer información interpretable sobre aspectos físicos relevantes del sistema, como la inercia y la energía potencial. Además, los autores proponen una parametrización que permite aplicar el formalismo hamiltoniano incluso cuando las coordenadas generalizadas están embebidas en un espacio de alta dimensión, o cuando solo se dispone de datos de velocidad en lugar del momento generalizado canónico. Al ofrecer modelos físicamente consistentes e interpretables, este marco abre la puerta a la síntesis de estrategias de control basadas en energía (moldeado de energía, asignación de interconexión y amortiguamiento). SymODEN constituye una de las extensiones fundacionales de las HNN hacia sistemas con control externo.

Lagrangian Neural Networks

Fecha: 30 de julio de 2020 (Preprint arXiv v2; ICLR 2020 Workshop DeepDiffEq)

Citación: Cranmer, M., Greydanus, S., Hoyer, S., Battaglia, P., Spergel, D., & Ho, S. (2020). Lagrangian Neural Networks. *ICLR 2020 Workshop on Integration of Deep Neural Models and Differential Equations (DeepDiffEq)*. arXiv preprint arXiv:2003.04630.

Área de aplicación: Fundamentos (Mecánica Lagrangiana Aplicada a Redes Neuronales)

Resumen:

Los modelos precisos del mundo se construyen sobre nociones de simetrías subyacentes, que en física se corresponden con leyes de conservación como la energía y el momento. Sin embargo, las redes neuronales convencionales tienen dificultades para aprender estas simetrías. Los autores proponen las Lagrangian Neural Networks (LNN), que parametrizan lagrangianos arbitrarios mediante redes neuronales. A diferencia de los modelos que aprenden hamiltonianos, las LNN no requieren coordenadas canónicas, por lo que funcionan bien en situaciones donde el momento canónico es desconocido o difícil de calcular. Además, el método no restringe la forma funcional de las energías aprendidas y produce modelos que conservan la energía para una amplia variedad de tareas. Los autores validan su enfoque en un péndulo doble y en una partícula relativista, demostrando conservación de energía donde un modelo base sufre disipación espuria, y modelando la relatividad en un caso donde un enfoque hamiltoniano fallaría por carecer de coordenadas canónicas naturales. Finalmente, muestran cómo el modelo puede aplicarse a grafos y a sistemas continuos mediante una Lagrangian Graph Network, demostrándolo en la ecuación de onda 1D. Este trabajo es una referencia obligada como familia alternativa de redes basadas en principios variacionales, complementaria a las HNN.

SympNets: Intrinsic structure-preserving symplectic networks for identifying Hamiltonian systems

Fecha: 19 de agosto de 2020 (Preprint arXiv v3; publicado en *Neural Networks*, 2020)

Citación: Jin, P., Zhang, Z., Zhu, A., Tang, Y., & Karniadakis, G. E. (2020). SympNets: Intrinsic structure-preserving symplectic networks for identifying Hamiltonian systems. *Neural Networks*, 132, 166-179.

Área de aplicación: Fundamentos (Redes Simpléticas para Identificación de Sistemas)

Resumen:

Los autores proponen las SympNets, nuevas redes simpléticas para identificar sistemas hamiltonianos a partir de datos, construidas mediante la composición de módulos lineales, de activación y de gradiente. Se definen dos clases: las LA-SympNets, compuestas por módulos lineales y de activación, y las G-SympNets, compuestas por módulos de gradiente. A diferencia de las HNN, que aprenden una función escalar H_θ y derivan el campo vectorial mediante diferenciación automática, las SympNets aprenden directamente el mapa de flujo discreto del sistema, garantizando por construcción que dicho mapa sea simplético. Los autores demuestran dos teoremas de aproximación universal que prueban que las SympNets pueden aproximar mapas simpléticos arbitrarios utilizando funciones de activación apropiadas. Los experimentos —péndulo, péndulo doble y problema de los tres cuerpos— muestran que incluso SympNets de tamaño muy reducido generalizan bien y manejan sistemas tanto separables como no separables, a partir de datos muestreados con pasos temporales cortos o largos. En todos los casos, las SympNets superan a los modelos base y

son considerablemente más rápidas tanto en entrenamiento como en predicción, incluso con datos muestreados de forma irregular.

Hamiltonian Generative Networks

Fecha: 14 de febrero de 2020 (Preprint arXiv v2; ICLR 2020)

Citación: Toth, P., Rezende, D. J., Jaegle, A., Racanière, S., Botev, A., & Higgins, I. (2020). Hamiltonian Generative Networks. *International Conference on Learning Representations (ICLR 2020)*. arXiv preprint arXiv:1909.13789.

Área de aplicación: Fundamentos (Aprendizaje de Dinámica Hamiltoniana desde Imágenes)

Resumen:

El formalismo hamiltoniano desempeña un papel central en la física clásica y cuántica, ofreciendo propiedades útiles como la reversibilidad temporal y la interpolación suave en el tiempo, pero estas propiedades no están disponibles de forma nativa en herramientas estándar como las redes neuronales recurrentes. Los autores, investigadores de DeepMind, presentan la Hamiltonian Generative Network (HGN), el primer enfoque capaz de aprender de forma consistente dinámica hamiltoniana a partir de observaciones de alta dimensionalidad —como imágenes— sin imponer supuestos de dominio restrictivos. El modelo se describe como un autoencoder variacional extendido temporalmente, que infiere el espacio de fases latente a partir de secuencias de imágenes mediante un objetivo similar al de un VAE. Una vez entrenada, la HGN permite muestrear nuevas trayectorias, ejecutar simulaciones tanto hacia adelante como hacia atrás en el tiempo, e incluso acelerar o ralentizar la dinámica aprendida. Los autores muestran además que una modificación sencilla de la arquitectura la convierte en un potente modelo de flujo normalizador, denominado Neural Hamiltonian Flow (NHF), que emplea dinámica hamiltoniana para modelar densidades expresivas. Este trabajo es una referencia clave como ejemplo de aplicación de HNN a datos de imagen/vídeo en lugar de estados simbólicos directos.

A generalized framework of neural networks for Hamiltonian systems

Fecha: 28 de octubre de 2024 (publicado online); *Journal of Computational Physics*, 521 (2025), 113536

Citación: Horn, P., Saz Ulibarrena, V., Koren, B., & Portegies Zwart, S. (2025). A generalized framework of neural networks for Hamiltonian systems. *Journal of Computational Physics*, 521, 113536.

Área de aplicación: Fundamentos (Marco Unificador de Arquitecturas Simpléticas)

Resumen:

Al resolver sistemas hamiltonianos mediante integradores numéricos, preservar la estructura simpléctica puede ser crucial, mientras que resolver problemas caóticos o rígidos exige integradores capaces de aproximar las trayectorias con extrema precisión, lo que puede ser computacionalmente costoso. Una red neuronal puede constituir una alternativa viable a los integradores numéricos, ofreciendo soluciones de alta fidelidad varios órdenes de magnitud más rápidas. Para entender si también es importante preservar la simplecticidad cuando se usan redes neuronales, los autores

analizan tres arquitecturas bien conocidas que incorporan la estructura simpléctica en su topología —Symplectic Recurrent Neural Networks, SympNets y HénonNets— encontrando numerosas similitudes entre ellas. Esto permite formular un marco generalizado en el que dichas arquitecturas quedan incluidas como casos particulares, habilitando además el descubrimiento de nuevas topologías mediante transiciones entre las arquitecturas establecidas. Los autores comparan las nuevas Generalized Hamiltonian Neural Networks (GHNN) frente a SympNets, HénonNets y perceptrones multicapa no conscientes de la física, usando datos de un péndulo, un péndulo doble y un problema gravitacional de tres cuerpos, con especial atención a la capacidad de generalizar fuera de los datos de entrenamiento. Las GHNN superan a todas las demás arquitecturas en los problemas considerados.

2. Port-Hamiltonian Neural Networks

Co-Learning Port-Hamiltonian Systems and Optimal Energy-Shaping Control

Fecha: 5 de mayo de 2026 (Preprint arXiv v2)

Citación: Kamboj, A., Dey, B., & Srivastava, V. (2026). Co-Learning Port-Hamiltonian Systems and Optimal Energy-Shaping Control. arXiv preprint arXiv:2604.26172.

Área de aplicación: Control Basado en Energía (Port-Hamiltonian Systems)

Resumen:

Los autores desarrollan un marco de aprendizaje informado por la física para el control por moldeo de energía (energy-shaping control) de sistemas port-hamiltonianos (pH) a partir de datos de trayectorias. El enfoque co-aprende de manera conjunta un modelo del sistema pH y un controlador óptimo de balance de energía basado en pasividad (EB-PBC), mediante optimización alternada con recolección de datos consciente de la política de control: en cada iteración, el modelo se refina usando datos de trayectoria recolectados bajo la política actual, y el controlador se reoptimiza sobre el modelo actualizado. Ambos componentes se parametrizan mediante redes neuronales que incorporan la estructura pH y del controlador EB-PBC, garantizando interpretabilidad en términos de interacciones energéticas. El controlador aprendido hace que el sistema en lazo cerrado sea inherentemente pasivo y demostrablemente estable, explotando la dinámica pasiva de la planta sin cancelar el potencial natural del sistema. Una regularización de disipación impone un decaimiento estricto de la energía durante el entrenamiento, mejorando la robustez frente a la brecha entre simulación y realidad. El marco se valida en tareas de regulación de estado y de *swing-up* en sistemas de péndulo plano y torsional.

Controlled oscillation modeling using port-Hamiltonian neural networks

Fecha: 17 de febrero de 2026 (Preprint arXiv v1)

Citación: Linares, M., Doras, G., Hélie, T., & Roebel, A. (2026). Controlled oscillation modeling using port-Hamiltonian neural networks. arXiv preprint arXiv:2602.15704.

Área de aplicación: Acústica y Sistemas Oscilatorios Controlados

Resumen:

Aprender sistemas dinámicos mediante métodos puramente basados en datos es un reto porque estos métodos no capturan las leyes de conservación subyacentes que permitirían generalizar correctamente. Los métodos de redes neuronales port-hamiltonianas existentes se han aplicado con éxito al

modelado de sistemas mecánicos, pero, aunque se diseñan sobre principios de balance de potencia, habitualmente no consideran discretizaciones que preserven dicha potencia y suelen depender de métodos de Runge-Kutta. Los autores proponen emplear un método de gradiente discreto de segundo orden embebido en el aprendizaje de sistemas dinámicos mediante redes port-hamiltonianas. Se presentan resultados numéricos para tres sistemas seleccionados para abarcar distintos rangos de comportamiento dinámico controlado: un oscilador armónico de referencia con almacenamiento de energía cuadrático; un oscilador de Duffing, con hamiltoniano no cuadrático que ofrece efectos dependientes de la amplitud; y un oscilador autosostenido, capaz de estabilizarse en un ciclo límite controlado mediante disipación no lineal. Los autores muestran que el método de gradiente discreto supera a un método de Runge-Kutta del mismo orden, y comparan dos formulaciones port-hamiltonianas teóricamente equivalentes, analizando el impacto de regularizar el jacobiano de la red durante el entrenamiento.

Identifying the nonlinear string dynamics with port-Hamiltonian neural networks

Fecha: 12 de mayo de 2026 (Preprint arXiv v1)

Citación: Linares, M., Doras, G., & Hélie, T. (2026). Identifying the nonlinear string dynamics with port-Hamiltonian neural networks. arXiv preprint arXiv:2605.12785.

Área de aplicación: Acústica Musical (Dinámica de Cuerdas No Lineales)

Resumen:

El aprendizaje automático híbrido combina el conocimiento físico con modelos basados en datos para mejorar tanto la interpretabilidad como el rendimiento. En este contexto, los Sistemas Port-Hamiltonianos (PHS), que generalizan la mecánica hamiltoniana para describir sistemas dinámicos abiertos y no autónomos, se han integrado con éxito con redes neuronales bajo el nombre de Port-Hamiltonian Neural Networks (PHNN). Si bien la capacidad de las PHNN para identificar sistemas hamiltonianos descritos por ecuaciones diferenciales ordinarias ya se había demostrado, su aplicación al aprendizaje de sistemas hamiltonianos descritos por ecuaciones en derivadas parciales permanecía en gran medida inexplorada, lo que limitaba su uso en acústica musical, donde los instrumentos se modelan habitualmente como sistemas de parámetros distribuidos. Los autores demuestran cómo aprender la dinámica no lineal de una cuerda a partir de datos, dentro de un marco físicamente consistente, mediante una extensión de las PHNN a EDPs. Al construir arquitecturas de red estructuradas basadas en PHS, es posible recuperar tanto el hamiltoniano que rige la cuerda como la disipación que la afecta. Este enfoque supera a métodos base no informados por la física tanto en precisión como en interpretabilidad, y experimentos con datos sintéticos demuestran la capacidad del modelo para identificar y emular la dinámica no lineal del sistema.

Improved Initialization for Port-Hamiltonian Neural Network Models

Fecha: 27 de enero de 2026 (Preprint arXiv v1)

Citación: van Otterdijk, G. J. E., Weiland, S., & Schoukens, M. (2026). Improved Initialization for Port-Hamiltonian Neural Network Models. arXiv preprint arXiv:2601.19617.

Área de aplicación: Identificación de Sistemas (Inicialización de Modelos)

Resumen:

Las redes neuronales port-hamiltonianas han mostrado resultados prometedores en la identificación de dinámicas no lineales de sistemas complejos, ya que su combinación de principios físicos con aprendizaje basado en datos permite un modelado preciso. Sin embargo, debido al problema de optimización no convexo inherente al aprendizaje de los parámetros correctos de la red, el procedimiento de entrenamiento es propenso a converger a mínimos locales, lo que puede derivar en un rendimiento deficiente. Para evitar este problema, los autores proponen una inicialización mejorada para las redes port-hamiltonianas. La idea central consiste en estimar primero un sistema port-hamiltoniano lineal, que se utiliza como inicialización de la red, tras lo cual la red neuronal se adapta a las no linealidades del sistema, reduciendo los tiempos de entrenamiento y mejorando la convergencia. Dado que obtener una buena estimación lineal port-hamiltoniana no es una tarea trivial, el trabajo propone además un método alternativo para obtenerlas, mejorando la fiabilidad y el coste computacional respecto a los enfoques existentes. La efectividad del método se evalúa en un montaje de masa-resorte-amortiguador encadenado bajo distintos niveles de ruido, comparándose frente al enfoque original.

Dissipative SymODEN: Encoding Hamiltonian Dynamics with Dissipation and Control into Deep Learning

Fecha: 30 de abril de 2020 (Preprint arXiv v3; ICLR 2020 Workshop DeepDiffEq)

Citación: Zhong, Y. D., Dey, B., & Chakraborty, A. (2020). Dissipative SymODEN: Encoding Hamiltonian Dynamics with Dissipation and Control into Deep Learning. *ICLR 2020 Workshop on Integration of Deep Neural Models and Differential Equations (DeepDiffEq)*. arXiv preprint arXiv:2002.08860.

Área de aplicación: Control Basado en Energía con Disipación

Resumen:

Inferir la dinámica de un sistema a partir de trayectorias observadas juega un papel crítico en la identificación y el control de sistemas físicos complejos, como manipuladores robóticos o sistemas HVAC. Sin embargo, la imposición estricta de un prior hamiltoniano resulta restrictiva para sistemas que habitualmente pierden energía de forma estructurada, como las pérdidas por fricción en brazos robóticos o las pérdidas resistivas en redes eléctricas. Para incorporar explícitamente la disipación como prior dentro del aprendizaje de extremo a extremo, los autores extienden la arquitectura Symplectic ODE-Net (SymODEN) y proponen Dissipative SymODEN, motivada por la formulación port-hamiltoniana, que introduce un término de corrección que da cuenta del prior de disipación. Los resultados muestran que la incorporación de la disipación mejora la precisión de predicción y el comportamiento fuera de muestra, además de ofrecer información sobre propiedades físicas relevantes del sistema (matriz de inercia, energía potencial, disipación de energía). Estas percepciones permiten a su vez el uso de controladores basados en energía, como el método del lagrangiano controlado y la asignación de interconexión y amortiguamiento.

Stable Port-Hamiltonian Neural Networks

Fecha: 5 de noviembre de 2025 (Preprint arXiv v2)

Citación: Roth, F. J., Klein, D. K., Kannapinn, M., Peters, J., & Weeger, O. (2025). Stable Port-Hamiltonian Neural Networks. arXiv preprint arXiv:2502.02480.

Área de aplicación: Identificación de Sistemas y Estabilidad Garantizada

Resumen:

La identificación de sistemas dinámicos no lineales mediante redes neuronales artificiales ha atraído gran atención por su amplio potencial de aplicación en ciencia e ingeniería. Sin embargo, los enfoques puramente basados en datos suelen tener dificultades con la extrapolación y pueden producir predicciones físicamente implausibles; además, la dinámica aprendida puede exhibir inestabilidades, dificultando su aplicación segura y robusta. Este trabajo presenta las redes port-hamiltonianas estables, una arquitectura de aprendizaje automático que incorpora sesgos físicos de conservación de energía y disipación, garantizando al mismo tiempo la estabilidad global de Lyapunov de la dinámica aprendida. A través de ejemplos ilustrativos y del mundo real, los autores demuestran que estos fuertes sesgos inductivos facilitan un aprendizaje robusto de dinámicas estables a partir de datos escasos, evitando la inestabilidad y superando a los enfoques puramente basados en datos tanto en precisión como en generalización físicamente significativa. Se muestra además la aplicabilidad del modelo para el modelado sustituto (*surrogate modeling*) impulsado por datos en aplicaciones de simulación multifísica.

Port-Hamiltonian Neural Networks with Output Error Noise Models

Fecha: 20 de febrero de 2025 (Preprint arXiv v1; enviado a *Automatica*)

Citación: Moradi, S., Beintema, G. I., Jaensson, N., Tóth, R., & Schoukens, M. (2025). Port-Hamiltonian Neural Networks with Output Error Noise Models. Preprint submitted to *Automatica*. arXiv preprint arXiv:2502.14432.

Área de aplicación: Identificación de Sistemas de Ingeniería con Ruido de Medición

Resumen:

Las redes neuronales hamiltonianas (HNN) representan una clase prometedora de métodos de aprendizaje profundo informados por la física que utilizan la teoría hamiltoniana como conocimiento fundacional dentro de las redes neuronales. Sin embargo, su aplicación directa a sistemas de ingeniería suele verse limitada por cuestiones prácticas, incluyendo la presencia de entradas externas, la disipación y las mediciones ruidosas. Este artículo introduce un marco que amplía las capacidades de las HNN para abordar estos factores, integrando la teoría port-hamiltoniana en la estructura de la red —lo que permite incluir entradas externas y disipación— mientras se mitiga el impacto del ruido de medición mediante una estructura de modelo de error de salida (output-error, OE). Las redes resultantes (OE-pHNN) pueden adaptarse para modelar sistemas de ingeniería complejos con mediciones ruidosas. Además, los autores proponen identificar las OE-pHNN basándose en el enfoque SUBNET (subspace encoder), que aproxima de forma eficiente la pérdida de simulación completa utilizando subsecciones de los datos y una función codificadora para predecir los estados iniciales, logrando modelos consistentes bajo mediciones ruidosas y realizando un análisis de consistencia para garantizar la fiabilidad del método.

3. Extensiones Arquitectónicas

Frequency-Separable Hamiltonian Neural Network for Multi-Timescale Dynamics

Fecha: 15 de marzo de 2026 (Preprint arXiv v2)

Citación: Li, Y., Yang, Y., & Allen-Blanchette, C. (2026). Frequency-Separable Hamiltonian Neural Network for Multi-Timescale Dynamics. arXiv preprint arXiv:2603.06354.

Área de aplicación: Extensión Arquitectónica (Dinámica Multiescala)

Resumen:

Aunque la mecánica hamiltoniana proporciona un sesgo inductivo poderoso para las redes neuronales que modelan sistemas dinámicos, las HNN y sus variantes a menudo fallan al capturar dinámicas temporales complejas que abarcan múltiples escalas temporales, limitación vinculada al sesgo espectral de las redes profundas, que favorecen aprender dinámicas de baja frecuencia y variación lenta. Los enfoques previos han intentado abordar este problema mediante esquemas de integración simpléctica o restricciones geométricas, pero son limitados en su capacidad de capturar completamente dinámicas multiescala. En este trabajo, los autores explotan la observación de que las funciones hamiltonianas admiten descomposiciones en modos rápidos y lentos explícitos, y pueden reconstruirse a partir de estos componentes. Se introduce la Frequency-Separable Hamiltonian Neural Network (FS-HNN), que parametriza el hamiltoniano del sistema utilizando múltiples redes, cada una gobernada por dinámica hamiltoniana y entrenada con datos muestreados en escalas temporales distintas. El marco se extiende además a ecuaciones en derivadas parciales aprendiendo operadores simplécticos condicionados por el estado y la frontera, mejorando el rendimiento de extrapolación a largo horizonte y generalizando a un amplio rango de problemas de EDO y EDP.

Kolmogorov–Arnold Representation for Symplectic Learning: Advancing Hamiltonian Neural Networks

Fecha: 26 de agosto de 2025 (Preprint arXiv v1; aceptado en IJCNN 2025)

Citación: Wu, Z., Xu, R., Chen, L., Kementzidis, G., Wang, S., & Deng, Y. (2025). Kolmogorov–Arnold Representation for Symplectic Learning: Advancing Hamiltonian Neural Networks. *IEEE International Joint Conference on Neural Networks (IJCNN 2025)*. arXiv preprint arXiv:2508.19410.

Área de aplicación: Extensión Arquitectónica (Kolmogorov-Arnold + HNN)

Resumen:

Las HNN garantizan la conservación de energía al aprender funciones hamiltonianas H_θ cuyas derivadas parciales generan dinámica que conserva la energía. Típicamente, H_θ se modela mediante perceptrones multicapa (MLP), que requieren un ajuste de hiperparámetros considerable para capturar características complejas o localizadas del paisaje energético, lo que puede dificultar la interpretabilidad y, si los parámetros no se optimizan con cuidado, reducir la precisión en horizontes temporales largos. Inspirándose en las Kolmogorov-Arnold Networks (KAN), que descomponen una función n -variada en sumas y composiciones de transformaciones univariadas, los autores proponen la Kolmogorov-Arnold Representation-based Hamiltonian Neural Network (KAR-HNN), que reemplaza el MLP de las HNN con una representación de Kolmogorov-Arnold. A diferencia de los MLP, las KAN forman una arquitectura localizada capaz de capturar más efectivamente características de alta frecuencia u oscilatorias, produciendo campos de gradiente más suaves. Tras evaluar KAR-

HNN en cuatro problemas de referencia —masa-resorte, péndulo simple, y problema de dos y tres cuerpos—, los autores anticipan su eficacia para el modelado preciso y estable de procesos físicos realistas de alta dimensionalidad y con pocos parámetros conocidos.

Parametric Generalized Hamiltonian Neural Networks

Fecha: Preprint (SSRN)

Citación: Horn, P., & Koren, B. (2026). Parametric Generalized Hamiltonian Neural Networks. Preprint (SSRN).

Área de aplicación: Extensión Arquitectónica (Sistemas Paramétricos)

Resumen:

Se han desarrollado múltiples enfoques de redes neuronales preservadoras de estructura para sistemas hamiltonianos, pero ninguna de estas arquitecturas se había introducido específicamente para sistemas hamiltonianos dependientes de parámetros: en los enfoques existentes, los parámetros del sistema quedan siempre fijos y definidos a través de los datos, de modo que ante cualquier cambio de parámetro es necesario crear un nuevo conjunto de datos y entrenar una nueva red desde cero. Una red preservadora de estructura embebe una restricción previamente conocida directamente en la topología de la red; en contraste con las redes informadas por la física, en las que la restricción se añade como un término extra en la función de pérdida, la estructura embebida implica un cambio en el espacio de hipótesis, lo que potencialmente mejora la generalización con muchos menos parámetros entrenables. Los autores presentan las Parametric Generalized Hamiltonian Neural Networks, capaces de aprender un mapa de flujo dependiente de parámetros mientras preservan la estructura simpléctica, eliminando la necesidad de reentrenar una red para cada valor del parámetro. Se prueba un teorema de aproximación universal, y una comparación frente a MLP no conscientes de la física muestra que las nuevas redes logran extrapolar a regiones del espacio de fases sin datos de entrenamiento, con un orden de magnitud menos de parámetros.

Separable Hamiltonian Neural Networks

Fecha: 15 de agosto de 2024 (Preprint arXiv v4)

Citación: Khoo, Z.-Y., Wu, D., Choong Low, J. S., & Bressan, S. (2024). Separable Hamiltonian Neural Networks. arXiv preprint arXiv:2309.01069.

Área de aplicación: Extensión Arquitectónica (Separabilidad Aditiva)

Resumen:

Modelar sistemas dinámicos constituye un reto central para la ciencia y la ingeniería, y las HNN son modelos del estado del arte que regresan el campo vectorial de un sistema dinámico bajo el sesgo de aprendizaje de las ecuaciones de Hamilton. Una observación reciente en la literatura es que embeber un sesgo relativo a la separabilidad aditiva del hamiltoniano — $H(q, p) = T(p) + V(q)$ — reduce la complejidad de la regresión y mejora el rendimiento predictivo. Motivados por esto, los autores proponen las *separable HNN*, que embeben la separabilidad aditiva mediante tres modos de sesgo: un sesgo observacional (entrenando con datos generados que incorporan la separabilidad), un sesgo de aprendizaje (embebido en la función de pérdida) y un sesgo inductivo (mediante MLP conjugados dentro de la propia HNN). Los resultados muestran que las separable HNN presentan un

alto rendimiento al regresar hamiltonianos y campos vectoriales aditivamente separables, superando a su contraparte no informada por la física; los autores comparan también su desempeño frente a la HNN base en un sistema caótico (Hénon-Heiles) y en un sistema de alta dimensionalidad. El código está disponible públicamente en GitHub.

Simplifying Hamiltonian and Lagrangian Neural Networks via Explicit Constraints

Fecha: 26 de octubre de 2020 (Preprint arXiv v1; NeurIPS 2020)

Citación: Finzi, M., Wang, K. A., & Wilson, A. G. (2020). Simplifying Hamiltonian and Lagrangian Neural Networks via Explicit Constraints. *Advances in Neural Information Processing Systems (NeurIPS 2020)*. arXiv preprint arXiv:2010.13581.

Área de aplicación: Extensión Arquitectónica (Sistemas de Coordenadas y Restricciones)

Resumen:

Razonar sobre el mundo físico requiere modelos dotados del sesgo inductivo adecuado para aprender la dinámica subyacente. Trabajos recientes mejoran la generalización en la predicción de trayectorias aprendiendo el hamiltoniano o el lagrangiano de un sistema en lugar de las ecuaciones diferenciales directamente. Sin embargo, mientras que estos métodos codifican las restricciones de los sistemas usando coordenadas generalizadas (por ejemplo, ángulos), los autores muestran que embeber el sistema en coordenadas cartesianas e imponer las restricciones explícitamente mediante multiplicadores de Lagrange simplifica drásticamente el problema de aprendizaje. Los autores introducen una serie de sistemas caóticos y de cuerpo extendido desafiantes —N péndulos, acoplamiento por resortes, campos magnéticos, rotores rígidos y giroscopios— para llevar al límite los enfoques actuales. Sus experimentos muestran que las coordenadas cartesianas con restricciones explícitas (CHNN/CLNN) conducen a una mejora de hasta 100 veces en precisión y eficiencia de datos frente a Neural ODEs y HNN estándar; en el giroscopio, el modelo llega a ser 260 veces más preciso, ya que el hamiltoniano en coordenadas cartesianas resulta más simple de aprender que en coordenadas angulares.

4. Dinámica No Lineal y Caos

Extrapolating the emergence of Hamiltonian chaos with random-feature Hamiltonian neural networks

Fecha: 31 de julio de 2026 (Preprint arXiv v1)

Citación: Choi, J. (2026). Extrapolating the emergence of Hamiltonian chaos with random-feature Hamiltonian neural networks. arXiv preprint arXiv:2607.28977.

Área de aplicación: Dinámica No Lineal y Caos Hamiltoniano

Resumen:

El aprendizaje automático de la dinámica hamiltoniana ha impulsado un interés creciente en las HNN, que codifican las ecuaciones de movimiento de Hamilton dentro de la arquitectura de aprendizaje. Pese a este progreso, se desconoce si dichas redes pueden predecir regímenes dinámicos ausentes en sus datos de entrenamiento, en particular el amplio mar caótico que emerge más allá del intervalo de parámetros observado. El autor aborda esta cuestión mediante una red neuronal

hamiltoniana de características aleatorias consciente del parámetro (RF-HNN). Entrenada únicamente con datos de un pequeño número de valores del parámetro de control en los que predominan toros invariantes, la RF-HNN predice de forma autónoma la dinámica de largo plazo en valores no vistos, donde se desarrolla un espacio de fases mixto y las regiones caóticas se expanden, sin usar datos de ese régimen. El método se demuestra en cuatro familias de sistemas hamiltonianos de dos grados de libertad, incluyendo el sistema de Hénon-Heiles. Mediante geometría de secciones de Poincaré y exponentes de Lyapunov de tiempo finito, se muestra que la RF-HNN reproduce la ruptura de estructuras regulares y la aparición de regiones caóticas, mientras que las HNN convencionales permanecen demasiado regulares; los resultados sugieren que lo determinante no es la estructura hamiltoniana por sí sola, sino cómo continúa el hamiltoniano ajustado en el parámetro de control.

5. Aplicaciones Físicas Reproducibles

Hamiltonian-based Neural ODE Networks on the $SE(3)$ Manifold For Dynamics Learning and Control

Fecha: 25 de noviembre de 2021 (Preprint arXiv v3; RSS 2021)

Citación: Duong, T., & Atanasov, N. (2021). Hamiltonian-based Neural ODE Networks on the $SE(3)$ Manifold For Dynamics Learning and Control. *Robotics: Science and Systems (RSS 2021)*. arXiv preprint arXiv:2106.12782.

Área de aplicación: Robótica (Dinámica de Cuerpo Rígido y Control $SE(3)$)

Resumen:

Disponer de modelos precisos de la dinámica de un robot es crítico para un control seguro y estable y para la generalización a condiciones operativas nuevas; sin embargo, los modelos diseñados manualmente pueden resultar insuficientemente precisos incluso tras un ajuste cuidadoso. Esto motiva el uso de técnicas de aprendizaje automático para aproximar la dinámica del robot a partir de trayectorias de estado y control. La dinámica de muchos robots —terrestres, aéreos y submarinos— se describe en términos de su pose y velocidad generalizada sobre la variedad $SE(3)$, y satisface principios de conservación de energía. Este artículo propone una formulación hamiltoniana sobre la estructura $SE(3)$ de una red neuronal de ecuación diferencial ordinaria, para aproximar la dinámica de un cuerpo rígido, garantizando la conservación total de energía por construcción. Los autores desarrollan control de moldeado de energía e inyección de amortiguamiento para la dinámica hamiltoniana $SE(3)$ aprendida, permitiendo un enfoque unificado para la estabilización y el seguimiento de trayectorias en péndulo, cuerpo rígido y cuadrotor. El código, los vídeos y el material suplementario están disponibles públicamente.

Learning Articulated Rigid Body Dynamics with Lagrangian Graph Neural Network

Fecha: 11 de noviembre de 2022 (Preprint arXiv v2; NeurIPS 2022)

Citación: Bhattoo, R., Ranu, S., & Krishnan, N. M. A. (2022). Learning Articulated Rigid Body Dynamics with Lagrangian Graph Neural Network. *Advances in Neural Information Processing Systems (NeurIPS 2022)*. arXiv preprint arXiv:2209.11588.

Área de aplicación: Robótica y Mecánica Estructural (Cuerpos Rígidos Articulados)

Resumen:

Las redes neuronales lagrangianas y hamiltonianas (LNN y HNN) codifican sesgos inductivos fuertes que les permiten superar significativamente a otros modelos de sistemas físicos. Sin embargo, hasta ahora estos modelos se habían limitado mayormente a sistemas simples, como péndulos y resortes, o a un único cuerpo rígido. Los autores presentan una red neuronal de grafos lagrangiana (LGNN) capaz de aprender la dinámica de cuerpos rígidos articulados explotando su topología, demostrando su rendimiento al aprender la dinámica de cuerdas, cadenas y armaduras (*trusses*) con las barras modeladas como cuerpos rígidos. La LGNN exhibe además capacidad de generalización: entrenada con cadenas de pocos segmentos, es capaz de simular cadenas con un número mucho mayor de eslabones y de longitud arbitraria, e incluso simular sistemas híbridos no vistos que combinan barras y cadenas. Los autores muestran que la LGNN puede emplearse para modelar la dinámica de estructuras reales complejas, como la estabilidad de estructuras de tensegridad, y discuten la naturaleza no diagonal de la matriz de masa. El código está disponible públicamente en GitHub.

Neural Symplectic Integrator with Hamiltonian Inductive Bias for the Gravitational N -body Problem

Fecha: 28 de noviembre de 2021 (Preprint arXiv v1; NeurIPS 2021 Workshop)

Citación: Cai, M. X., Portegies Zwart, S., & Podareanu, D. (2021). Neural Symplectic Integrator with Hamiltonian Inductive Bias for the Gravitational N -body Problem. *Fourth Workshop on Machine Learning and the Physical Sciences (NeurIPS 2021)*. arXiv preprint arXiv:2111.15631.

Área de aplicación: Astrofísica Computacional (Problema Gravitacional de N Cuerpos)

Resumen:

El problema gravitacional de N cuerpos, de importancia fundamental en astrofísica para predecir el movimiento de N cuerpos celestes bajo su gravedad mutua, se resuelve habitualmente de forma numérica, ya que no existe una solución analítica general para $N > 2$. Los autores se preguntan si el problema puede resolverse con precisión mediante una red neuronal, y si dicha red puede observar conservación de energía y momento angular orbital a largo plazo. Inspirándose en el mapa simpléctico de Wisdom y Holman, presentan un integrador neuronal simpléctico de N cuerpos que divide el hamiltoniano en una parte de dos cuerpos, resoluble analíticamente, y una parte de interacción que se aproxima mediante una red neuronal. Su código simpléctico neuronal integra un sistema general de tres cuerpos durante 10^5 pasos sin desviarse de la dinámica de referencia obtenida con un integrador tradicional de N cuerpos, y exhibe buen sesgo inductivo al predecir con éxito la evolución de sistemas de N cuerpos que no formaban parte del conjunto de entrenamiento.

Hamiltonian Dynamics Learning from Point Cloud Observations for Nonholonomic Mobile Robot Control

Fecha: 12 de marzo de 2024 (Preprint arXiv v2)

Citación: Altawaitan, A., Stanley, J., Ghosal, S., Duong, T., & Atanasov, N. (2024). Hamiltonian Dynamics Learning from Point Cloud Observations for Nonholonomic Mobile Robot Control. arXiv preprint arXiv:2309.09163.

Área de aplicación: Robótica Móvil (Control a partir de Nubes de Puntos)

Resumen:

La navegación autónoma fiable requiere adaptar la política de control de un robot móvil en respuesta a cambios de dinámica bajo distintas condiciones operativas. Los modelos de dinámica diseñados manualmente pueden tener dificultades para capturar variaciones con un conjunto limitado de parámetros, mientras que los enfoques basados en datos ofrecen mayor capacidad de modelado pero requieren grandes cantidades de datos etiquetados con el estado. Este trabajo desarrolla un enfoque para aprender la dinámica de un robot directamente a partir de observaciones de nubes de puntos (*point clouds*), eliminando la necesidad y los errores de la estimación de estado, al tiempo que se embebe estructura hamiltoniana en el modelo para mejorar la eficiencia de datos. Los autores diseñan una función de pérdida en el espacio de observación que relaciona la predicción de movimiento del modelo con la predicción obtenida mediante registro de nubes de puntos, para entrenar una ecuación diferencial ordinaria neuronal hamiltoniana. El modelo aprendido permite el diseño de un controlador de seguimiento de trayectoria basado en modelo con moldeado de energía, demostrado sobre un robot con ruedas no holonómico real (un robot Clearpath Jackal equipado con LiDAR), constituyendo un ejemplo validado experimentalmente sobre hardware físico, más allá de la simulación.

6. Explicabilidad e Interpretabilidad

Discovering Symbolic Laws Directly from Trajectories with Hamiltonian Graph Neural Networks

Fecha: 11 de julio de 2023 (Preprint arXiv v1)

Citación: Bishnoi, S., Bhattoo, R., Jayadeva, Ranu, S., & Krishnan, N. M. A. (2023). Discovering Symbolic Laws Directly from Trajectories with Hamiltonian Graph Neural Networks. arXiv preprint arXiv:2307.05299.

Área de aplicación: Explicabilidad (Regresión Simbólica sobre Redes de Grafos Hamiltonianas)

Resumen:

La evolución temporal de los sistemas físicos se describe mediante ecuaciones diferenciales que dependen de cantidades abstractas como la energía y la fuerza; estas cantidades se derivan habitualmente como funcionales a partir de observables como posiciones y velocidades, y descubrir estas leyes simbólicas subyacentes es clave para comprender las interacciones en la naturaleza. Los autores presentan una red neuronal de grafos hamiltoniana (HGNN), una GNN reforzada por la física que aprende la dinámica de los sistemas directamente a partir de su trayectoria, demostrando su rendimiento sobre sistemas de n resortes, n péndulos, sistemas gravitacionales y sistemas binarios de Lennard-Jones, con excelente concordancia respecto a la referencia usando pocos datos. Los autores evalúan además la capacidad de la HGNN de generalizar a tamaños de sistema mayores y a un sistema híbrido resorte-péndulo. Finalmente, empleando regresión simbólica sobre la HGNN entrenada, infieren las ecuaciones subyacentes que relacionan los funcionales de energía, incluso para sistemas complejos como el líquido binario de Lennard-Jones, facilitando el descubrimiento interpretable de leyes de interacción directamente a partir de trayectorias de sistemas físicos.

H-FEX: A Symbolic Learning Method for Hamiltonian Systems

Fecha: 25 de junio de 2025 (Preprint arXiv v1)

Citación: Lai, J., Liang, S., & Wang, C. (2025). H-FEX: A Symbolic Learning Method for Hamiltonian Systems. arXiv preprint arXiv:2506.20607.

Área de aplicación: Explicabilidad (Método de Expresión Finita para Sistemas Hamiltonianos)

Resumen:

Los sistemas hamiltonianos describen una amplia clase de sistemas dinámicos gobernados por funciones hamiltonianas, que codifican la energía total y dictan la evolución del sistema. Los enfoques basados en datos, como la regresión simbólica y los métodos basados en redes neuronales, ofrecen un medio para aprender las ecuaciones que gobiernan estos sistemas directamente a partir de datos observacionales, pero a menudo tienen dificultades para capturar con precisión funciones hamiltonianas complejas preservando al mismo tiempo la conservación de energía. Para superar esta limitación, los autores proponen el Finite Expression Method for learning Hamiltonian Systems (H-FEX), un método de aprendizaje simbólico que introduce nodos de interacción novedosos diseñados para capturar términos de interacción intrincados de forma efectiva. Sus experimentos, incluyendo pruebas sobre sistemas dinámicos altamente rígidos, demuestran que H-FEX puede recuperar funciones hamiltonianas de sistemas complejos que capturan con precisión la dinámica del sistema y preservan la energía durante horizontes temporales largos, destacando su potencial como marco para descubrir expresiones de forma cerrada de sistemas dinámicos complejos.

Discovery of Symbolic Hamiltonian Expressions with Buckingham-Symplectic Networks

Fecha: 1 de abril de 2026 (Preprint arXiv v1)

Citación: Germany, J., Bakarji, J., & Najem, S. (2026). Discovery of Symbolic Hamiltonian Expressions with Buckingham-Symplectic Networks. arXiv preprint arXiv:2604.00576.

Área de aplicación: Explicabilidad (Análisis Dimensional + Redes Simpléticas)

Resumen:

Los autores presentan las Buckingham-Symplectic Networks, un marco para el descubrimiento de expresiones hamiltonianas simbólicas que combina el análisis dimensional del teorema Pi de Buckingham con redes neuronales de estructura simpléctica. La motivación central es que, si bien los métodos de regresión simbólica y las redes hamiltonianas aprenden representaciones de la dinámica a partir de datos, rara vez garantizan que las expresiones descubiertas sean dimensionalmente consistentes ni que se reduzcan de forma natural a un número mínimo de grupos adimensionales independientes, lo que dificulta tanto su interpretabilidad física como su capacidad de generalizar entre configuraciones físicas de distinta escala. Al imponer explícitamente la estructura simpléctica junto con restricciones de análisis dimensional, el marco propuesto reduce el espacio de búsqueda de expresiones candidatas y favorece el descubrimiento de leyes hamiltonianas más compactas, físicamente consistentes y generalizables entre distintas escalas del sistema, aportando una vía adicional para la extracción de conocimiento científico interpretable a partir de modelos aprendidos.

Identifying Physical Law of Hamiltonian Systems via Meta-Learning

Fecha: 23 de febrero de 2021 (Preprint arXiv v1; ICLR 2021)

Citación: Lee, S., Yang, H., & Seong, W. (2021). Identifying Physical Law of Hamiltonian Systems via Meta-Learning. *International Conference on Learning Representations (ICLR 2021)*. arXiv preprint arXiv:2102.11544.

Área de aplicación: Explicabilidad y Generalización (Meta-Aprendizaje de Leyes Físicas)

Resumen:

La mecánica hamiltoniana es una herramienta eficaz para representar muchos procesos físicos mediante expresiones matemáticas concisas y bien generalizadas. Un hamiltoniano bien modelado facilita a los investigadores analizar y predecir fenómenos relacionados gobernados por la misma ley física; sin embargo, identificar una expresión funcional compartida del hamiltoniano es en general muy difícil, y requiere experimentos cuidadosamente diseñados y la intuición del investigador. Los autores proponen que los algoritmos de meta-aprendizaje pueden ser herramientas potentes basadas en datos para identificar la ley física que gobierna sistemas hamiltonianos, sin ningún supuesto matemático sobre su representación, pero con observaciones de un conjunto de sistemas gobernados por la misma ley. Muestran que un meta-aprendiz bien entrenado puede identificar la representación compartida del hamiltoniano —por ejemplo, la expresión $H = p^2/(2ml^2) + mgl(1 - \cos q)$ del péndulo ideal— evaluando el método sobre varios tipos de sistemas físicos con diversas configuraciones experimentales. Una vez establecido un hamiltoniano apropiado a partir de la observación de varios péndulos, un nuevo sistema similar puede reconocerse fácilmente adaptando nuevos parámetros físicos sobre la expresión compartida.

7. Evaluación y Comparativas

A matched-integrator evaluation of Hamiltonian neural networks on pendulum and Kepler dynamics

Fecha: 10 de agosto de 2026 (Preprint arXiv v1)

Citación: Kemunto, N. L., Gaba, Y. U., & Tewe, B. (2026). A matched-integrator evaluation of Hamiltonian neural networks on pendulum and Kepler dynamics. arXiv preprint arXiv:2608.10235.

Área de aplicación: Evaluación y Comparativas (Protocolo de Integrador Equiparado)

Resumen:

Las HNN parametrizan la dinámica conservativa mediante un hamiltoniano escalar aprendido, proporcionando un prior arquitectónico ausente en las redes neuronales de campo vectorial genéricas. Los autores evalúan este prior bajo un protocolo controlado en el que una HNN y una red *feedforward* base con el mismo número de parámetros se entrenan sobre las mismas trayectorias generadas con RK4, usan los mismos objetivos de derivada por diferencias centrales y los mismos ajustes de optimización, y se integran en inferencia con el mismo esquema RK4, reportando resultados sobre cinco semillas independientes. En el péndulo no lineal, la HNN reduce la deriva media de energía en un factor de 42 y el error cuadrático medio de trayectoria en un factor de 15,8 en $T = 100$ (aproximadamente 16 periodos), con menor variabilidad entre semillas; la diferencia es más pronunciada en regiones más no lineales del espacio de fases. Como diagnóstico adicional, examinan un *rollout* explícito estilo Störmer-Verlet de la HNN aprendida, observando que la garantía estándar de simplecticidad de *velocity Verlet* no aplica directamente al no ser el hamiltoniano separable. El mismo protocolo se aplica al problema de Kepler tridimensional de dos cuerpos, donde la HNN

exhibe de nuevo menor deriva de trayectoria, energía y momento angular que la línea base, aportando un estudio controlado sobre cómo la parametrización hamiltoniana afecta a la predicción a largo horizonte.

Deconstructing the Inductive Biases of Hamiltonian Neural Networks

Fecha: 12 de febrero de 2022 (Preprint arXiv v2; ICLR 2022)

Citación: Gruver, N., Finzi, M., Stanton, S., & Wilson, A. G. (2022). Deconstructing the Inductive Biases of Hamiltonian Neural Networks. *International Conference on Learning Representations (ICLR 2022)*. arXiv preprint arXiv:2202.04836.

Área de aplicación: Evaluación y Comparativas (Análisis de Sesgos Inductivos)

Resumen:

Las redes neuronales inspiradas en la física, como las hamiltonianas o lagrangianas, superan de forma notable a otros modelos de dinámica aprendidos al aprovechar sesgos inductivos fuertes. Sin embargo, estos modelos son difíciles de aplicar a muchos sistemas del mundo real, como aquellos que no conservan energía o que contienen contactos, un escenario habitual en robótica y aprendizaje por refuerzo. Los autores examinan los sesgos inductivos que hacen exitosos en la práctica a los modelos inspirados en la física, mostrando que, contrariamente a la sabiduría convencional, la mejor generalización de las HNN es resultado de modelar directamente la aceleración y de evitar complejidad artificial proveniente del sistema de coordenadas, más que de la estructura simpléctica o la conservación de energía en sí mismas. Relajando los sesgos inductivos de estos modelos, los autores logran igualar o superar el rendimiento en sistemas que conservan energía, mejorando drásticamente el rendimiento en sistemas prácticos no conservativos, y extienden este enfoque a modelos de transición para entornos comunes de MuJoCo. Este trabajo es una referencia crítica que cuestiona qué componentes de las HNN son realmente responsables de su buen desempeño.

8. Optimización Inspirada en Dinámica Hamiltoniana

Fusion of ECA-Net with Hamiltonian Deep Neural Networks and Dynamic Step Size Optimization

Fecha: 2025 (Publicado en ICIC 2025, CCIS 2568)

Citación: Liang, Y., Bai, S., & Zhang, Z. (2025). Fusion of ECA-Net with Hamiltonian Deep Neural Networks and Dynamic Step Size Optimization. *Intelligent Computing (ICIC 2025)*, CCIS 2568, 39-50. https://doi.org/10.1007/978-981-96-9955-1_4

Área de aplicación: Optimización de Redes Profundas Inspirada en Dinámica Hamiltoniana (Visión por Computador)

Resumen:

Las Hamiltonian Deep Neural Networks (H-DNN) son una arquitectura de red neuronal innovadora que integra los principios de conservación de energía y estabilidad del gradiente propios de la mecánica hamiltoniana, abordando de forma efectiva los problemas de desvanecimiento del gradiente e interpretabilidad habituales en los métodos de aprendizaje profundo tradicionales. A diferencia de las HNN aplicadas a la modelización de sistemas físicos, aquí la dinámica hamiltoniana se emplea como principio de diseño para la propia arquitectura de red profunda —de forma análoga a una red residual estabilizada—, con el objetivo de mejorar la estabilidad del entrenamiento y la

generalización en tareas de aprendizaje profundo genéricas. Este estudio valida empíricamente la efectividad de las H-DNN en tareas complejas de reconocimiento de imágenes. Sin embargo, las H-DNN emplean un paso temporal fijo, lo que presenta limitaciones al manejar datos complejos. Para abordar esto, se propone AdaHamil-ECA, arquitectura que introduce un mecanismo de paso temporal adaptativo según la complejidad de los datos, combinado con el módulo Efficient Channel Attention (ECA-Net) que realza los canales de características más relevantes. Los resultados muestran que AdaHamil-ECA supera a las H-DNN tradicionales en un 2,7-3 % de precisión en tareas complejas de clasificación de imágenes, acelerando además la convergencia y mejorando la robustez.

9. Catálogo de Implementaciones Open-Source

A continuación se recopilan las implementaciones de código abierto localizadas para las arquitecturas de la familia HNN cubiertas en este documento. El catálogo documenta el ecosistema de software disponible (framework, autoría, alcance) como paso previo a una eventual integración en un entorno de evaluación unificado; por el momento constituye una revisión bibliográfica de las implementaciones existentes, sin ejecución de código.

Hamiltonian Neural Networks (Greydanus et al., 2019) <https://github.com/greydanus/hamiltonian-nn> — PyTorch. Implementación de referencia de los autores originales; incluye los experimentos de masa-resorte, péndulo (a partir de píxeles) y problema de dos cuerpos del paper fundacional. Repositorio ligero, ampliamente citado como punto de partida didáctico.

Symplectic ODE-Net (Zhong et al., 2020) <https://github.com/d-biswa/Symplectic-ODENet> — PyTorch. Código y modelos preentrenados de los autores para los experimentos con control (péndulo actuado, carro-péndulo) del paper de ICLR 2020.

Lagrangian Neural Networks (Cranmer et al., 2020) https://github.com/MilesCranmer/lagrangian_nns — JAX. Implementación oficial; incluye notebooks de tutorial y del péndulo doble. Referencia habitual para comparar HNN frente a LNN.

Hamiltonian Generative Networks (Toth et al., 2020) https://github.com/google-deepmind/dm_hamiltonian_dynamics_suite (suite de datos oficial de DeepMind) y <https://github.com/CampusAI/Hamiltonian-Generative-Networks> (reimplementación comunitaria en PyTorch, dado que los autores no publicaron código de entrenamiento). Útil para el caso de aprendizaje de dinámica hamiltoniana desde imágenes.

SympNets (Jin et al., 2020) <https://github.com/bentaps/strupnet> — PyTorch. Reimplementación comunitaria mantenida que incluye SympNets y variantes adicionales (P-, R- y GR-SympNets); no se localizó repositorio oficial de los autores originales.

Simplifying Hamiltonian/Lagrangian NN via Explicit Constraints (Finzi et al., 2020) <https://github.com/mfinzi/constrained-hamiltonian-neural-networks> — PyTorch. Implementación oficial (CHNN/CLNN) con los sistemas caóticos y de cuerpo extendido (giroscopio, rotores) del paper.

Deconstructing the Inductive Biases of HNN (Gruver et al., 2022) <https://github.com/ngruver/decon-hnn> — PyTorch. Código oficial de los experimentos comparativos, incluyendo los entornos de MuJoCo.

Separable Hamiltonian Neural Networks (Khoo et al., 2024) <https://github.com/zykhoo/SeparableNNs> — PyTorch. Implementación oficial de los tres modos de sesgo de separabilidad

aditiva propuestos por los autores.

Learning Articulated Rigid Body Dynamics con LGNN (Bhattoo et al., 2022) https://github.com/M3RG-IITD/rigid_body_dynamics_graph — JAX. Código oficial; incluye los experimentos de cadenas, cerchas y estructuras de tensegridad.

Hamiltonian Neural ODE en SE(3) (Duong & Atanasov, 2021) <https://thaipduong.github.io/SE3HamDL/> — PyTorch. Material suplementario oficial de los autores (código, vídeos) para péndulo, cuerpo rígido y cuadrotor.

Port-Hamiltonian Approach to Neural Network Training (Zymrael) <https://github.com/Zymrael/PortHamiltonianNN> — PyTorch. Implementación de referencia general de redes neuronales port-hamiltonianas, útil como base para las variantes de la sección 2.

Port-Hamiltonian Neural Networks — TensorFlow (esclear) <https://github.com/esclear/ph-nn> — TensorFlow. Alternativa en TensorFlow al ecosistema predominantemente PyTorch/JAX de las PHNN.

Stable Port-Hamiltonian Neural Networks (Roth et al., 2025) <https://github.com/CPSHub/sphnn-publication> — Código y datos experimentales de referencia del paper, incluyendo los casos de modelado sustituto multifísico.

Hamiltonian Deep Neural Networks — arquitectura base (DecodeEPFL) <https://github.com/DecodeEPFL/HamiltonianNet> — PyTorch. Implementación de referencia de las H-DNN como principio de diseño de redes profundas estables, base conceptual del paper de fusión con ECA-Net (sección 8).

Symplectic Learning for HNN (SpaceAbleOrg) <https://github.com/SpaceAbleOrg/symplectic-hnn> — PyTorch. Código de entrenamiento y evaluación, conjuntos de datos sintéticos y modelos preentrenados.

Order-Chaos HNN (anshu957) <https://github.com/anshu957/OrderChaosHNN> — Implementación de HNN aplicada al sistema de Hénon-Heiles para el estudio de la mezcla de dinámica regular y caótica, directamente relevante para la sección 4 de este documento.

Observación metodológica. La mayoría de estas implementaciones son independientes entre sí (distintos frameworks, formatos de datos y convenciones de coordenadas), por lo que integrarlas en un framework de evaluación unificado —con benchmarks compartidos como el péndulo, el problema de Kepler y el sistema de Hénon-Heiles— constituye una tarea de ingeniería propia, no cubierta en la presente revisión bibliográfica.

10. Lista de Ejemplos y Sistemas Físicos de Referencia

Esta sección recopila los sistemas físicos y bancos de pruebas (*benchmarks*) empleados en la literatura revisada, indicando qué papers de este documento los utilizan. Sirve como mapa de referencia cruzada para identificar, dado un sistema de interés, qué arquitecturas y trabajos lo han abordado.

Masa-resorte / oscilador armónico Greydanus et al. (HNN, 1.1); Linares et al. (oscilación controlada port-H, 2.2, como caso base); Wu et al. (KAR-HNN, 3.2).

Péndulo simple / no lineal Greydanus et al. (1.1, a partir de píxeles); Jin et al. (SympNets, 1.4); Horn et al. (GHNN, 1.6); Wu et al. (KAR-HNN, 3.2); Khoo et al. (Separable HNN, 3.4); Lee et al. (meta-aprendizaje, 6.4); Kemunto et al. (evaluación matched-integrator, 7.1).

Péndulo doble Cranmer et al. (LNN, 1.3); Jin et al. (SympNets, 1.4); Horn et al. (GHNN, 1.6); Gruver et al. (deconstrucción de sesgos, 7.2).

Péndulo plano y torsional (control) Kamboj et al. (co-aprendizaje port-H y control, 2.1).

Problema de Kepler / dos cuerpos Greydanus et al. (1.1); Toth et al. (HGN, 1.5, a partir de píxeles); Kemunto et al. (7.1).

Problema de tres cuerpos / N cuerpos gravitacional Jin et al. (SympNets, 1.4); Horn et al. (GHNN, 1.6); Wu et al. (KAR-HNN, 3.2); Cai et al. (integrador simpléctico neuronal, 5.3); Bishnoi et al. (HGNN simbólica, 6.1).

Oscilador de Duffing Linares et al. (2.2).

Oscilador autosostenido (ciclo límite) Linares et al. (2.2).

Cuerpo rígido / giroscopio / rotor rígido Finzi et al. (restricciones explícitas, 3.5); Duong & Atanasov (SE(3), 5.1).

Cuerpos rígidos articulados (cadenas, cerchas, tensegridad) Bhattoo et al. (LGNN, 5.2).

Cuadro rotor y vehículos sobre la variedad SE(3) Duong & Atanasov (5.1).

Robot móvil no holonómico (hardware real, LiDAR) Altawaitan et al. (5.4).

Cuerda no lineal (EDP, acústica musical) Linares et al. (dinámica de cuerdas, 2.3).

Masa-resorte-amortiguador encadenado van Otterdijk et al. (inicialización mejorada, 2.4).

Sistema de Hénon-Heiles (caos) Choi (RF-HNN, 4.1); Khoo et al. (Separable HNN, 3.4, comparación); Horn et al. (GHNN, 1.6, vía HénonNets).

Sistemas de n resortes / n péndulos Bishnoi et al. (6.1).

Líquido binario de Lennard-Jones Bishnoi et al. (6.1).

Sistemas de identificación de ingeniería con ruido (bancos genéricos) Moradi et al. (2.7); Roth et al. (2.6, modelado sustituto multifísico).

Vídeo / imagen (dinámica de píxeles) Toth et al. (HGN, 1.5).

Reconocimiento de imágenes (aplicación no física) Liang et al. (fusión ECA-Net + H-DNN, 8.1).