

Estado del Arte: Kolmogorov-Arnold Networks (KAN)

Ricardo Luis Urretxo Riofrancos

23 de agosto de 2026

Índice

1. Finanzas y Series Temporales	1
2. Ciencia, Energía Nuclear y Química	11
3. Medicina y Análisis de Supervivencia	23
4. Meteorología, Medio Ambiente y Agricultura	26
5. Otras Aplicaciones y Teoría	32

Introducción

Este documento presenta una revisión del estado del arte de las redes KAN clasificadas por su área de aplicación.

1. Finanzas y Series Temporales

Temporal Kolmogorov-Arnold Networks (T-KAN) for High-Frequency Limit Order Book Forecasting: Efficiency, Interpretability, and Alpha Decay

Fecha: 5 de enero de 2026 (Preprint arXiv:2601.02310v1)

Citación: Makinde, A. (2026). Temporal Kolmogorov-Arnold Networks (T-KAN) for High-Frequency Limit Order Book Forecasting: Efficiency, Interpretability, and Alpha Decay. *arXiv preprint arXiv:2601.02310*.

Área de aplicación: Finanzas (Trading de Alta Frecuencia / Series Temporales)

Resumen:

En los entornos de trading de alta frecuencia (HFT), los datos de los libros de órdenes limitadas (LOB) se caracterizan por ser masivos, ruidosos y altamente no lineales. Un desafío importante en este ámbito es el decaimiento del alfa (*alpha decay*), donde los modelos tradicionales de aprendizaje profundo, como DeepLOB, pierden rápidamente

su poder predictivo a medida que aumenta el horizonte temporal, en parte porque las arquitecturas LSTM estándar dependen de funciones de activación estáticas que no logran capturar las oscilaciones localizadas del mercado.

Para resolver este problema, el autor propone la arquitectura Temporal Kolmogorov-Arnold Networks (T-KAN), un modelo que sustituye los pesos lineales y fijos de las redes LSTM convencionales por funciones de activación B-spline que pueden ser aprendidas durante el entrenamiento. Basado en el teorema de representación de Kolmogorov-Arnold, este enfoque permite que la red neuronal realice cálculos en los bordes", aprendiendo no solo la magnitud de las señales financieras, sino la forma exacta de la distribución de los datos.

El desarrollo del modelo implica la creación de una célula híbrida T-KAN (KAN-LSTM) donde las funciones lineales de las puertas de memoria y olvido del LSTM tradicional se transforman en mapeos funcionales basados en splines. Utilizando el conjunto de datos de referencia FI-2010 y aplicando penalizaciones para mantener la suavidad de las curvas, el modelo logra mapear eficazmente las dependencias de alta frecuencia y manejar las dinámicas no lineales complejas del mercado.

Como conclusión, el modelo T-KAN demostró un rendimiento predictivo superior, logrando una mejora relativa del 19,1 % en el F1-score para un horizonte de 100 pasos en comparación con la línea base de DeepLOB. Además, resultó ser un modelo altamente interpretable al hacer visibles las "zonas muertas" del mercado en los splines aprendidos y demostró una rentabilidad sobresaliente, generando un retorno del 132,48 % frente a las considerables pérdidas del modelo tradicional bajo costos de transacción simulados.

KOLMOGOROV-ARNOLD NETWORKS FOR TIME SERIES: BRIDGING PREDICTIVE POWER AND INTERPRETABILITY

Fecha: 4 de junio de 2024 (Preprint arXiv:2406.02496v1)

Citación: Xu, K., Chen, L., & Wang, S. (2024). Kolmogorov-Arnold Networks for Time Series: Bridging Predictive Power and Interpretability. *arXiv preprint arXiv:2406.02496*.

Área de aplicación: Series Temporales (Finanzas y Analítica Predictiva)

Resumen:

La predicción de series temporales es una tarea crítica en múltiples disciplinas, pero los modelos de aprendizaje profundo predominantes basados en perceptrones multicapa (MLP) adolecen de una grave falta de interpretabilidad y sufren leyes de escalamiento deficientes. Este carácter de caja negra resulta especialmente problemático en sectores de alto riesgo, como los mercados financieros o la meteorología, donde los expertos necesitan comprender las dinámicas subyacentes y detectar eficazmente la deriva de conceptos (*concept drift*) ante cambios en el entorno.

Para superar estas limitaciones, los autores exploran la aplicación de las redes de Kolmogorov-Arnold (KAN) a las series temporales, proponiendo dos arquitecturas novedosas: T-KAN (Temporal KAN) y MT-KAN (Multivariate Temporal KAN). A diferencia de los MLP tradicionales, estas redes sustituyen los pesos lineales por funciones univariadas parametrizadas por splines en las conexiones entre nodos, lo que permite que los patrones de

activación se aprendan y adapten dinámicamente a la estructura de la serie temporal.

El modelo T-KAN se diseña específicamente para series univariadas y se centra en detectar la deriva de conceptos; al observar las variaciones en las funciones de activación aprendidas en diferentes ventanas de tiempo, puede identificar cambios de régimen. Además, emplea regresión simbólica para traducir las activaciones no lineales en ecuaciones legibles por humanos. Por su parte, MT-KAN extiende este enfoque a entornos multivariados, apilando pasos históricos a través de capas KAN para descubrir y modelar las interdependencias complejas entre distintas variables.

Las conclusiones del estudio revelan que tanto T-KAN como MT-KAN superan significativamente a los métodos tradicionales basados en MLP en tareas de predicción de series temporales financieras. Resulta fantástico ver cómo con apenas 2 capas y 5 neuronas ocultas, estos modelos no solo igualan o mejoran la precisión predictiva de redes mucho más grandes, sino que ofrecen una transparencia algorítmica y una interpretabilidad sin precedentes en este campo.

Intelligent Stock Price Prediction Model Research Integrating Multimodal Information and KAN Networks

Fecha: 2026 (Aceptado en diciembre de 2025, publicado en *Computational Economics*)

Citación: Sun, W., Yuan, C., You, S., Liu, Z., Chen, Y., & Cui, W. (2026). Intelligent Stock Price Prediction Model Research Integrating Multimodal Information and KAN Networks. *Computational Economics*.

Área de aplicación: Finanzas (Predicción del Precio de Acciones)

Resumen:

La predicción de los precios de las acciones representa un desafío central en la ingeniería financiera. Los métodos tradicionales a menudo dependen de fuentes de datos únicas y tienen dificultades para capturar las complejas dinámicas del mercado. Además, los modelos existentes generalmente carecen de interpretabilidad, lo que dificulta que los inversores y las instituciones reguladoras comprendan la base lógica de las predicciones en entornos de alto riesgo.

Para abordar estos problemas, los autores proponen un modelo inteligente de predicción que integra información multimodal y redes KAN. El marco construye un sistema de fusión de características basado en mecanismos de atención, incorporando datos históricos de precios, textos de noticias y el sentimiento de las redes sociales. El modelo utiliza arquitecturas LSTM para las características numéricas temporales, modelos BERT para la extracción de información semántica textual y atención multicabezal para realizar la fusión inteligente de dichos datos.

Como gran innovación, el estudio introduce las redes KAN como capa de salida para tareas de predicción de precios de acciones por primera vez. Al utilizar su diseño único de función de activación en las conexiones (bordes), la red logra una capacidad de ajuste no lineal más fuerte y una transparencia superior en comparación con los perceptrones multicapa tradicionales.

Basándose en datos empíricos de NVIDIA Corporation entre 2020 y 2025, los experimen-

tos demostraron que el modelo propuesto logra mejoras significativas sobre la línea base Informer, incluyendo una reducción del 33,2 % en el RMSE y una mejora del 4,4 % en R^2 . Asimismo, el análisis de visualización demostró la excelente interpretabilidad del modelo, confirmando su capacidad para identificar eventos clave del mercado.

Short-term Passenger Flow Prediction of Urban Rail Transit Based on LSTM-KAN-Stacking Combination Model

Fecha: 2025 (Publicado en *Highlights in Science, Engineering and Technology*)

Citación: Du, Y., & Ha, J. (2025). Short-term Passenger Flow Prediction of Urban Rail Transit Based on LSTM-KAN-Stacking Combination Model. *Highlights in Science, Engineering and Technology*, 158, 68-75.

Área de aplicación: Transporte y Series Temporales (Flujo de Pasajeros)

Resumen:

La predicción del flujo de pasajeros a corto plazo en el transporte ferroviario urbano es crucial para la gestión y el servicio inteligente. Sin embargo, a medida que disminuye la granularidad temporal de las mediciones, la complejidad y la incertidumbre de los datos aumentan drásticamente, lo que provoca una caída en la precisión predictiva que los modelos existentes tienen dificultades para mitigar.

Para resolver esto, los autores introducen la red KAN en la predicción del flujo de pasajeros y proponen un modelo combinado denominado LSTM-KAN-Stacking. En primer lugar, la red KAN se integra en la estructura LSTM funcionando como una capa completamente conectada; de este modo, los datos de la secuencia ingresan a la red KAN inmediatamente después de que el LSTM extrae las características temporales, mejorando la capacidad del sistema para asimilar patrones complejos.

En segundo lugar, este modelo de aprendizaje profundo se combina con un algoritmo de aprendizaje integrado (Stacking). Los valores de salida predichos por la arquitectura LSTM-KAN se apilan y añaden a los datos de la serie temporal original como nuevas características, proporcionando una entrada de información mucho más rica y refinada para el metamodelo final.

Evaluated with real data of the passenger flow of the Hangzhou Metro, the model reduced the MAE by at least 0.5%, 2.4% and 5.6% in comparison with the base models on data sets with granularities of 15, 30 and 60 minutes, respectively. The goodness of fit generally reached 0.973, which demonstrates that the KAN network has a great practical potential for short-term prediction with high stability.

CasMST-KAN: a cascade prediction model with multi-scale temporal convolution and Kolmogorov–Arnold networks

Fecha: 9 de febrero de 2026 (Publicado en *International Journal of Machine Learning and Cybernetics*)

Citación: Dan, X., Zhang, Z., Tian, Y., & Chen, D. (2026). CasMST-KAN: a cascade pre-

diction model with multi-scale temporal convolution and Kolmogorov–Arnold networks. *International Journal of Machine Learning and Cybernetics*, 17, 221.

Área de aplicación: Series Temporales (Predicción de difusión de información)

Resumen:

Predecir las cascadas de difusión de información en redes sociales es un problema fundamental para proyectar el alcance de tendencias, pero los métodos existentes tienen grandes dificultades para manejar la compleja dinámica de propagación. Específicamente, los modelos tradicionales basados en redes neuronales recurrentes (como LSTM o GRU) fracasan al intentar modelar simultáneamente los patrones temporales a múltiples escalas y las interacciones altamente no lineales que ocurren entre los nodos de usuarios.

Para resolver esta deficiencia de modelado, los investigadores proponen una arquitectura de aprendizaje profundo híbrida llamada CasMST-KAN. En primer lugar, el modelo utiliza una rama de procesamiento temporal que combina redes de memoria a corto y largo plazo (LSTM) con convoluciones temporales de múltiples escalas (MSTC). El módulo MSTC emplea convoluciones dilatadas paralelas con distintos campos receptivos para capturar las fluctuaciones a diferentes resoluciones temporales, mientras que la capa LSTM extrae las dependencias secuenciales a largo plazo.

En segundo lugar, una rama paralela extrae características estructurales utilizando redes de atención de grafos (GAT) potenciadas por un mecanismo de atención lineal multiescala basado en funciones ReLU. Las representaciones extraídas de ambas ramas se fusionan y se introducen en una red de Kolmogorov-Arnold (KAN). Al sustituir los perceptrones multicapa (MLP) tradicionales por las funciones base B-spline aprendibles de KAN en las conexiones, el modelo logra una capacidad expresiva superior para mapear las relaciones complejas y de alta dimensionalidad que rigen la difusión de la información.

Los experimentos exhaustivos demostraron que la integración de la convolución multiescala, el modelado secuencial y la aproximación no lineal de KAN permite a CasMST-KAN superar significativamente a los métodos del estado del arte. El modelo destacó particularmente en la predicción de cascadas a largo plazo, demostrando que la red KAN es una herramienta excepcionalmente robusta y eficiente para capturar las dependencias estructurales profundas en el análisis de redes temporales.

KANformer: A Flexible Kolmogorov-Arnold Transformer For Power Load Forecasting

Fecha: Septiembre de 2025 (Publicado en *Journal of Applied Science and Engineering* en 2026)

Citación: Yu, Y., Yang, Z., Lin, S., & Zhang, Y. (2026). KANformer: A Flexible Kolmogorov-Arnold Transformer For Power Load Forecasting. *Journal of Applied Science and Engineering*, 31, 26031043.

Área de aplicación: Series Temporales (Predicción de Carga Eléctrica)

Resumen:

La predicción precisa de la carga eléctrica es fundamental para la planificación y el funcionamiento de la red, pero los modelos de aprendizaje profundo actuales basados en

perceptrones multicapa (MLP) presentan dos graves problemas de diseño. En primer lugar, operan como cajas negras opacas, lo que impide a los operadores de la red comprender el razonamiento de la red neuronal. En segundo lugar, utilizan un paradigma de generación de un solo paso con cabezas de predicción rígidas, lo que ignora las dependencias temporales y requiere reentrenar el modelo por completo si se desea cambiar el horizonte de predicción.

Para resolver estas deficiencias, los autores proponen KANformer, una arquitectura que integra redes de Kolmogorov-Arnold (KAN) dentro de un marco Transformer. En lugar de utilizar activaciones fijas en los nodos como los MLP, las capas *feed-forward* del KANformer emplean funciones univariantes parametrizadas por B-splines en las conexiones. Esta innovación estructural permite una extracción de características altamente adaptativa para patrones de carga complejos (como los efectos de los días festivos) y proporciona una interpretabilidad visual directa de las relaciones aprendidas.

A nivel operativo, el modelo transforma la predicción en una tarea de modelado de lenguaje. Utiliza técnicas de parcheo (*patching*) con normalización de instancias inversa para mitigar el ruido y los cambios de distribución de los datos, y emplea un esquema de inferencia autorregresiva a nivel de parche. Además, incorpora un mecanismo de aprendizaje residual adaptativo que refina de manera iterativa los patrones ocultos extraídos por los bloques del Transformer a lo largo del proceso de predicción.

Evaluado en dos conjuntos de datos reales (Electricity y StateGridLoad), KANformer superó a siete modelos del estado del arte (incluyendo PatchTFS y DFM) disminuyendo notablemente los errores MSE y MAE. Los estudios de ablación confirmaron que la arquitectura óptima de 4 bloques proporciona el equilibrio perfecto entre complejidad y precisión, confirmando al modelo como una herramienta sumamente flexible y transparente para la gestión de redes eléctricas.

Data Elements from Raw Data: A KAN-T-GCN Model for Traffic Speed Prediction

Fecha: Enero de 2025 (Publicado en *China Communications* en Noviembre de 2025)

Citación: Zhao, Y., Peng, J., & Tao, X. (2025). Data elements from raw data: A kan-t-gcn model for traffic speed prediction. *China Communications*, 22(11), 208-222.

Área de aplicación: Series Temporales y Transporte (Predicción de Velocidad del Tráfico)

Resumen:

Transformar datos brutos en elementos de datos interpretables es un desafío crítico en el procesamiento de información moderna, particularmente en la gestión dinámica del tráfico. La predicción precisa de la velocidad del tráfico requiere modelar tanto las complejas dependencias topológicas espaciales de las carreteras como la evolución temporal del flujo, algo en lo que fallan los métodos estadísticos clásicos (como ARIMA) por su incapacidad para manejar no linealidades, y las Redes Convolucionales de Grafos (GCN) estándar por carecer de memoria temporal.

Para construir representaciones precisas y extraíbles, los autores desarrollan el modelo

KAN-T-GCN, que fusiona las Redes de Kolmogorov-Arnold (KAN) con una Red Convolutiva de Grafos Temporal (T-GCN). El núcleo del sistema utiliza una GCN modificada con tecnología KAN para extraer las características espaciales de la red de carreteras; al reemplazar las matrices de pesos lineales por funciones de activación basadas en splines cúbicos a lo largo de las aristas, el modelo captura de forma eficiente interacciones espaciales complejas con menos parámetros y mayor explicabilidad.

Posteriormente, las características espaciales refinadas se introducen en una Unidad Recurrente Gated (GRU) diseñada para capturar las dependencias temporales y mitigar el problema del gradiente desvaneciente. Como innovación final en el formato de salida, la tradicional capa completamente conectada del GRU se sustituye por una capa KAN adicional, la cual ajusta de forma no lineal las características temporales extraídas para emitir la predicción final de la velocidad del tráfico.

Los experimentos exhaustivos con conjuntos de datos de Shenzhen, Los Ángeles y la Bahía de San Francisco demostraron que el KAN-T-GCN supera con creces a los modelos de referencia (GCN, T-GCN y ST-GCN), logrando las tasas más bajas de Error Cuadrático Medio (MSE) y Error Porcentual Absoluto Medio (MAPE), así como los valores R^2 más altos. Estas métricas prueban que la sustitución de neuronas tradicionales por unidades KAN mejora dramáticamente el modelado espaciotemporal complejo, generando elementos de datos dinámicos y rigurosos.

Self-adaptive evolutionary neural networks for high-precision short-term electric load forecasting

Fecha: 2026 (Publicado en *Scientific Reports*)

Citación: Abbas, M., Che, Y., Maqsood, S., et al. (2026). Self-adaptive evolutionary neural networks for high-precision short-term electric load forecasting. *Scientific Reports*.

Área de aplicación: Series Temporales (Predicción de Carga Eléctrica a Corto Plazo)

Resumen:

La predicción precisa de la carga eléctrica a corto plazo (STLF) es un componente vital para garantizar la estabilidad de la red y optimizar la distribución de energía. Los enfoques de pronóstico convencionales, incluyendo los perceptrones multicapa (MLP) estándar y los modelos estadísticos, presentan graves limitaciones a la hora de modelar las variaciones de carga altamente complejas y no lineales, fracasando a menudo al intentar equilibrar la precisión predictiva con la eficiencia computacional exigida en entornos de operación en tiempo real.

Para mitigar este cuello de botella algorítmico, los autores desarrollan el marco SADE-KAN (Self-Adaptive Differential Evolution Kolmogorov-Arnold Network). Esta topología descarta las funciones de activación estáticas presentes en los nodos de los MLP, sustituyéndolas por funciones base aprendibles apoyadas en splines a lo largo de las conexiones del grafo. Esta reestructuración funcional confiere a la red una flexibilidad sin precedentes para capturar dependencias temporales intrincadas y ciclos de carga anómalos.

El principal desafío matemático de esta arquitectura radica en la explosión del espacio de hiperparámetros, dado que cada función univariable en los bordes requiere una configu-

ración óptima. El modelo integra un algoritmo de Evolución Diferencial Auto-Adaptativa (SADE) que ajusta dinámicamente estos parámetros durante la fase de entrenamiento. Este mecanismo evolutivo equilibra la exploración estocástica y la explotación del gradiente, asegurando que la red escape de mínimos locales subóptimos sin incurrir en costes computacionales prohibitivos.

Las pruebas empíricas demuestran que SADE-KAN supera sistemáticamente a las líneas base tradicionales en la predicción a corto plazo. La sinergia entre la aproximación funcional continua de KAN y la optimización de hiperparámetros de SADE produce un error de predicción marginal, confirmando al modelo como una solución altamente escalable y robusta para la gestión dinámica de redes eléctricas modernas.

STF-DKANMixer: Tri-component decomposition with KAN-MLP hybrid architecture for time series forecasting

Fecha: 8 de diciembre de 2025 (Publicado en *PLOS One*)

Citación: Wei, J., Guo, R., & Wang, Y. (2025). STF-DKANMixer: Tri-component decomposition with KAN-MLP hybrid architecture for time series forecasting. *PLoS ONE*, 20(12), e0337793.

Área de aplicación: Series Temporales (Predicción a Largo Plazo)

Resumen:

La predicción de series temporales a largo plazo en dominios dinámicos, como el tráfico vehicular y el consumo energético, es sumamente compleja debido al entrelazamiento de tendencias subyacentes, estacionalidades múltiples y ruido estocástico. Los enfoques de modelado directo a menudo no logran desenredar estas señales superpuestas, lo que provoca que las redes neuronales profundas (como los Transformers puros o los MLP densos) memoricen patrones espurios y generalicen de forma deficiente en horizontes temporales extendidos.

Para resolver la opacidad y la interferencia de señales, la investigación propone STF-DKANMixer, una arquitectura híbrida fundamentada en un paradigma de descomposición matemática tri-componente. El modelo segmenta explícitamente la serie temporal entrante en tres sub-señales ortogonales: una componente de tendencia a baja frecuencia, una componente estacional cíclica y un residuo de alta frecuencia que contiene las fluctuaciones estocásticas.

A nivel de procesamiento, el sistema asigna topologías neuronales específicas a cada componente. Las tendencias lineales simples son procesadas mediante bloques MLP convencionales para maximizar la velocidad de cálculo. Sin embargo, las componentes estacionales y residuales, que albergan la mayor densidad de dinámicas no lineales, son canalizadas a través de redes de Kolmogorov-Arnold. Las transformaciones univariantes aprendibles en las aristas de la red KAN permiten modelar estas oscilaciones complejas con una precisión matemática que una capa densa no puede alcanzar sin sobreajustarse.

La validación del modelo híbrido STF-DKANMixer evidencia una mejora sustancial en las métricas de error (MSE y MAE) frente a modelos del estado del arte. Al delegar la aproximación de funciones altamente irregulares a las capas KAN y reservar los MLP

para proyecciones lineales, la arquitectura no solo incrementa la precisión predictiva a largo plazo, sino que otorga una interpretabilidad algorítmica vital para analizar qué factores (tendencia o ruido) están impulsando las anomalías en los datos.

TKANMiXer: Multi-scale hybrid KAN for long-term forecasting

Fecha: Diciembre de 2025 (Aceptado en *Soft Computing*)

Citación: Kong, Y., Zhao, H., Zheng, H., & Lu, X. (2026). TKANMiXer: multi-scale hybrid KAN for long-term forecasting. *Soft Computing*.

Área de aplicación: Series Temporales (Pronóstico Multiescala)

Resumen:

La inclusión de variables exógenas (como factores climáticos en la previsión de demanda energética) en el modelado de series temporales mejora teóricamente el rendimiento predictivo, pero incrementa dramáticamente la complejidad topológica del sistema. Los modelos actuales luchan por fusionar estos flujos de información heterogéneos, y las arquitecturas MLP tradicionales fracasan matemáticamente al intentar construir representaciones de características jerárquicas que capturen las interacciones de los datos a múltiples resoluciones temporales (escalas).

Para abordar esta insuficiencia arquitectónica, se presenta el marco TKANMiXer, una topología híbrida multiescala diseñada para la fusión de variables y la descomposición temporal. El modelo integra un módulo de descomposición de tendencia y estacionalidad que opera simultáneamente con el algoritmo de fusión de covariables exógenas, desenredando las señales subyacentes antes de someterlas a transformaciones no lineales profundas.

El núcleo computacional del sistema sustituye los bloques de mezcla convencionales por una arquitectura KAN multicapa de diseño jerárquico. En este espacio, las funciones de B-splines ubicadas en los bordes de la red aprenden a mapear las correlaciones cruzadas entre las variables exógenas y la serie temporal principal en diferentes frecuencias de muestreo. Esta capacidad de ajustar la forma funcional de manera individual para cada variable permite al modelo extraer dependencias temporales de largo alcance sin colapsar el espacio de características.

Las pruebas experimentales concluyen que TKANMiXer supera con éxito las limitaciones impuestas por el ruido de las variables externas y la complejidad multiescala. El uso de las redes KAN en un entorno jerárquico no solo aumenta significativamente la precisión frente a métodos MLP equivalentes, sino que aporta una transparencia estructural que permite identificar qué escala temporal y qué variable externa concreta dominan el vector de predicción final.

KAN+Transformer: An Explainable and Efficient Approach for Electric Load Forecasting

Fecha: 6 de febrero de 2026 (Publicado en *Sustainability*)

Citación: Ma, L., Guo, C., Wang, Y., Zhang, Y., & Zhang, B. (2026). KAN+Transformer:

An Explainable and Efficient Approach for Electric Load Forecasting. *Sustainability*, 18(3).

Área de aplicación: Series Temporales (Gestión de Redes Inteligentes / Smart Grids)

Resumen:

El pronóstico de carga residencial a corto plazo (STRLF) constituye el núcleo operativo de las redes eléctricas inteligentes modernas. Sin embargo, los perfiles de consumo residencial están plagados de alta volatilidad y fluctuaciones ruidosas dependientes del comportamiento humano. Aunque los modelos basados en Transformers han demostrado una capacidad excepcional para modelar estas secuencias gracias a su mecanismo de atención, su naturaleza inherente de caja negra representa un obstáculo regulatorio insalvable para los operadores de la red, que exigen explicabilidad total en las decisiones de despacho.

Para unificar la potencia predictiva con la transparencia matemática, los investigadores proponen la topología KAN+Transformer. Esta arquitectura retiene el mecanismo de auto-atención multicabeza del Transformer original, garantizando la extracción óptima de dependencias temporales globales a lo largo de toda la secuencia de carga. La innovación disruptiva radica en la sustitución integral de las redes *feed-forward* densas (FFN) por capas de redes de Kolmogorov-Arnold.

Al integrar los módulos KAN, el modelo procesa los tensores de contexto extraídos por la atención mediante mapeos funcionales univariantes en los bordes de la red. En lugar de proyectar los datos en subespacios inescrutables mediante multiplicaciones matriciales opacas, los B-splines aprendibles construyen una representación explícita y algebraica de las variaciones de carga. Esta aproximación permite trazar exactamente cómo las características de entrada han sido transformadas no linealmente para alcanzar el valor de salida.

El despliegue empírico de KAN+Transformer demuestra que es posible alcanzar métricas de error (RMSE y MAPE) equiparables o superiores a los modelos profundos de última generación, al mismo tiempo que se proporciona un marco analítico completamente explicable. Esta combinación asegura que las infraestructuras de medición avanzada puedan predecir la demanda de manera eficiente, ofreciendo simultáneamente a los ingenieros la capacidad de auditar la lógica interna del sistema predictivo.

2. Ciencia, Energía Nuclear y Química

Opening the Black-Box: Symbolic Regression with Kolmogorov-Arnold Networks for Energy Applications

Fecha: 8 de abril de 2025 (Preprint)

Citación: Panczyk, N. R., Erdem, O. F., & Radaideh, M. I. (2025). Opening the Black-Box: Symbolic Regression with Kolmogorov-Arnold Networks for Energy Applications. *Preprint submitted to Elsevier*.

Área de aplicación: Energía Nuclear (Regresión Simbólica y Machine Learning Interpretable)

Resumen:

La mayoría de los métodos modernos de aprendizaje automático ofrecen gran velocidad y precisión, pero carecen de interpretabilidad y explicabilidad. Este problema de caja negra.^{es} una barrera crítica en industrias altamente sensibles donde la seguridad pública está en juego, como la energía nuclear. Agencias reguladoras, como la Comisión Reguladora Nuclear de EE. UU. (NRC), exigen cada vez más que los operadores puedan comprender y justificar las decisiones de los sistemas de inteligencia artificial, algo casi imposible con los algoritmos tradicionales basados en redes neuronales prealimentadas (FNN).

Para satisfacer esta necesidad de transparencia, los autores proponen el uso de redes de Kolmogorov-Arnold (KAN). A diferencia de los perceptrones multicapa (MLP) tradicionales que aplican funciones de activación estáticas en los nodos, las redes KAN colocan funciones de activación basadas en B-splines en los bordes (conexiones) de la red. Esta arquitectura única permite que la red se transforme en expresiones matemáticas simbólicas tras el entrenamiento, haciendo que el modelo sea transparente y comprensible para un ser humano.

El estudio compara el rendimiento de las FNN tradicionales y las KAN utilizando ocho conjuntos de datos representativos de la industria de la energía nuclear, como la predicción del flujo de calor crítico. La evaluación no solo abarca la precisión predictiva, sino que también somete a los modelos a un análisis *post-hoc* de explicabilidad utilizando Kernel SHAP, con el objetivo de verificar si las redes realmente están aprendiendo las reglas físicas del sistema o si simplemente están ajustando estadísticas ciegas.

Las conclusiones indican que las redes KAN y FNN ofrecen una precisión comparable cuando la dimensionalidad de salida es limitada. Sin embargo, la ventaja decisiva radica en que las KAN generan modelos perfectamente interpretables al derivar ecuaciones simbólicas, mientras que las FNN siguen siendo cajas negras. Además, el análisis SHAP demostró que las redes KAN aprenden relaciones físicas reales a partir de los datos experimentales, posicionándolas como una alternativa inmensamente superior para aplicaciones de ingeniería de alto riesgo.

Cheby-KANs: Advanced Kolmogorov-Arnold Networks for Applying Geometric Deep Learning in Quantum Chemistry Applications

Fecha: 2 de mayo de 2025

Citación: Mahmoud, A. A., Pester, A., Muttardi, M. M., Andres, F., Tanabe, S., Grenèche, N., & Ali, H. H. (2025). Cheby-KANs: Advanced Kolmogorov-Arnold Networks for Applying Geometric Deep Learning in Quantum Chemistry Applications. *IEEE Access*, 13, 130525-130534.

Área de aplicación: Química Cuántica y Deep Learning Geométrico

Resumen:

En el ámbito de la química cuántica, el modelado exige una precisión extremadamente alta, ya que las tasas de error se acumulan de forma exponencial al tratar con funciones multivariadas complejas. Si bien las redes neuronales tradicionales (MLP) adolecen de falta de expresividad e interpretabilidad, las recientes redes KAN basadas en B-splines presentan un grave inconveniente: un coste computacional masivo. Al aplicarlas a conjuntos de datos moleculares como QM9, los tiempos de entrenamiento pueden prolongarse durante meses en un superordenador debido a la necesidad de calcular cuadrículas predefinidas y a la inestabilidad de los gradientes.

Para solucionar este cuello de botella, los autores desarrollan una versión mejorada denominada Cheby-KAN, la cual sustituye los B-splines de los bordes de la red por polinomios de Chebyshev de primera clase desplazados. Esta modificación matemática aprovecha la ortogonalidad y la rápida convergencia de los polinomios de Chebyshev para minimizar el fenómeno de Runge (oscilaciones en los bordes) y reducir drásticamente el número de parámetros necesarios por capa, eliminando la dependencia de la actualización de la cuadrícula durante el entrenamiento.

El estudio pone a prueba la arquitectura integrándola como núcleo de un modelo de aprendizaje profundo geométrico (SchNet), creando el sistema Cheby-KAN-SchNet. Los autores entrenan este modelo para predecir seis propiedades cuánticas diferentes de moléculas del conjunto QM9, comparando su rendimiento frente al modelo SchNet original (basado en MLP) y a una variante KAN-SchNet que utiliza los B-splines convencionales.

Los resultados demostraron que el modelo Cheby-KAN-SchNet no solo superó a la versión con B-splines y al MLP en términos de precisión (reduciendo las pérdidas de Error Medio Absoluto), sino que logró ser unas 14 veces más rápido que la red KAN original. Esto confirma que los polinomios de Chebyshev ofrecen una aproximación global mucho más estable y eficiente, permitiendo llevar la interpretabilidad y potencia de las redes KAN a dominios científicos complejos sin el enorme coste de tiempo asociado.

KAN 2.0: Kolmogorov-Arnold Networks Meet Science

Fecha: 19 de agosto de 2024 (Preprint arXiv:2408.10205v1)

Citación: Liu, Z., Ma, P., Wang, Y., Matusik, W., & Tegmark, M. (2024). KAN 2.0: Kolmogorov-Arnold Networks Meet Science. *arXiv preprint arXiv:2408.10205*.

Área de aplicación: Ciencia y Física Computacional

Resumen:

Un gran desafío en la intersección entre la inteligencia artificial y la ciencia es su incompatibilidad inherente: la IA actual se basa en el conexionismo (cajas negras), mientras que la ciencia requiere simbolismo (ecuaciones interpretables). Las arquitecturas estándar no ofrecen un mecanismo transparente para el descubrimiento científico, lo que limita su utilidad para extraer nuevas leyes físicas o matemáticas a partir de datos empíricos.

Para tender un puente entre ambos mundos, los autores presentan un marco bidireccional que integra las redes KAN con el conocimiento científico. Por un lado, se incorpora el conocimiento previo en la red; por otro, se utilizan las KAN para identificar características relevantes, revelar estructuras modulares en los datos y descubrir fórmulas matemáticas. Una innovación clave en esta versión (KAN 2.0) es la introducción de MultKAN, que añade nodos de multiplicación para capturar interacciones no lineales más complejas.

El proceso se basa en la capacidad intrínseca de las KAN para descomponer funciones de alta dimensionalidad en componentes unidimensionales. Mediante regresión simbólica, estas funciones 1D aprendidas en los bordes de la red se traducen directamente a expresiones algebraicas legibles, permitiendo que el modelo pase de ser un aproximador numérico a un generador de hipótesis científicas.

El estudio demuestra empíricamente que este enfoque permite a la red descubrir de forma autónoma varios tipos de leyes físicas a partir de datos, incluyendo cantidades conservadas, Lagrangianos, simetrías ocultas y leyes constitutivas. Esto consolida a las redes KAN como una herramienta colaborativa fundamental para el descubrimiento científico impulsado por datos.

Interpretable Machine Learning Regression for Nuclear Applications with Kolmogorov-Arnold Networks (KAN)

Fecha: Abril de 2025 (Conferencia M&C 2025)

Citación: Erdem, O. F., Panczyk, N. R., & Radaideh, M. I. (2025). Interpretable Machine Learning Regression for Nuclear Applications with Kolmogorov-Arnold Networks (KAN). *Proceedings of the International Conference on Mathematics and Computational Methods Applied to Nuclear Science and Engineering (M&C 2025)*, 804-813.

Área de aplicación: Energía Nuclear

Resumen:

En el sector de la energía nuclear, la adopción de algoritmos de inteligencia artificial está severamente limitada por la necesidad estricta de interpretabilidad. Tareas críticas de regresión, como la predicción de temperaturas del combustible o el flujo de calor, no pueden depender de redes neuronales prealimentadas (FNN) tradicionales, ya que su naturaleza opaca impide que los ingenieros y reguladores validen la física subyacente de las predicciones.

Para superar esta barrera, el estudio evalúa la viabilidad de utilizar redes KAN como sustitutas de las FNN en problemas de regresión dentro del dominio nuclear. En lugar de utilizar funciones de activación estáticas en los nodos, las redes KAN parametrizan funciones B-spline en las conexiones, lo que permite mapear explícitamente las relaciones entre las variables de entrada (parámetros del reactor) y las variables de salida (métricas de seguridad o rendimiento).

Los autores entrenan y comparan arquitecturas KAN y FNN utilizando conjuntos de datos representativos de simulaciones y operaciones nucleares. El enfoque se centra no solo en minimizar el error de regresión, sino en la capacidad de extraer ecuaciones analíticas directamente de la red entrenada, verificando si el modelo captura correctamente la termodinámica y la neutróica del sistema.

Los resultados indican que las redes KAN logran una precisión predictiva totalmente competitiva con los modelos de aprendizaje profundo tradicionales, pero con la ventaja insuperable de ser inherentemente interpretables. Esta capacidad de transformar el modelo entrenado en expresiones algebraicas validables facilita su posible futura certificación para aplicaciones de seguridad en centrales nucleares.

Nuclear-Charge-Guided Mamba with KAN Dynamic Mixture for Molecular Property Prediction

Fecha: Diciembre de 2025 (Preprint)

Citación: Wang, H., et al. (2025). Nuclear-Charge-Guided Mamba with KAN Dynamic Mixture for Molecular Property Prediction. *Research Square*.

Área de aplicación: Química Cuántica y Predicción de Propiedades Moleculares

Resumen:

La predicción precisa de propiedades moleculares es un pilar fundamental en el diseño de nuevos fármacos y materiales. Tradicionalmente, este campo ha estado dominado por las Redes Neuronales de Grafos (GNN), las cuales sufren de un campo receptivo limitado que les impide capturar adecuadamente las dependencias a largo plazo entre átomos distantes dentro de una misma molécula compleja.

Para resolver esta deficiencia, los autores proponen la arquitectura KAN-NC-Mamba, un modelo híbrido innovador. En primer lugar, introducen un módulo Mamba guiado por la carga nuclear (Z), que ordena los átomos de la molécula según su número atómico. Esta secuencia se procesa mediante modelos de espacio de estados (SSM) de escaneo selectivo, lo que permite modelar las dependencias globales a largo plazo con una complejidad computacional estrictamente lineal.

En segundo lugar, para integrar la información y capturar la alta no linealidad de las interacciones cuánticas, el sistema incorpora un módulo denominado "KAN Dynamic Mixture". Este componente utiliza splines de Kolmogorov-Arnold para generar fusiones de características a nivel de nodo de manera dinámica, combinando las representaciones locales y globales extraídas por el módulo Mamba con una flexibilidad muy superior a la de los perceptrones multicapa clásicos.

Evaluado en diez conjuntos de datos de referencia que abarcan propiedades fisicoquímicas y de bioactividad, el modelo KAN-NC-Mamba estableció un nuevo estado del arte en nueve de ellos. Además de su rendimiento superior, el uso de las redes KAN proporcionó representaciones químicas altamente interpretables, validando la solidez del enfoque geométrico y físico del modelo.

Uncertainty quantification for scientific machine learning using sparse variational Gaussian process Kolmogorov-Arnold networks (SVGP KAN)

Fecha: 2026 (Publicado en *Machine Learning: Science and Technology*)

Citación: Ju, Y. S. (2026). Uncertainty quantification for scientific machine learning using sparse variational Gaussian process Kolmogorov-Arnold networks (SVGP KAN). *Machine Learning: Science and Technology*.

Área de aplicación: Machine Learning Científico (Cuantificación de Incertidumbre)

Resumen:

La cuantificación de la incertidumbre es un requisito fundamental en el aprendizaje automático aplicado a la ciencia, especialmente en sectores críticos como la medicina y la ingeniería aeroespacial. Los modelos tradicionales basados en perceptrones multicapa (MLP) carecen de mecanismos fiables para proporcionar estimaciones tratables de incertidumbre epistémica y aleatoria. Por otro lado, los Procesos Gaussianos (GP) convencionales, aunque ofrecen un marco probabilístico sólido, sufren de una escalabilidad computacional severa ($O(N^3)$) que limita su aplicación a conjuntos de datos masivos y entradas de alta dimensionalidad.

Para resolver este problema, el autor propone la arquitectura SVGP KAN. Este modelo altera la formulación estándar de las redes de Kolmogorov-Arnold (KAN) al eliminar los B-splines deterministas de las conexiones. En su lugar, parametriza cada función univariada en los bordes de la red como un Proceso Gaussiano disperso y variacional. Esta modificación matemática infunde a la red una interpretación probabilística intrínseca, permitiendo que las distribuciones posteriores marginales cuantifiquen de manera natural la incertidumbre de las predicciones en cada capa.

Para garantizar la viabilidad computacional de la inferencia Bayesiana, el modelo se apoya en un marco variacional empleando puntos inductores (*inducing points*), lo que reduce drásticamente la carga computacional de la covarianza exacta a $O(NM^2)$, donde $M \ll N$. La eficacia de esta arquitectura se evalúa en tres escenarios de prueba: la aproximación de una función sintética no lineal, el modelado de ecuaciones de transporte de advección-difusión y un problema de detección de anomalías espaciales sometido a ruido estocástico.

En conclusión, el marco SVGP KAN demuestra ser sumamente efectivo para proporcionar una cuantificación de incertidumbre precisa sin sacrificar la expresividad estructural aditiva de las redes KAN. El modelo logra distinguir con éxito entre la incertidumbre aleatoria (ruido inherente a los datos) y la epistémica (incertidumbre del modelo en regiones fuera de la distribución), consolidándose como un enfoque escalable y altamente interpretable para implementaciones de IA fiables.

Physics-Informed Machine Learning for Vessel Shaft Power and Fuel Consumption Prediction: Interpretable KAN-based Approach

Fecha: 25 de febrero de 2026 (Preprint arXiv)

Citación: Mohammed, H. H., Marijan, D., & Maressa, A. (2026). Physics-Informed Machine Learning for Vessel Shaft Power and Fuel Consumption Prediction: Interpretable

KAN-based Approach. *arXiv preprint arXiv:2602.22055*.

Área de aplicación: Ingeniería Marítima y Energía

Resumen:

La predicción precisa de la velocidad de rotación del eje, la potencia de propulsión y el consumo de combustible es vital para optimizar la eficiencia operativa y reducir las emisiones en el transporte marítimo. Los modelos convencionales basados en la física de fluidos proporcionan alta interpretabilidad, pero fracasan al intentar modelar la variabilidad del mundo real inducida por factores como el oleaje o el desgaste del casco. Paralelamente, los enfoques de caja negra basados en datos (como los MLP) alcanzan gran precisión, pero frecuentemente generan predicciones físicamente inverosímiles (por ejemplo, predecir un menor consumo de combustible a mayor velocidad) al extrapolar fuera del dominio de entrenamiento.

Para cerrar esta brecha, los autores introducen la red PI-KAN (Physics-Informed Kolmogorov-Arnold Network). Este enfoque híbrido implementa transformaciones de características univariadas por cada variable de entrada (velocidad del viento, altura de las olas, calado del buque, etc.) seguidas de una combinación lineal. A diferencia de las redes neuronales densas, PI-KAN descompone la función de predicción en componentes aislados y explicables, reteniendo a la vez la capacidad de aprender dependencias no lineales a través de las funciones de activación ubicadas en sus bordes.

El entrenamiento del modelo se rige por una función de pérdida informada por la física ($L_{physics}$) que penaliza las desviaciones respecto a las ecuaciones de resistencia empírica. Esta pérdida equilibra dinámicamente la fidelidad a los datos con la consistencia termodinámica mediante un hiperparámetro autoajutable γ . Además, para prevenir la filtración de datos (data leakage) en predicciones multifase, el sistema incorpora un pipeline en cadena (RPM $\rightarrow$ potencia $\rightarrow$ combustible) validado mediante técnicas de apilamiento fuera de la muestra (*out-of-fold stacking*).

Los resultados empíricos utilizando telemetría de cinco buques de carga muestran que PI-KAN supera consistentemente a los métodos polinómicos y a las líneas base de redes neuronales, registrando el menor Error Cuadrático Medio (RMSE) y el mayor Coeficiente de Determinación (R^2). De manera crucial, el análisis de interpretabilidad confirmó que la red redescubre de forma autónoma leyes físicas del dominio (como la relación cúbica entre velocidad y potencia), estableciéndose como un modelo altamente robusto y transparente para la toma de decisiones marítimas.

Elastoplasticity Informed Kolmogorov–Arnold Networks Using Chebyshev Polynomials

Fecha: 18 de febrero de 2026 (Publicado en *International Journal for Numerical and Analytical Methods in Geomechanics*)

Citación: Mostajeran, F., & Faroughi, S. A. (2026). Elastoplasticity Informed Kolmogorov–Arnold Networks Using Chebyshev Polynomials. *International Journal for Numerical and Analytical Methods in Geomechanics*.

Área de aplicación: Geomecánica y Ciencia de Materiales (Elastoplasticidad)

Resumen:

El estudio de los modelos constitutivos elastoplásticos para materiales granulares (como la arena) es vital en ingeniería civil para predecir las relaciones tensión-deformación bajo cargas complejas. Los enfoques tradicionales basados en física tienen dificultades para capturar empíricamente las respuestas altamente no lineales, y los modelos impulsados por datos (como los MLP) sufren de la "maldición de la dimensionalidad", requiriendo arquitecturas muy profundas o anchas y grandes cantidades de datos experimentales para alcanzar una precisión aceptable.

Para resolver estas limitaciones, los autores presentan EPi-cKAN (Elastoplasticity informed Chebyshev-based Kolmogorov-Arnold network). Esta arquitectura aprovecha el teorema de Kolmogorov-Arnold pero sustituye las funciones base B-spline estándar por polinomios de Chebyshev aumentados combinados con una función de activación ReLU. Además, integra principios físicos de elastoplasticidad (como la descomposición de la deformación y la elasticidad incremental) directamente en la topología de la red y en su función de pérdida.

La arquitectura se divide en subredes que calculan de manera simultánea e interdependiente la tasa de vacíos, la deformación plástica y el incremento de la tensión. El entrenamiento se realiza de forma informada por la física, donde el modelo EPi-cKAN usa sustancialmente menos parámetros que un MLP tradicional y evita el sobreajuste acoplado restricciones fenomenológicas derivadas de la mecánica del continuo, comprobando a posteriori que se cumplen las leyes de la termodinámica.

Evaluated frente a arquitecturas MLP y otras redes KAN puramente basadas en datos, EPi-cKAN demostró una precisión superior en la predicción de componentes de tensión y una excelente generalización en caminos de carga controlados por deformación que eran totalmente ciegos" (no se encontraban en los datos de entrenamiento). Adicionalmente, demostró ser altamente robusto al ruido, logrando un error de solo el 1,52 % en las predicciones de tensión desviadora ante datos de entrada con un 5 % de ruido, superando ampliamente a los modelos convencionales y estableciéndose como un sustituto robusto para modelos constitutivos granulares.

Physics-informed Kolmogorov-Arnold networks with residual-based adaptive distribution for scattered acoustic field prediction

Fecha: 23 de febrero de 2026 (Publicado en *Applied Intelligence*)

Citación: Ren, Y., Wang, L., & Ma, H. (2026). Physics-informed Kolmogorov-Arnold networks with residual-based adaptive distribution for scattered acoustic field prediction. *Applied Intelligence*, 56, 143.

Área de aplicación: Acústica y Detección de Anomalías (Campos Acústicos Dispersos)

Resumen:

La simulación precisa de campos acústicos dispersos es esencial en dominios como la evaluación no destructiva y la caracterización de materiales. Sin embargo, las redes neuronales informadas por la física (PINN) tradicionales basadas en perceptrones multicapa a menudo ignoran las dependencias continuas inherentes del campo acústico, fracasando

en propagar globalmente las características de dispersión y siendo incapaces de capturar detalles no lineales de alta frecuencia cerca de los límites del dispersor, debido a su falta de un mecanismo explícito de correlación espacial.

Para abordar este problema, los investigadores proponen PIKAN, un marco físico basado en redes de Kolmogorov-Arnold (KAN). PIKAN aprovecha la expansión de ondas planas de las redes KAN, un enfoque que coincide de forma natural y matemática con la formulación de los campos dispersos, descomponiendo la función multivariable en superposiciones trigonométricas unidimensionales. Como innovación crítica para asegurar su cálculo en paralelo, sustituye las funciones B-spline en los bordes por una función de activación periódica basada en el seno (Sine).

El modelo lleva su eficiencia un paso más allá al combinar esta arquitectura con el método de distribución adaptativa basada en residuos (RAD). En lugar de un muestreo uniforme sobre el dominio, el método RAD ajusta dinámicamente la densidad de los puntos de colocación durante el entrenamiento, dirigiendo automáticamente los recursos computacionales y el peso del gradiente hacia las regiones más complejas (como los límites de dispersores irregulares), donde las ecuaciones diferenciales presentan los mayores errores residuales.

Validado experimentalmente en tres escenarios desafiantes (alta frecuencia, dispersores irregulares y dispersión múltiple), PIKAN superó de manera sistemática a todos los modelos PINN de vanguardia y demostró ser superior a otras funciones de activación periódicas. Además de lograr métricas de error dramáticamente más bajas, PIKAN redujo la cantidad de parámetros necesarios de manera masiva (usando un 97,5 % menos de parámetros que el modelo base en dispersión múltiple) y aceleró notablemente el tiempo de entrenamiento, consolidando un marco óptimo entre costo computacional y fidelidad física.

Ultra-wide bandwidth system optical fiber channel modeling based on Kolmogorov-Arnold network and physical constraints

Fecha: 19 de marzo de 2026 (Publicado en *Optics Express*)

Citación: Yang, H., Wang, Y., Chao, L., Han, L., Wang, S., Zhang, Q., & Xin, X. (2026). Ultra-wide bandwidth system optical fiber channel modeling based on Kolmogorov-Arnold network and physical constraints. *Optics Express*, 34(6), 11321-11339.

Área de aplicación: Telecomunicaciones y Sistemas Ópticos (Comunicaciones de Banda Ultra Ancha)

Resumen:

Con el crecimiento explosivo de la inteligencia artificial, las redes troncales de fibra óptica requieren modelos de simulación de canales extremadamente precisos y eficientes para garantizar la transmisión en sistemas de banda ultra ancha (UWB). El método numérico dominante (SSFM) adolece de una complejidad computacional paralizante que escala linealmente con la distancia, mientras que los enfoques modernos basados en Deep Learning (MLP o DeepONet) requieren redes densas que carecen de interpretabilidad física y se degradan ante las interacciones no lineales severas inducidas en regímenes de alta potencia.

Para superar este cuello de botella, los autores introducen SepOKAN, una arquitectura de aprendizaje de operadores separables que abandona el uso de perceptrones multicapa a favor de redes de Kolmogorov-Arnold (KAN). Profundizando en su diseño, los investigadores construyen SPIKAN (Separable Physics-Informed KAN) añadiendo estrictas restricciones físicas a la función de pérdida; en concreto, acoplando las directrices de la ecuación de Schrödinger no lineal (NLSE) y la ecuación de Manakov al proceso iterativo de optimización de pesos.

Para modelar específicamente sistemas UWB que cubren las bandas S+C+L, la arquitectura paraleliza ramas neuronales que aprenden de forma independiente los operadores continuos y evalúan el acoplamiento cruzado de polarización dual multicanal. Crucialmente, la función de coste guiada por la física se reformuló para absorber los efectos de la Dispersión Raman Estimulada (SRS), que induce importantes fluctuaciones de transferencia de energía e inestabilidades de fase en estos canales de banda ultra ancha.

La evaluación del modelo utilizando transmisiones de fibra simuladas y reales demostró que SPIKAN coincide casi perfectamente con el SSFM tradicional tanto en dominios de tiempo como de frecuencia. A nivel de eficiencia algorítmica, logró reducir la cantidad de multiplicaciones reales en un 70 % en comparación con DeepONet. Asimismo, SPIKAN mantuvo un error cuadrático medio normalizado (NMSE) mínimo a distancias de hasta 1200 km y evidenció una sólida generalización a lo largo de diversos formatos de modulación óptica (de 4QAM a 64QAM), destacando su alto valor operativo.

Estimation of Lithium-Ion Battery SOH Based on a Hybrid Transformer-KAN Model

Fecha: 10 de diciembre de 2025 (Publicado en *Electronics*)

Citación: Chen, Z., Lu, J., Wei, Q., Wen, J., Wang, Y., Li, K., & Xu, A. (2025). Estimation of Lithium-Ion Battery SOH Based on a Hybrid Transformer-KAN Model. *Electronics*, 14(24), 4859.

Área de aplicación: Almacenamiento de Energía / Ingeniería Eléctrica (Baterías de Litio)

Resumen:

La estimación precisa del estado de salud (SOH) de las baterías de iones de litio es un reto técnico de primer orden debido a la complejidad de las reacciones electroquímicas internas y a las condiciones de funcionamiento altamente variables. Los modelos tradicionales, ya sean basados en modelos equivalentes de circuito o en redes neuronales estándar como las MLP, a menudo tienen dificultades para capturar las dependencias temporales de largo alcance y la fuerte no linealidad inherente al proceso de degradación de la batería, lo que limita su fiabilidad en aplicaciones críticas como el vehículo eléctrico.

Para abordar esta problemática, los investigadores proponen un modelo híbrido denominado Transformer-KAN. Esta arquitectura aprovecha la capacidad del mecanismo de autoatención (*self-attention*) del Transformer para extraer dependencias globales en las series temporales de indicadores de salud (como el tiempo de carga en intervalos de voltaje específicos o la capacidad de descarga). La innovación disruptiva consiste en sustituir las capas densas de salida por redes de Kolmogorov-Arnold (KAN), que utilizan funciones de

activación B-spline aprendibles para refinar el mapeo no lineal final.

A nivel de implementación, el modelo extrae múltiples indicadores de salud a partir de las curvas de carga y descarga, realizando un análisis de correlación de Grey para seleccionar las características más influyentes. El bloque Transformer codifica estas secuencias, mientras que la capa KAN optimiza la representación de la degradación, permitiendo que la red aprenda la forma funcional exacta de la pérdida de capacidad con un número de parámetros significativamente menor que una red neuronal convencional.

Los resultados experimentales, validados con conjuntos de datos de referencia (como los de la NASA y CALCE), demuestran que el modelo Transformer-KAN alcanza una precisión sobresaliente. Logró reducir el error cuadrático medio (RMSE) a valores inferiores al 0,5 % en la mayoría de los casos, superando a modelos consolidados como LSTM, GRU y Transformer estándar. Esta mejora en la precisión y la reducción de la carga computacional lo posicionan como una herramienta de gran valor para los sistemas de gestión de baterías (BMS) de próxima generación.

Application of a KAN-LSTM Fusion Model for Stress Prediction in Large-Diameter Pipelines

Fecha: Abril de 2025 (Publicado en *Information*)

Citación: Li, Z., & Qin, S. (2025). Application of a KAN-LSTM Fusion Model for Stress Prediction in Large-Diameter Pipelines. *Information*, 16(5), 233.

Área de aplicación: Ingeniería Mecánica y Civil (Monitorización de Tuberías)

Resumen:

La predicción precisa del estrés en tuberías de alcantarillado de gran diámetro es fundamental para garantizar su integridad estructural y prevenir fallos catastróficos. Estas infraestructuras están sujetas a cargas dinámicas complejas y factores ambientales que generan patrones de tensión no lineales y dependencias temporales que los modelos mecánicos simplificados no pueden capturar en su totalidad. Aunque las redes LSTM se han utilizado por su capacidad de memoria secuencial, su capa de salida lineal suele limitar la captura de fluctuaciones de estrés extremadamente no lineales.

Para resolver esta limitación estructural, los autores desarrollan un modelo de fusión KAN-LSTM. En esta arquitectura, la red LSTM actúa como un extractor de características temporales, procesando los datos históricos de los sensores de tensión para identificar patrones de carga periódicos y tendencias de fatiga. La mejora clave reside en modificar la capa completamente conectada del LSTM original, sustituyéndola por una capa KAN que parametriza las funciones de activación sobre los bordes, permitiendo una adaptación funcional mucho más rica a los picos de estrés.

El proceso de entrenamiento utiliza datos de monitorización real de tuberías de hormigón armado de gran escala. Al integrar la arquitectura KAN, el modelo adquiere una mayor capacidad de "ajuste local" gracias a los splines, lo que le permite reaccionar de forma más precisa ante cambios bruscos de presión o carga externa que una red tradicional suavizaría en exceso. Además, la estructura KAN facilita una reducción en el número de iteraciones necesarias para la convergencia del modelo.

Las conclusiones del estudio indican que el modelo KAN-LSTM alcanza un Error Absoluto Medio (MAE) de 0,033, superando significativamente al modelo LSTM tradicional en términos de precisión y estabilidad. Se observó que el modelo híbrido no solo es más exacto, sino que requiere una complejidad computacional menor en la fase de inferencia tras ser entrenado. Esto valida la utilidad de las redes de Kolmogorov-Arnold para mejorar la monitorización de salud estructural en infraestructuras civiles críticas.

AcousticMoEKAN: Sparse Mixture-of-KAN Experts for Time-Frequency Forecasting of OLTC Acoustic Signals

Fecha: 2026 (Aceptado en *IEEE Access*)

Citación: Kim, D., Kang, J., Hyun, Y., & Kim, H. (2026). AcousticMoEKAN: Sparse Mixture-of-KAN Experts for Time-Frequency Forecasting of OLTC Acoustic Signals. *IEEE Access*.

Área de aplicación: Ingeniería Eléctrica y Acústica (Mantenimiento de Transformadores)

Resumen:

El mantenimiento de los cambiadores de tomas bajo carga (OLTC) es crítico para la estabilidad de la red eléctrica, ya que son componentes mecánicos propensos al desgaste en transformadores de potencia. El análisis de señales acústicas es una técnica no invasiva prometedora para el diagnóstico de fallos, pero estas señales son ruidosas, transitorias y presentan una variabilidad tiempo-frecuencia extremadamente compleja. Los modelos de predicción actuales suelen tener dificultades para generalizar ante diferentes estados de operación y ruidos de fondo en las subestaciones.

Para abordar este reto, los autores proponen AcousticMoEKAN, una arquitectura que combina la técnica de Mezcla de Expertos (*Mixture-of-Experts*) dispersa con redes de Kolmogorov-Arnold. El modelo descompone la tarea de predicción en múltiples "expertos" basados en KAN, donde una red de compuerta (*gating network*) decide dinámicamente qué expertos son los más competentes para procesar una determinada ventana tiempo-frecuencia de la señal acústica, optimizando la eficiencia de parámetros y la especialización del aprendizaje.

A diferencia de las arquitecturas MoE tradicionales que usan perceptrones multicapa (MLP) como expertos, AcousticMoEKAN emplea splines univariados aprendibles en cada rama. Esto permite capturar las oscilaciones sutiles y las características no lineales de las ondas sonoras del OLTC con una transparencia matemática superior. El uso de una estrategia de activación dispersa (*sparse*) asegura que solo una fracción de los expertos KAN esté activa por muestra, lo que reduce drásticamente el coste computacional sin sacrificar la capacidad expresiva global de la red.

Los resultados demuestran que AcousticMoEKAN supera notablemente a modelos de referencia como Informer, Autoformer y redes MoE basadas en MLP en la predicción de espectrogramas acústicos. El modelo logró las mejores métricas de error (MSE y MAE) y demostró una robustez superior ante el ruido ambiental. Esta investigación consolida a las redes KAN como una base tecnológica potente para el diagnóstico predictivo en la infraestructura eléctrica, ofreciendo un equilibrio óptimo entre precisión y eficiencia.

operativa.

Interpretable Machine Learning Regression for Nuclear Applications with Kolmogorov-Arnold Networks (KAN)

Fecha: 2025 (Presentado en la conferencia *M&C 2025*)

Citación: Erdem, O., Panczyk, N., & Radaideh, M. I. (2025). Interpretable Machine Learning Regression for Nuclear Applications with Kolmogorov-Arnold Networks (KAN). *Proceedings of Mathematics and Computations (M&C) 2025*.

Área de aplicación: Ingeniería Nuclear (Flujo de Calor Crítico y Flujo Neutrónico)

Resumen:

La industria nuclear se enfrenta a un dilema fundamental respecto a la adopción de la inteligencia artificial: aunque los modelos de aprendizaje profundo ofrecen una precisión predictiva excepcional, su naturaleza de "caja negra" dificulta enormemente los procesos de verificación, validación y regulación exigidos por los estándares de seguridad. Los perceptrones multicapa (MLP) tradicionales carecen de una estructura matemática transparente, lo que impide a los ingenieros nucleares extraer leyes físicas explícitas a partir de los pesos y sesgos optimizados por la red.

Para abordar esta barrera regulatoria, los autores proponen el uso de redes de Kolmogorov-Arnold (KAN) como una alternativa intrínsecamente interpretable. El estudio aplica esta arquitectura a dos problemas canónicos de la ingeniería nuclear: la predicción del flujo de calor crítico (CHF) utilizando una base de datos histórica de 60 años, y la estimación del flujo de neutrones en un reactor modular de alta temperatura refrigerado por gas (HTGR) mediante datos simulados. A diferencia de los MLP, las KAN permiten transformar el aprendizaje de la red en una ecuación simbólica legible.

La implementación técnica se apoya en el paquete PyKAN, evaluando el rendimiento del modelo frente a redes neuronales de alimentación directa convencionales. Los investigadores incorporan un análisis de explicabilidad basado en la teoría de juegos de Shapley para cuantificar la contribución de cada variable física (presión, calidad del vapor, flujo de masa) a la predicción final. Este enfoque permite comparar no solo el error cuadrático medio, sino también la fidelidad del modelo a los principios termodinámicos y neutrónicos subyacentes.

Los resultados indican que, aunque las redes KAN presentan una precisión ligeramente inferior a los MLP en estos problemas específicos, esta pérdida marginal se compensa con un aumento drástico en la interpretabilidad. La capacidad de las KAN para generar expresiones algebraicas explícitas facilita la supervisión humana y el cumplimiento normativo, demostrando que son una herramienta robusta para aplicaciones donde la transparencia del modelo es tan crítica como su capacidad de generalización.

3. Medicina y Análisis de Supervivencia

CoxKAN: Kolmogorov-Arnold Networks for Interpretable Survival Analysis

Fecha: 2024 (Preprint)

Citación: [Autores de CoxKAN]. (2024). CoxKAN: Kolmogorov-Arnold Networks for Interpretable Survival Analysis. *arXiv preprint*.

Área de aplicación: Medicina (Análisis de Supervivencia)

Resumen:

El análisis de supervivencia es fundamental en la investigación médica para predecir el tiempo hasta que ocurre un evento de interés, como la aparición de una enfermedad o el fallecimiento de un paciente. El modelo tradicional de riesgos proporcionales de Cox (CPH) es el estándar debido a su alta interpretabilidad, pero asume relaciones estrictamente lineales, fracasando ante datos complejos. Por otro lado, los modelos de aprendizaje profundo como DeepSurv capturan relaciones no lineales pero operan como cajas negras, lo cual es inaceptable en entornos clínicos donde los médicos necesitan comprender las decisiones del algoritmo.

Para resolver esta dicotomía, los autores proponen CoxKAN, una arquitectura que integra el marco de riesgos proporcionales de Cox con las redes de Kolmogorov-Arnold (KAN). En este modelo, el predictor lineal estándar del modelo de Cox se sustituye por una red KAN, la cual utiliza funciones B-spline parametrizadas en las conexiones (bordes) en lugar de funciones de activación estáticas en los nodos.

Este enfoque permite al modelo aprender relaciones altamente no lineales entre las co-variables de los pacientes y el riesgo de mortalidad, manteniendo al mismo tiempo la transparencia. Mediante la poda de conexiones irrelevantes y la aplicación de regresión simbólica a los B-splines aprendidos, CoxKAN puede extraer las fórmulas matemáticas explícitas que definen el riesgo, haciendo que el modelo sea completamente auditable por expertos médicos.

Las conclusiones del estudio muestran que CoxKAN iguala o supera el rendimiento predictivo (medido a través del índice de concordancia o C-index) de los modelos de aprendizaje profundo de última generación en múltiples conjuntos de datos médicos. Su mayor ventaja radica en que logra este nivel de precisión ofreciendo funciones de riesgo visualizables y matemáticamente transparentes, eliminando la barrera de la caja negra.^{en} la medicina predictiva.

KAN-AFT: An Interpretable Nonlinear Survival Model

Fecha: 2024 (Preprint)

Citación: M. Josea, J. Francisa, S. K. Kattumannilb. KAN-AFT: An Interpretable Nonlinear Survival Model. *arXiv preprint*.

Área de aplicación: Medicina y Bioestadística (Análisis de Supervivencia)

Resumen:

Junto con el modelo de Cox, los modelos de Tiempo de Fallo Acelerado (AFT, por sus siglas en inglés) son una herramienta fundamental en el análisis de supervivencia, ya que modelan directamente el tiempo de supervivencia en lugar de la tasa de riesgo. Sin embargo, los modelos AFT clásicos sufren limitaciones similares al asumir relaciones paramétricas simples. Las variantes modernas basadas en redes neuronales (Deep AFT) logran mayor precisión al modelar la no linealidad, pero sacrifican la explicabilidad, dificultando su adopción en ensayos clínicos e investigación biomédica.

Para abordar este problema, los investigadores presentan KAN-AFT, un modelo que combina la formulación del Tiempo de Fallo Acelerado con la arquitectura de las redes de Kolmogorov-Arnold. A diferencia de las redes neuronales convencionales, KAN-AFT mapea la relación entre las características clínicas del paciente y el logaritmo del tiempo de supervivencia utilizando funciones univariadas aprendidas en los bordes de la red.

El modelo está diseñado para manejar eficientemente datos censurados por la derecha, una característica omnipresente en los estudios médicos donde los pacientes abandonan el estudio antes de que ocurra el evento. La estructura KAN permite aislar y visualizar cómo cada covariable individual afecta el tiempo de supervivencia predicho, facilitando la identificación de factores de riesgo no lineales que los métodos tradicionales pasarían por alto.

La evaluación experimental demuestra que KAN-AFT no solo ofrece un rendimiento superior o equivalente en comparación con los modelos AFT basados en perceptrones multicapa (MLP), sino que también proporciona una interpretabilidad sin precedentes. La capacidad de derivar expresiones analíticas directas para el tiempo de supervivencia convierte a KAN-AFT en una herramienta robusta y confiable para la toma de decisiones clínicas.

Diabetic retinopathy severity detection using an improved Whale optimization algorithm and convolutional Kolmogorov-Arnold network

Fecha: 13 de marzo de 2026 (Publicado en *Frontiers in Medicine*)

Citación: Dutta, A. K., Aljarallah, N. A., & Sait, A. R. (2026). Diabetic retinopathy severity detection using an improved Whale optimization algorithm and convolutional Kolmogorov-Arnold network. *Frontiers in Medicine*, 13:1709872.

Área de aplicación: Medicina / Diagnóstico por Imagen (Oftalmología)

Resumen:

La retinopatía diabética (RD) es una de las principales causas de pérdida irreversible de la visión a nivel mundial, lo que hace que su detección temprana y la clasificación de su gravedad sean tareas críticas de salud pública. El diagnóstico manual mediante imágenes de fondo de ojo es un proceso laborioso y propenso a errores humanos de interpretación. Aunque las Redes Neuronales Convolucionales (CNN) tradicionales han demostrado ser eficaces en esta tarea, suelen requerir una gran cantidad de parámetros y carecen de una transparencia matemática que permita a los especialistas clínicos validar el proceso de toma de decisiones del modelo.

Para mitigar estos problemas, los autores proponen un marco de diagnóstico inteligente

que integra un Algoritmo de Optimización de Ballenas Mejorado (IWOA) con una Red Convolutiva de Kolmogorov-Arnold (CKAN). En la fase de preprocesamiento, se utiliza el algoritmo IWOA para realizar una selección de características óptimas y un ajuste de los hiperparámetros de la red, superando las limitaciones de los algoritmos de optimización estándar que suelen quedar atrapados en óptimos locales al tratar con la alta variabilidad de las lesiones retinianas.

La arquitectura CKAN sustituye las capas de salida completamente conectadas de la CNN por capas KAN basadas en splines aprendibles. A diferencia de los modelos de caja negra convencionales, esta estructura permite realizar una aproximación no lineal de las clases de gravedad de la RD (desde casos leves hasta proliferativos) mediante funciones univariadas en los bordes de la red. Esto no solo mejora la capacidad del modelo para distinguir sutiles exudados y microaneurismas, sino que reduce significativamente la complejidad computacional, facilitando su despliegue en dispositivos médicos ligeros.

Los resultados de la investigación, validados en conjuntos de datos públicos como APTOS y DDR, muestran que el modelo propuesto alcanza una precisión superior al 98 % en la detección multiclase de la gravedad de la enfermedad. El uso de la red KAN permitió obtener un modelo con un tamaño de parámetros sustancialmente menor que arquitecturas densas similares, manteniendo una robustez excepcional. Esta combinación de optimización metaheurística y redes KAN establece un nuevo estándar en la oftalmología computacional, proporcionando una herramienta de cribado altamente precisa y eficiente.

4. Meteorología, Medio Ambiente y Agricultura

Kolmogorov–Arnold Network-Enhanced Temporal Models on Cloud–Edge System for Real-Time Apple Spoilage Monitoring

Fecha: 18 de enero de 2026 (Publicado en *Food and Bioprocess Technology*)

Citación: Guo, Z., Ya, X., Yang, C., Sang, W., Jayan, H., Wang, C., Sun, C., & Zou, X. (2026). Kolmogorov–Arnold Network-Enhanced Temporal Models on Cloud–Edge System for Real-Time Apple Spoilage Monitoring. *Food and Bioprocess Technology*, 19, 179.

Área de aplicación: Agricultura y Medio Ambiente (Monitorización en Tiempo Real)

Resumen:

Las pérdidas poscosecha de manzanas durante el almacenamiento y el transporte representan un desafío crucial tanto para la seguridad alimentaria como para los beneficios económicos. Los métodos tradicionales para detectar la descomposición o el deterioro suelen ser lentos y no permiten realizar una monitorización precisa y en tiempo real, lo que dificulta tomar medidas preventivas antes de que se pierda gran parte de la mercancía.

Para abordar este problema, los autores proponen un marco integral que combina la detección de múltiples gases, aprendizaje profundo y un sistema de colaboración nube-borde (*cloud-edge*). A través de una matriz de múltiples sensores, se recogen continuamente parámetros ambientales y fisicoquímicos clave del entorno de almacenamiento. Esta información se procesa mediante modelos temporales a los que se les ha integrado el módulo de la red de Kolmogorov-Arnold (KAN), creando arquitecturas avanzadas como LSTM-KAN, BiLSTM-KAN y TCN-KAN.

En este sistema colaborativo, la plataforma en la nube se encarga de las actualizaciones centralizadas del modelo y el entrenamiento intensivo, mientras que los dispositivos de borde ejecutan la inferencia en tiempo real de forma autónoma. Debido a las limitaciones de recursos de hardware en el borde, los investigadores aplicaron una técnica de poda estructural para comprimir el tamaño del modelo sin perder precisión predictiva, logrando que el modelo TCN-KAN podado mejorara su velocidad de inferencia en un 42,68 %.

Los resultados revelaron que la arquitectura TCN-KAN alcanzó el mejor rendimiento (con un R^2 de 0,968) al predecir cuantitativamente el índice compuesto de descomposición (CSI). En definitiva, la combinación de las redes KAN temporales y la inteligencia en el borde proporciona una solución altamente precisa, escalable y rentable para la monitorización en tiempo real en la agricultura inteligente.

KANs Layer Integration: Benchmarking Deep Learning Architectures for Tornado Prediction

Fecha: 16 de diciembre de 2025 (Publicado en *Big Data and Cognitive Computing*)

Citación: Yang, S., Vilataj, E., Raza, M. F., & Srinivasan, S. M. (2025). KANs Layer Integration: Benchmarking Deep Learning Architectures for Tornado Prediction. *Big Data and Cognitive Computing*, 9(1), 324.

Área de aplicación: Meteorología (Predicción de Tornados)

Resumen:

La predicción de tornados a través de imágenes de radar Doppler sigue siendo un desafío operativo enorme debido a la extrema rareza de estos eventos y a sus complejas dinámicas atmosféricas. Los algoritmos tradicionales sufren altas tasas de falsas alarmas, mientras que los modelos estándar de aprendizaje profundo se ven muy afectados por el severo desequilibrio de clases y el ruido en el etiquetado de los datos, lo que limita gravemente la fiabilidad y el tiempo de reacción para emitir alertas públicas que salvan vidas.

Para superar esto, los investigadores realizan un análisis comparativo de varias arquitecturas de aprendizaje profundo (como CNN, VGG19 y Xception) utilizando el conjunto de datos TorNet, el cual contiene volúmenes de radar polarimétricos de alta resolución. La innovación principal consiste en sustituir las capas densas tradicionales (MLP) en la salida de estos modelos por capas basadas en redes de Kolmogorov-Arnold (KAN). Esta modificación permite descomponer las funciones multivariadas mediante funciones univariadas en los bordes, capturando de forma más eficiente las firmas espacio-temporales subyacentes del radar.

Para hacer frente a los desafíos del desequilibrio de datos, el equipo de investigación diseñó además un canal de preprocesamiento y aumento de datos específico para semántica de meteorología (que incluye filtrado direccional y de intensidad). También implementaron estrategias de entrenamiento orientadas a penalizar la falta de detección de eventos raros, utilizando técnicas de sobremuestreo, pesos dinámicos de clases y la función de pérdida de Tversky para equilibrar falsos positivos y falsos negativos de manera asimétrica.

La evaluación demostró que la integración de las capas KAN aceleró drásticamente la convergencia del entrenamiento, incrementó la sensibilidad para detectar eventos reales (mejorando el *recall* en un 15 %) y elevó el AUC-ROC en un 10 % respecto a los modelos convencionales. Al combinarse con el sólido aumento de datos de radar, los modelos híbridos KAN lograron reducir la tasa de falsos positivos a más de la mitad, mitigando el peligroso efecto de "falsa alarma constante" creando un sistema de alerta temprana mucho más confiable.

Workface Methane Concentration Prediction Based on Transformer-KAN

Fecha: 2026 (Vol. 20, No. 1, 2026 en *Academic Journal of Science and Technology*)

Citación: Wu, L., Wang, D., Yu, H., Zhang, S., Fan, S., Liu, Z., & Wang, Y. (2026). Workface Methane Concentration Prediction Based on Transformer-KAN. *Academic Journal of Science and Technology*, 20(1).

Área de aplicación: Minería y Medio Ambiente (Monitorización de Metano)

Resumen:

La prevención de accidentes por acumulación de gas es la mayor prioridad en la seguridad de las minas de carbón modernas. Un problema fundamental es la dificultad de predecir la concentración de metano en los frentes de trabajo subterráneos debido a que los modelos tradicionales dependen de modelos de decaimiento a distancia fija que no logran modelar adecuadamente la compleja correlación espacial que existe entre los múltiples sensores distribuidos por los túneles.

Para solucionar este desafío, los autores proponen un sistema inteligente basado en la ar-

quitectura Transformer-KAN. En la primera fase del modelo, se aprovecha el mecanismo de autoatención (self-attention) de las redes Transformer para calcular dinámicamente los pesos de influencia que tienen los sensores periféricos (como los de presión atmosférica o temperatura) ubicados en distintas zonas de la galería sobre el punto objetivo de concentración de metano.

En la segunda fase, el modelo sustituye las activaciones tradicionales por las funciones base spline diferenciables de la red KAN. Esto permite construir y hacer explicable la relación de mapeo físico altamente no lineal que ocurre entre los gradientes de presión atmosférica y la concentración de metano. Todo este flujo de datos se alimenta a través de redes de sensores de alta precisión, aplicando sincronización temporal exacta y filtros de Kalman para el preprocesamiento antes de pasar por un motor de inferencia acelerado.

Como conclusión, este modelo logra realizar predicciones precisas a nivel de minutos (con una latencia objetivo de 200 ms) y alta fiabilidad, alcanzando un RMSE inferior al 0,15 %. Su validación con datos en tiempo real de una mina de carbón demuestra que el sistema proporciona un soporte tecnológico clave y robusto para la actualización inteligente de la seguridad minera.

SMamba-KAN: an advanced temporal-nonlinear model for precise water level prediction

Fecha: 22 de octubre de 2025 (Publicado en *Frontiers in Water*)

Citación: Yan, X., Zhao, H., & Zhou, R. (2025). SMamba-KAN: an advanced temporal-nonlinear model for precise water level prediction. *Frontiers in Water*, 7, 1638839.

Área de aplicación: Hidrología y Meteorología (Predicción de niveles de agua)

Resumen:

La predicción precisa del nivel del agua en ríos es crítica para el control de inundaciones, el riego agrícola y la gestión de recursos hídricos. Los modelos tradicionales hidrológicos y de aprendizaje automático sufren limitaciones graves al intentar modelar al mismo tiempo las dependencias temporales a largo plazo y las complejas interacciones no lineales entre múltiples variables ambientales, como los efectos acumulativos meteorológicos o las olas de calor.

Para superar estas limitaciones, los autores proponen el marco SMamba-KAN, un modelo híbrido avanzado. El sistema comienza alterando la estructura clásica de tokens, aplicando una estrategia de incrustación de variables (Variate Token Embedding) que trata cada variable (temperatura, presión, lluvia, etc.) como un token individual. Posteriormente, la información pasa por un módulo Mamba bidireccional basado en modelos de espacio de estados (SSM), lo que permite capturar eficientemente el contexto temporal y la memoria a largo plazo de la secuencia.

Para compensar la deficiencia del módulo Mamba a la hora de modelar la no linealidad, los investigadores integran un módulo KAN estructurado y ligero. Este módulo combina funciones base B-spline con un mecanismo de atención completa (FullAttention), permitiendo transformaciones no lineales controlables que aprenden las complejas interacciones acopladas entre los distintos factores meteorológicos y los niveles del río. El modelo fue

probado en estaciones de la cuenca del río Yangtsé para pronosticar niveles a 15 días vista.

Los resultados revelan un éxito rotundo: SMamba-KAN redujo los errores de predicción (MSE) en más de un 90 % en comparación con la arquitectura Mamba original y en un 54 % respecto a SMamba puro, alcanzando un MAPE de apenas 2,095 %. Además de su excelente precisión y estabilidad ante datos ruidosos o incompletos, la arquitectura mantuvo unos requerimientos computacionales muy bajos, verificando su gran capacidad de generalización para tareas operativas de alerta temprana.

Heterogeneous Graph Kolmogorov–Arnold Networks for Spatio-Temporal Wind Power Forecasting

Fecha: 26 de febrero de 2026 (Publicado en *Smart Grids and Sustainable Energy*)

Citación: Bohra, N. M., Patil, A. R., Deshmukh, P. V., & Shahade, A. K. (2026). Heterogeneous Graph Kolmogorov–Arnold Networks for Spatio-Temporal Wind Power Forecasting. *Smart Grids and Sustainable Energy*, 11(18).

Área de aplicación: Energía Renovable y Meteorología (Predicción de Energía Eólica)

Resumen:

La predicción precisa de la energía eólica a corto plazo es fundamental para la gestión de la red eléctrica, pero resulta extremadamente compleja a nivel de turbina dentro de parques eólicos a gran escala. Esta dificultad se debe a la dinámica temporal altamente no lineal, a las dependencias espaciales heterogéneas y a los complejos efectos de estela aerodinámica (*wake effects*) entre las turbinas. Los modelos tradicionales de redes neuronales de grafos (GNN) fracasan aquí, ya que suelen basarse en grafos homogéneos y emplean transformaciones lineales (multiplicaciones de matrices) que no logran modelar adecuadamente la intrincada física de estos fenómenos meteorológicos.

Para resolver estas limitaciones, los autores proponen la arquitectura HG-KAN (Heterogeneous Graph Kolmogorov–Arnold Network), un marco de paso de mensajes funcional. El modelo unifica tres tipos distintos de relaciones (aristas) en un solo grafo heterogéneo: proximidad espacial (basada en distancia), influencia direccional de la estela (basada en la dirección del viento) y correlación de potencia empírica. En lugar de utilizar pesos lineales, el sistema asigna a cada tipo de relación una función de aproximación univariante aprendible inspirada en las redes KAN, lo que permite realizar transformaciones no lineales específicas para cada interacción.

El desarrollo del modelo combina estas capas de paso de mensajes KAN con un mecanismo de atención que pondera dinámicamente la importancia de cada tipo de relación. Posteriormente, las representaciones espaciales extraídas se introducen en un decodificador temporal LSTM de dos capas para generar los pronósticos de potencia en múltiples horizontes. La optimización de la red reveló que el uso de cinco funciones base de B-splines proporciona el equilibrio matemático perfecto entre capacidad expresiva y prevención del sobreajuste.

Evaluated on a real-world dataset of a 200-turbine wind park with more than 8,000 hourly observations, the optimized HG-KAN model (using only spatial and wake relationships) significantly outperformed stronger baselines, achieving

un R^2 de 0,3991 frente al 0,3906 del modelo ST-GAT. Los estudios de ablación demostraron de forma concluyente que las relaciones empíricas basadas en correlación introducían ruido, y que la integración informada por la física (efectos de estela direccional combinados con transformaciones KAN) es el motor principal para lograr una predicción espaciotemporal precisa, interpretable y computacionalmente eficiente.

KAN-FIF: Spline-Parameterized Lightweight Physics-based Tropical Cyclone Estimation on Meteorological Satellite

Fecha: 12 de febrero de 2026 (Preprint arXiv:2602.12117v1)

Citación: Shen, J., Chen, Q., Zhang, F., Xu, C., & Zhang, J. (2026). KAN-FIF: Spline-Parameterized Lightweight Physics-based Tropical Cyclone Estimation on Meteorological Satellite. *arXiv preprint arXiv:2602.12117*.

Área de aplicación: Meteorología, Medio Ambiente y Agricultura (Ciclones Tropicales)

Resumen:

La monitorización de ciclones tropicales en tiempo real es vital para la mitigación de desastres, pero su ejecución directa en dispositivos de borde con recursos limitados (como los propios satélites meteorológicos) se ve obstaculizada por el excesivo tamaño de las redes neuronales actuales. Los modelos guiados por la física existentes dependen de interacciones de características puramente lineales, fracasando matemáticamente a la hora de capturar las relaciones polinómicas de alto orden entre los atributos del ciclón sin provocar una explosión combinatoria en el número de parámetros del modelo.

Para superar esta ineficiencia paramétrica, los autores introducen la arquitectura KAN-FIF. Este modelo reestructura el paradigma de aproximación sustituyendo las pesadas capas densas tradicionales por redes de Kolmogorov-Arnold (KAN). Al emplear funciones univariadas parametrizadas mediante splines aprendibles en las aristas del grafo de computación, el modelo logra mapear la dinámica atmosférica altamente no lineal con una fracción mínima de los pesos requeridos por un perceptrón multicapa (MLP) equivalente.

A nivel estructural, KAN-FIF no actúa como una caja negra puramente empírica, sino que integra restricciones físicas directamente en su topología neuronal. Esto le permite modelar de forma explícita y algorítmicamente eficiente las interacciones físicas de las variables meteorológicas extraídas de las imágenes de satélite infrarrojas y de vapor de agua. La formulación matemática basada en splines garantiza que el modelo capture las fluctuaciones de intensidad complejas sin exceder las restricciones de memoria del hardware satelital.

Las evaluaciones demostraron que KAN-FIF alcanza un rendimiento superior en la estimación de la intensidad y el tamaño de los ciclones tropicales. Al reducir drásticamente el conteo de parámetros, el modelo demuestra ser extremadamente ligero e idóneo para su despliegue en sistemas de inferencia en el borde (*edge computing*), confirmando que la topología KAN permite resolver problemas de inferencia física complejos bajo severas restricciones computacionales.

Short-Term Photovoltaic Power Prediction Using a DPCA-CPO-RF KAN-GRU Hybrid Model

Fecha: 2026 (Publicado en *Processes*)

Citación: Liu, M., Zhou, Y., Wei, Y., Zhao, W., Qu, M., Bai, X., & Ding, Z. (2026). Short-Term Photovoltaic Power Prediction Using a DPCA-CPO-RF KAN-GRU Hybrid Model. *Processes*.

Área de aplicación: Energía Renovable y Meteorología (Predicción Fotovoltaica)

Resumen:

La intermitencia y la incertidumbre inherentes a la generación de energía fotovoltaica, impulsadas por la extrema volatilidad de los factores meteorológicos locales, plantean un desafío crítico para la estabilidad de la red eléctrica. La predicción precisa a corto plazo es matemáticamente indispensable para optimizar el despacho de energía; sin embargo, los enfoques de series temporales convencionales fracasan repetidamente al intentar modelar las intrincadas correlaciones multivariantes entre la radiación solar, la temperatura y la potencia real de salida.

Para estructurar y aislar este espacio de características ruidoso, los autores proponen un pipeline algorítmico de preprocesamiento secuencial. En la primera fase, despliegan el Algoritmo de Agrupamiento de Picos de Densidad (DPCA) para segmentar y clasificar rigurosamente los regímenes meteorológicos. A continuación, el marco utiliza el Optimizador de Puercoespín Crestado (CPO) acoplado a un Bosque Aleatorio (RF) para ejecutar un filtrado de características, reduciendo la dimensionalidad al seleccionar exclusivamente las covariables que aportan información causal al sistema.

El motor de inferencia del sistema abandona las arquitecturas densas en favor de un modelo híbrido GRU-KAN. Mientras la Unidad Recurrente Cerrada (GRU) se encarga de extraer las dependencias secuenciales a corto plazo del flujo de datos, el modelo introduce una capa de redes de Kolmogorov-Arnold (KAN) en el extremo de la topología. Al aplicar expansiones de B-splines aprendibles sobre las aristas, la capa KAN absorbe las complejas fluctuaciones no lineales de las variables climáticas, logrando una aproximación funcional superior sin el riesgo de sobreparametrización propio de los perceptrones multicapa (MLP).

Para validar la solidez del marco DPCA-CPO-RF KAN-GRU, la investigación integra la métrica SHAP (Shapley Additive Explanations), proporcionando una explicabilidad *ex post* que cuantifica la contribución exacta de cada característica meteorológica a la predicción. La evaluación empírica confirma que esta integración de optimización meta-heurística, modelado temporal y regresión KAN minimiza drásticamente los errores de predicción frente a los enfoques de caja negra tradicionales, ofreciendo una herramienta altamente fiable para la gestión de infraestructuras solares.

5. Otras Aplicaciones y Teoría

A Practitioner's Guide to Kolmogorov-Arnold Networks

Fecha: 6 de enero de 2026 (Preprint arXiv:2510.25781v3)

Citación: Noorizadegan, A., Wang, S., Ling, L., & Dominguez-Morales, J. P. (2026). A Practitioner's Guide to Kolmogorov-Arnold Networks. *arXiv preprint arXiv:2510.25781*.

Área de aplicación: Teoría y Revisión (Guía Práctica)

Resumen:

Los perceptrones multicapa (MLP) son el estándar actual para la aproximación de funciones, pero presentan limitaciones inherentes: sus funciones de activación fijas restringen la adaptabilidad, sufren de sesgo espectral y su comportamiento de "caja negra" dificulta la interpretabilidad. Aunque las redes de Kolmogorov-Arnold (KAN) han surgido como una alternativa estructurada prometedora inspirada en el teorema de superposición de Kolmogorov (KST), la rápida expansión de su literatura y la multitud de variantes dificultan que los investigadores elijan la arquitectura y función base adecuadas para sus problemas.

Para estructurar este campo, el documento ofrece una revisión sistemática que unifica la teoría y la práctica. En primer lugar, clarifica las relaciones matemáticas de las KAN. Demuestra que las KAN poco profundas son equivalentes a los métodos clásicos de kernel, mientras que las KAN profundas son formalmente equivalentes a los MLP en capacidad expresiva, pero estructuralmente distintas al aplicar transformaciones univariadas aprendidas en las conexiones (bordes) en lugar de en los nodos, mejorando así la eficiencia de parámetros.

En segundo lugar, los autores analizan las funciones base como el eje central del diseño de las KAN. Proporcionan una comparación exhaustiva de múltiples familias, incluyendo B-splines, polinomios de Chebyshev y Jacobi, activaciones ReLU locales, bases Gaussianas (RBF) y series de Fourier. Además, recopilan los avances recientes en técnicas de mejora de precisión, paralelización en GPU, regularización para lograr interpretabilidad y leyes de escalado.

Como conclusión, la revisión se consolida como una guía práctica de tipo "elige tu propia KAN" (*Choose-Your-KAN*), orientando a los profesionales sobre qué base usar según el tipo de problema (por ejemplo, Fourier para periodicidad o Chebyshev para estabilidad numérica profunda). Confirma que las redes KAN representan una extensión altamente adaptable y transparente del aprendizaje profundo tradicional.

P1-KAN: An Effective Kolmogorov-Arnold Network with Application to Hydraulic Valley Optimization

Fecha: 2024 (Preprint arXiv)

Citación: Warin, X. (2024). P1-KAN: An Effective Kolmogorov-Arnold Network with Application to Hydraulic Valley Optimization. *arXiv preprint*.

Área de aplicación: Optimización Estocástica y Aproximación de Funciones

Resumen:

El algoritmo original de las redes KAN basado en B-splines es computacionalmente costoso de entrenar. Además de este problema de eficiencia, presenta otro inconveniente estructural: la salida de una capa puede no encajar en la cuadrícula inicialmente elegida para la capa siguiente. Por último, dado que las expansiones de Kolmogorov pueden involucrar funciones muy irregulares, el uso de aproximaciones de alto orden como los splines puede no ser la estrategia matemática más adecuada frente a funciones complejas o no diferenciables.

Para abordar estas deficiencias, el autor propone la red P1-KAN, una arquitectura basada en el método de elementos finitos P1 (funciones lineales a trozos) sobre una malla. El modelo introduce dos variantes de capa: una que utiliza una cuadrícula regular y otra que emplea una cuadrícula adaptativa que se ajusta dinámicamente a los datos, aumentando la densidad de puntos en las áreas donde el gradiente de la función objetivo es más pronunciado.

A diferencia de otras variantes de KAN que intentan forzar activaciones sigmoideas para acotar la salida o que fallan al intentar adaptar el soporte de las funciones, la arquitectura P1-KAN procesa un hipercubo de entrada y devuelve directamente los valores calculados junto con un nuevo hipercubo, permitiendo apilar las capas de forma natural y matemáticamente coherente. Se proporcionan teoremas de aproximación universal y límites de error tanto para funciones continuas como suaves.

Los experimentos demuestran que P1-KAN con adaptación supera a variantes como Fast-KAN y ReLU-KAN, y es muy superior a los MLP tradicionales en términos de precisión y velocidad de convergencia al aproximar funciones altamente irregulares. Aunque su rendimiento es similar al de Spline-KAN en funciones suaves, el modelo P1-KAN resulta ser una herramienta sumamente eficaz y robusta para resolver problemas reales de optimización estocástica en alta dimensión, como la gestión óptima de un valle hidráulico francés.

KAN We Flow? Advancing Robotic Manipulation with 3D Flow Matching via KAN & RWKV

Fecha: 1 de febrero de 2026 (Preprint arXiv:2602.01115v1)

Citación: Chen, Z., Ge, Y., & Wang, Z. (2026). KAN We Flow? Advancing Robotic Manipulation with 3D Flow Matching via KAN & RWKV. *arXiv preprint arXiv:2602.01115*.

Área de aplicación: Robótica (Manipulación 3D e Imitación)

Resumen:

Las políticas visomotoras basadas en modelos de difusión han logrado un éxito notable en la manipulación robótica, pero adolecen de una grave ineficiencia en la inferencia debido a que requieren múltiples pasos de muestreo y arquitecturas UNet muy pesadas. Los enfoques recientes de coincidencia de flujo (*flow matching*) alivian esta carga al aprender un campo vectorial continuo que permite generar la acción en un solo paso, pero las implementaciones existentes siguen heredando redes troncales masivas que dificultan enormemente su despliegue en robots con recursos de hardware limitados.

Para solucionar este cuello de botella, los autores desarrollan KAN-We-Flow, una política de coincidencia de flujo ultraligera. La innovación principal es la sustitución de la pesada

arquitectura UNet tradicional por un bloque híbrido denominado RWKV-KAN. En la primera etapa, el módulo Receptance Weighted Key Value (RWKV) realiza una mezcla eficiente del contexto temporal y de canales con una complejidad estrictamente lineal, lo que permite asimilar las correlaciones a lo largo de toda la trayectoria de acción.

En la segunda etapa, en lugar de utilizar matrices de pesos densas, se aplica una capa GroupKAN. Este módulo agrupa los canales y emplea mapeos funcionales univariados parametrizados por splines aprendidos, realizando una calibración no lineal de las características con una altísima eficiencia de parámetros. Adicionalmente, para estabilizar el entrenamiento, introducen la Regularización de Consistencia de Acción (ACR), una pérdida auxiliar que alinea la trayectoria predicha con las demostraciones expertas mediante una extrapolación de Euler, evitando la deriva temporal sin añadir coste computacional en la inferencia.

Las evaluaciones empíricas confirman que KAN-We-Flow establece un nuevo estado del arte en tasas de éxito en los simuladores Adroit, Meta-World y DexArt. Logra estas mejoras con una reducción drástica del 86,8 % en el número de parámetros respecto a líneas base como DP3, y reduce el tiempo de inferencia en más de un 90 % (hasta los 8 ms), habilitando un control reactivo y en tiempo real esencial para la robótica moderna.

Multilevel Training for Kolmogorov Arnold Networks

Fecha: 6 de marzo de 2026 (Preprint arXiv:2603.04827v1)

Citación: Southworth, B. S., Actor, J. A., Harper, G., & Cyr, E. C. (2026). Multilevel Training for Kolmogorov Arnold Networks. *arXiv preprint arXiv:2603.04827*.

Área de aplicación: Machine Learning (Optimización y Entrenamiento)

Resumen:

La aceleración algorítmica del entrenamiento en arquitecturas neuronales comunes es sumamente difícil debido a la falta de estructura garantizada por las composiciones de funciones inherentes a dichas redes. A diferencia de los métodos numéricos clásicos para resolver ecuaciones diferenciales parciales (PDEs), donde los métodos multinivel y multigrilla (multigrid) logran resolver sistemas en tiempo lineal, los intentos de aplicar estas ideas a los perceptrones multicapa (MLP) no han logrado mejoras algorítmicas reales en la velocidad. Esto se debe principalmente a la dificultad matemática de definir representaciones gruesas de un modelo de aprendizaje automático y operadores de transferencia que no deshagan el progreso del entrenamiento.

Para superar esta barrera, los autores explotan la estructura inherente de las redes de Kolmogorov-Arnold (KAN). En primer lugar, establecen una equivalencia matemática rigurosa entre las redes KAN que utilizan funciones base spline y los MLP multicanal con activaciones ReLU de tipo potencia, lograda a través de un cambio de base lineal. Demuestran que este cambio de base lineal entre las dos arquitecturas coincide exactamente con una discretización por diferencias finitas del operador derivativo sobre los nodos (knots) del spline.

Basándose en este cambio de base, los investigadores desarrollan un enfoque de entrenamiento multinivel para las redes KAN. Entrenan una secuencia de redes definidas de forma natural a través de un refinamiento uniforme de los nodos del spline, utilizando operadores de interpolación geométrica analítica entre los modelos. Este esquema de interpolación

permite crear una "jerarquía adecuadamente anidada" (properly nested hierarchy), asegurando que la interpolación hacia un modelo fino preserve el progreso realizado en los modelos gruesos, mientras que el soporte compacto de las funciones spline garantiza una optimización complementaria en los niveles subsiguientes.

Los experimentos numéricos demuestran que este enfoque de entrenamiento multinivel puede lograr mejoras de varios órdenes de magnitud tanto en precisión como en eficiencia frente a los métodos convencionales para entrenar redes KAN o MLP comparables. Este rendimiento es especialmente notable en la aplicación de redes neuronales informadas por la física (PINNs), demostrando que un diseño estructurado de la red neuronal permite habilitar algoritmos multinivel que mejoran drásticamente el rendimiento del entrenamiento.

KAN-Dreamer: Benchmarking Kolmogorov-Arnold Networks as Function Approximators in World Models

Fecha: 2026 (Preprint)

Citación: Shi, C., & Luan, X. (2026). KAN-Dreamer: Benchmarking Kolmogorov-Arnold Networks as Function Approximators in World Models. *Preprint*.

Área de aplicación: Aprendizaje por Refuerzo (Modelos de Mundo)

Resumen:

Los modelos de mundo (World Models) como DreamerV3 representan el estado del arte en algoritmos de aprendizaje por refuerzo basado en modelos (MBRL), logrando una alta eficiencia de muestra al aprender comportamientos dentro de un modelo de mundo latente. Sin embargo, estos marcos dependen casi exclusivamente de arquitecturas MLP y CNN tradicionales. Aunque las redes de Kolmogorov-Arnold (KAN) han surgido como una alternativa con mayor eficiencia de parámetros e interpretabilidad, sus implementaciones originales sufren de una latencia de inferencia prohibitiva y sobrecarga computacional. Queda por demostrar si las variantes eficientes de KAN pueden sustituir a los MLP en la dinámica latente de alta dimensionalidad sin degradar la velocidad de generación de trayectorias imaginadas ni la eficiencia de muestra del agente.

Para investigar esta viabilidad, los autores introducen KAN-Dreamer, una arquitectura modificada que integra redes KAN en el marco de DreamerV3. El diseño desacopla la arquitectura en categorías funcionales, manteniendo el modelo de secuencia recurrente (GRU) intacto para asegurar la estabilidad, pero sustituyendo los componentes de predicción de retroalimentación (Feed-forward). Específicamente, reemplazan las capas densas en la Percepción Visual (Encoder/Decoder), la Predicción Latente (predictores de Recompensa y Continuación) y el Aprendizaje de Comportamiento (Actor/Crítico) por capas KAN y su variante acelerada, FastKAN, la cual utiliza funciones de base radial (RBF) gaussianas.

Para garantizar la viabilidad computacional dentro del entorno de World Models basado en JAX (el framework de DreamerV3), los investigadores desarrollan una implementación de FastKAN totalmente vectorizada. A diferencia de las redes KAN originales, simplifican la gestión de la cuadrícula utilizando rejillas uniformes fijas en lugar de actualizaciones adaptativas dependientes de los datos, lo cual estabiliza el flujo de gradientes durante el aprendizaje por refuerzo en línea. Esta vectorización empaqueta los coeficientes en

tensores monolíticos, maximizando la utilización de la GPU mediante operaciones *einsum* sin flujos de control condicionales.

Las evaluaciones empíricas en la suite de control de DeepMind (tarea `walker_walk`) demuestran que el uso de FastKAN adaptado como reemplazo directo de los predictores de Recompensa y Continuación alcanza un rendimiento a la par con la arquitectura original basada en MLP. El modelo KAN-Dreamer logra mantener la misma eficiencia de muestra y velocidad de entrenamiento (wall-clock time), proporcionando la primera evidencia empírica sólida de que las variantes eficientes de KAN son viables y competitivas para el aprendizaje de representaciones complejas en sistemas avanzados de RL.

KANDy: Kolmogorov-Arnold Networks and Dynamical Systems

Fecha: 2025 (Preprint)

Citación: [Autores de KANDy]. (2025). KANDy: Kolmogorov-Arnold Networks and Dynamical Systems. *arXiv preprint*.

Área de aplicación: Sistemas Dinámicos y Ecuaciones Diferenciales

Resumen:

El descubrimiento de modelos basados en datos para sistemas dinámicos no lineales es un problema inverso complejo. El objetivo es deducir las ecuaciones gobernantes (el campo vectorial subyacente) a partir de series temporales observadas. Los métodos tradicionales de identificación dispersa, como SINDy, son altamente interpretables pero fracasan cuando la dinámica del sistema no cumple con requisitos estrictos de dispersión. Por el contrario, los enfoques basados en redes neuronales profundas (MLP o RNN) actúan como cajas negras; aproximan la trayectoria con precisión, pero no ofrecen ninguna información analítica sobre los mecanismos físicos o matemáticos que generan los datos.

Para superar esta dicotomía, los autores presentan el marco KANDy, que integra las redes de Kolmogorov-Arnold (KAN) en el modelado de sistemas dinámicos. En lugar de utilizar una red neuronal tradicional para aprender el mapeo de transición de estados, KANDy emplea la arquitectura KAN para aproximar directamente la función continua del campo vectorial $dx/dt = G(x)$. Esta formulación matemática aprovecha el teorema de representación de Kolmogorov-Arnold para descomponer la función multivariante del sistema en una suma de funciones continuas univariantes.

El núcleo del modelo reemplaza las combinaciones lineales densas y las funciones de activación estáticas por funciones B-spline parametrizadas y aprendibles en los bordes de la red. Mediante la aplicación de técnicas de regularización dispersa durante el entrenamiento, KANDy logra podar las conexiones irrelevantes. Posteriormente, aplica algoritmos de regresión simbólica sobre las funciones univariantes retenidas, lo que permite traducir la red entrenada directamente en expresiones algebraicas legibles por humanos que describen la evolución del sistema.

Las evaluaciones empíricas demuestran que KANDy es capaz de reconstruir con éxito las ecuaciones gobernantes de sistemas canónicos complejos, incluyendo atractores caóticos. El modelo logra capturar comportamientos dinámicos que no poseen una estructura dispersa estricta, ofreciendo una precisión predictiva comparable a los enfoques de aprendizaje profundo de caja negra, pero proporcionando la interpretabilidad matemática exacta

que los físicos y matemáticos necesitan para comprender la dinámica subyacente.

Research Directions on Kolmogorov–Arnold Networks: A Comprehensive Review

Fecha: Enero de 2026 (Publicado en *Symmetry* - MDPI)

Citación: [Autores del Review]. (2026). Research Directions on Kolmogorov–Arnold Networks: A Comprehensive Review. *Symmetry*, 18(1), 60.

Área de aplicación: Teoría de Machine Learning (Revisión Sistemática)

Resumen:

Desde su reciente popularización, la literatura sobre las redes de Kolmogorov–Arnold (KAN) ha experimentado un crecimiento exponencial. Aunque se han posicionado como una alternativa matemáticamente rigurosa y explicable frente a los perceptrones multicapa (MLP), la rápida proliferación de variantes arquitectónicas y aplicaciones ha fragmentado el campo. Para los investigadores y profesionales de la ciencia de datos, resulta cada vez más difícil rastrear las limitaciones teóricas reales, comprender las diferencias matemáticas entre las distintas topologías propuestas y determinar en qué dominios estas redes superan genuinamente a los modelos de aprendizaje profundo tradicionales.

Para estructurar este panorama, el artículo proporciona una taxonomía exhaustiva y una revisión sistemática del estado del arte de las redes KAN. El estudio comienza diseccionando el mecanismo de aproximación fundamental, contrastando cómo los MLP utilizan capas anidadas de combinaciones lineales seguidas de no linealidades fijas, mientras que las KAN implementan explícitamente la descomposición de Kolmogorov–Arnold sumando composiciones de funciones univariadas parametrizadas de forma adaptativa.

A continuación, la revisión categoriza los avances arquitectónicos más críticos, analizando variantes que buscan mitigar los cuellos de botella computacionales originales (como Fast-KAN o ChebyKAN). El documento cartografía el éxito de estas topologías en diversas aplicaciones científicas de alta complejidad, destacando su rendimiento superior o comparable en la resolución de ecuaciones diferenciales parciales (PDEs), donde ofrecen una convergencia mejorada y permiten una cuantificación de incertidumbre tratable, así como en la previsión de series temporales para sistemas de potencia y monitorización ambiental.

Como conclusión, el documento funciona como una hoja de ruta estratégica para futuras investigaciones. Si bien confirma que las redes KAN representan un salto cualitativo hacia una inteligencia artificial inherentemente interpretable y paramétricamente eficiente, advierte sobre desafíos críticos no resueltos. Específicamente, señala que la inestabilidad en la extensión de las cuadrículas dinámicas y la actual falta de optimización a nivel de hardware (paralelización en GPU) son barreras técnicas primordiales que la comunidad debe superar para que las KAN puedan escalar al nivel de los modelos fundacionales masivos actuales.

CLAK: CNN-LSTM-Attention and Kolmogorov-Arnold Networks for UAV Localization

Fecha: 2026 (Preprint)

Citación: [Autores de CLAK]. (2026). CLAK: CNN-LSTM-Attention and Kolmogorov-Arnold Networks for UAV Localization. *arXiv preprint*.

Área de aplicación: Robótica y Navegación (Localización de UAVs)

Resumen:

La localización precisa de vehículos aéreos no tripulados (UAVs) en entornos donde la señal GPS está denegada o fuertemente interferida es un problema de estimación de estado no lineal muy complejo. Los sistemas de navegación inercial y los enfoques de fusión multisensor tradicionales acumulan errores de deriva (*drift*) con el tiempo. Por su parte, los modelos de aprendizaje profundo existentes que intentan mapear señales de radiofrecuencia o datos inerciales a coordenadas espaciales suelen carecer de la flexibilidad necesaria para adaptarse a las trayectorias de vuelo altamente dinámicas y al ruido estocástico del entorno.

Para resolver este desafío de aproximación de funciones, los investigadores proponen la arquitectura CLAK (CNN-LSTM-Attention-KAN). La primera fase del pipeline procesa las matrices de datos multisensor sin procesar. Se utiliza una Red Neuronal Convolutiva (CNN) unidimensional para extraer características espaciales locales de las señales, seguida de una red de Memoria a Corto y Largo Plazo (LSTM) que modela la evolución temporal y la cinemática de la trayectoria del dron. A esto se le suma un mecanismo de atención que pondera dinámicamente los tensores de características, mitigando el impacto de los sensores ruidosos o anómalos.

La innovación algorítmica central ocurre en la etapa de regresión final. En lugar de colapsar las características espaciotemporales extraídas utilizando perceptrones multicapa (MLP) convencionales, el modelo introduce una capa de redes de Kolmogorov-Arnold (KAN). Al parametrizar funciones univariantes continuas (B-splines) en los bordes de la red, el módulo KAN realiza un mapeo altamente no lineal y matemáticamente expresivo desde el espacio latente de características hasta el espacio de coordenadas tridimensionales (x, y, z) del UAV.

Los experimentos realizados utilizando conjuntos de datos de vuelo simulados y reales demostraron que la arquitectura CLAK reduce significativamente el Error Cuadrático Medio (MSE) en la estimación de la posición tridimensional en comparación con arquitecturas base como CNN-LSTM estándar. La sustitución de las capas densas por capas KAN no solo mejoró la robustez del modelo frente a la pérdida de señal, sino que también optimizó la eficiencia de parámetros, facilitando una inferencia de menor latencia fundamental para el control de vuelo en tiempo real.

KAN for Anomaly Detection: Unsupervised Complex Pattern Recognition

Fecha: 2026 (Preprint)

Citación: [Autores del paper KAN-Anomaly]. (2026). Kolmogorov-Arnold Networks for

Anomaly Detection. *arXiv preprint*.

Área de aplicación: Ciberseguridad y Mantenimiento Predictivo (Detección de Anomalías)

Resumen:

La detección de anomalías no supervisada asume un papel crítico en la monitorización de sistemas industriales y redes informáticas, donde la escasez de etiquetas de fallos hace inviable el aprendizaje supervisado. El enfoque estándar utiliza Autoencoders (AE) basados en perceptrones multicapa (MLP) para comprimir y reconstruir los datos, utilizando el error de reconstrucción como indicador de anomalía. Sin embargo, los AE tradicionales a menudo sufren del problema de la "función identidad" generalizando en exceso; es decir, su excesiva capacidad les permite reconstruir sorprendentemente bien incluso las muestras anómalas, lo que incrementa peligrosamente la tasa de falsos negativos.

Para restringir esta sobregeneralización geométrica, los autores introducen el Autoencoder basado en redes de Kolmogorov-Arnold (KAN-AE). Este modelo reestructura por completo el codificador y el decodificador, eliminando las matrices de pesos lineales estáticas. En su lugar, proyecta los datos de entrada hacia la variedad latente (*latent manifold*) utilizando funciones spline acotadas y aprendibles en las conexiones de la red. Esta formulación obliga al modelo a aprender una representación mucho más ajustada y específica de la distribución de los datos normales.

El mecanismo de control subyacente radica en la regularización intrínseca de las KAN. Al optimizar las funciones univariadas, el modelo KAN-AE penaliza la complejidad innecesaria en la topología de la red mediante técnicas de dispersión (*sparsification*). Esto asegura que el espacio latente retenga únicamente las varianzas fundamentales de las operaciones del sistema normal, haciendo que el decodificador sea matemáticamente incapaz de interpolar y reconstruir correctamente vectores de características que provengan de distribuciones anómalas u hostiles.

La validación empírica en conjuntos de datos de referencia (como NSL-KDD para intrusiones en red y turbinas para series temporales industriales) confirmó la superioridad del enfoque. KAN-AE amplió significativamente el margen ortogonal entre las puntuaciones de error de reconstrucción de las muestras normales y las anómalas, mejorando el Área Bajo la Curva (AUC-ROC) en más de un 8 % respecto a los autoencoders profundos tradicionales, y ofreciendo una trazabilidad funcional que permite identificar exactamente qué variables desencadenaron la alerta.

SINDy-KANs: Sparse Identification of Nonlinear Dynamics via Kolmogorov-Arnold Networks

Fecha: Marzo de 2026 (Preprint arXiv:2603.18548v1)

Citación: [Autores de SINDy-KANs]. (2026). SINDy-KANs: Sparse Identification of Nonlinear Dynamics via Kolmogorov-Arnold Networks. *arXiv preprint arXiv:2603.18548*.

Área de aplicación: Sistemas Dinámicos y Ecuaciones Diferenciales

Resumen:

El algoritmo SINDy (Identificación Dispersa de Dinámicas No Lineales) es el estándar

actual para descubrir las ecuaciones diferenciales que gobiernan un sistema a partir de datos empíricos. Sin embargo, su éxito depende críticamente de la elección de una biblioteca predefinida de funciones candidatas (polinomios, senos, cosenos). Si la verdadera dinámica del sistema contiene términos analíticos que no están presentes en el diccionario inicial del investigador, la regresión dispersa fracasa al intentar aproximar la función, lo que limita severamente su aplicación en sistemas físicos desconocidos.

Para superar esta dependencia de bibliotecas fijas, los autores formulan SINDy-KAN, una arquitectura que fusiona la regresión dispersa con el teorema de representación de Kolmogorov-Arnold. En lugar de proyectar los datos sobre un diccionario preconstruido de términos rígidos, el modelo utiliza las funciones univariadas (B-splines) en las aristas de una red KAN para aprender de forma adaptativa y dinámica la base funcional óptima directamente desde la matriz de datos de estado del sistema.

Durante el proceso de optimización empírica, la arquitectura aplica una penalización de regularización dispersa (norma L_1) sobre los coeficientes de los splines. Este mecanismo de poda estructural fuerza a la red a colapsar las conexiones redundantes, reteniendo únicamente las transformaciones no lineales que dictan verdaderamente la evolución temporal del sistema. Posteriormente, se aplica regresión simbólica sobre los splines supervivientes para extraer las expresiones matemáticas exactas.

Los resultados numéricos en sistemas caóticos de referencia (como el atractor de Lorenz y ecuaciones de reacción-difusión) demuestran que SINDy-KAN reconstruye las ecuaciones gobernantes con un error paramétrico cercano a cero. Al sustituir la biblioteca discreta por una red continua de aproximadores universales univariados, el modelo supera ampliamente al SINDy clásico frente a dinámicas exóticas o racionales, estableciendo un nuevo paradigma de descubrimiento científico autónomo.

Kolmogorov-Arnold Causal Generative Models

Fecha: 2026 (Preprint)

Citación: [Autores del Modelo Generativo Causal]. (2026). Kolmogorov-Arnold Causal Generative Models. *arXiv preprint*.

Área de aplicación: Inferencia Causal y Modelos Generativos Profundos

Resumen:

La inferencia causal y el modelado generativo profundo buscan comprender y simular los mecanismos de generación de datos en sistemas complejos. Los modelos causales estructurales (SCM) tradicionales imponen fuertes restricciones paramétricas (como linealidad o ruido aditivo) que no reflejan la realidad. Por otro lado, los flujos normalizadores (Normalizing Flows) basados en redes neuronales densas capturan transformaciones altamente no lineales, pero carecen de interpretabilidad causal y sufren un inmenso cuello de botella computacional ($O(D^3)$) al calcular el determinante del Jacobiano necesario para la estimación exacta de la verosimilitud (log-likelihood).

Para abordar esta incompatibilidad matemática, la investigación introduce un modelo generativo causal fundamentado en las redes de Kolmogorov-Arnold. La arquitectura reemplaza los perceptrones multicapa (MLP) dentro de las capas de flujo autorregresivo por

redes KAN. Al asignar funciones univariadas continuas a los bordes del grafo computacional, el modelo aprende los mecanismos causales subyacentes entre las variables (nodos) sin imponer distribuciones predefinidas restrictivas.

La principal ventaja matemática de esta topología radica en la tratabilidad analítica de las derivadas. Dado que las redes KAN se basan en sumas de funciones de una sola variable, el cálculo de la matriz Jacobiana se vuelve estricta y algorítmicamente disperso. Esto permite calcular el determinante del Jacobiano en tiempo lineal $O(D)$, habilitando el entrenamiento mediante máxima verosimilitud exacta sin recurrir a aproximaciones estocásticas o topologías de acoplamiento afín que limitan la expresividad del flujo generativo.

La evaluación sobre redes bayesianas sintéticas y conjuntos de datos observacionales biomédicos confirmó que el modelo superó a los enfoques generativos causales de caja negra existentes. Logró identificar la dirección causal correcta con una precisión superior al 94 % y generar datos contrafactuales de altísima fidelidad. Fundamentalmente, extrajo ecuaciones estructurales transparentes, demostrando que las redes KAN son el puente definitivo entre el poder de los modelos generativos profundos y el rigor de la inferencia causal estructural.
