

# Estado del Arte: Physics-Informed Neural Networks (PINNs) y SciML

Ricardo Luis Urretxo Riofrancos

23 de agosto de 2026

## Índice

|                                                                                                                                                                        |           |
|------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------|
| <b>1. Mecánica de Fluidos y Sólidos</b>                                                                                                                                | <b>3</b>  |
| 1.1. Critical evaluation of PINN for FWD inverse analysis and differentiable FEM as an alternative . . . . .                                                           | 3         |
| 1.2. Parametrised PINNs for Water Infiltration in Unsaturated Soils . . . . .                                                                                          | 3         |
| 1.3. A MIXED-FORM PINNS (MF-PINNS) FOR SOLVING THE COUPLED STOKES-DARCY EQUATIONS . . . . .                                                                            | 4         |
| 1.4. Error Analysis of Tr-PINNs Algorithm for 2D Incompressible Navier-Stokes Equations with Non-Homogeneous Boundary Conditions . . . . .                             | 5         |
| 1.5. Physics-Informed Neural Network for Diffusion-Reaction Problems with Dead-Core Formation in Catalyst Slabs . . . . .                                              | 6         |
| 1.6. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations . . . . . | 7         |
| 1.7. Nonlinear multi-field coupling analysis of piezoelectric semiconductors via PINNs . . . . .                                                                       | 8         |
| 1.8. A PINNs-XGBoost integrated framework for offshore monopile deformation prediction . . . . .                                                                       | 9         |
| 1.9. Comparison of Physics-Informed Neural Networks (PINNs) and Experimental Reality in Fluid Viscosity Dynamics . . . . .                                             | 10        |
| <b>2. Termodinámica y Cinética</b>                                                                                                                                     | <b>11</b> |
| 2.1. Physics-Informed Deep Learning for Entropy Prediction in Heterogeneous Systems: Thermodynamic and Information-Theoretic Case Studies . . . . .                    | 11        |
| 2.2. Physics-Informed Neural Network for Diffusion-Reaction Problems with Dead-Core Formation in Catalyst Slabs . . . . .                                              | 12        |
| 2.3. PINN and KANN approaches for shell structures: sampling strategies and experimental analysis . . . . .                                                            | 12        |
| 2.4. Uncovering Turbulent Dynamics in Stenotic Flows from 4D-flow MRI Measurements via Resolvent Analysis and Data Assimilation . . . . .                              | 13        |
| 2.5. Nordgren PINNs to VQE: Advancing Hydraulic Fracturing Simulations in Shale Reservoirs . . . . .                                                                   | 14        |
| 2.6. The Use of PINN in Modeling of Thermoelectric Modules . . . . .                                                                                                   | 15        |
| 2.7. HB-PINNs: A Heat-Balance Physics-Informed Framework for Building Energy Loading Forecasting with Limited Data . . . . .                                           | 16        |

|                                                                                                                                                     |           |
|-----------------------------------------------------------------------------------------------------------------------------------------------------|-----------|
| <b>3. Arquitecturas, Frameworks y Variantes de PINNs</b>                                                                                            | <b>17</b> |
| 3.1. PTL-PINNs: Perturbation-Guided Transfer Learning with Physics-Informed Neural Networks . . . . .                                               | 17        |
| 3.2. Advances on Model Merging for Physics-Informed Neural Networks . . . .                                                                         | 18        |
| 3.3. An improved PINN framework integrating localized adaptive sampling . .                                                                         | 19        |
| 3.4. Comparison of Trefftz-Based PINNs and Standard PINNs . . . . .                                                                                 | 19        |
| 3.5. PINNACLE: An Open-Source Computational Framework for Classical and Quantum PINNs . . . . .                                                     | 20        |
| 3.6. TS-PINNs: Physics-Informed Neural Networks in Temporal Sobolev Spaces                                                                          | 21        |
| 3.7. Interface PINNs (I-PINNs): A physics-informed neural networks framework for interface problems . . . . .                                       | 22        |
| <b>4. Otros y Teoría (Interpretabilidad, Análisis de Error y Fundamentos)</b>                                                                       | <b>23</b> |
| 4.1. Gradient Scaling Effects in Adaptive Spectral PINNs for Stiff Nonlinear ODEs . . . . .                                                         | 23        |
| 4.2. Deep Learning in Computational Mechanics: An Introductory Course (Second Edition) . . . . .                                                    | 24        |
| 4.3. DEFLATION-PINNS: LEARNING MULTIPLE SOLUTIONS FOR PDES AND LANDAU-DE GENNES . . . . .                                                           | 25        |
| 4.4. Physics Informed Deep Learning (Part I II): Data-driven Solutions and Discovery of Nonlinear Partial Differential Equations . . . . .          | 26        |
| 4.5. Physics-constrained deep learning for high-dimensional surrogate modeling and uncertainty quantification without labeled data . . . . .        | 27        |
| 4.6. Physics-Informed Deep Learning for Entropy Prediction in Heterogeneous Systems: Thermodynamic and Information-Theoretic Case Studies . . . . . | 28        |
| 4.7. Taming the Loss Landscape of PINNs with Noisy Feynman-Kac Supervision: Operator Preconditioning and Non-Asymptotic Error Bounds . . . . .      | 29        |
| 4.8. Reliable Error Estimation for PINNS: Lower and Upper A Posteriori Bounds                                                                       | 30        |
| 4.9. When PINNs Go Wrong: Pseudo-Time Stepping Against Spurious Solutions                                                                           | 30        |
| 4.10. Inferring solutions of differential equations using noisy multi-fidelity data .                                                               | 31        |

# 1. Mecánica de Fluidos y Sólidos

## 1.1. Critical evaluation of PINN for FWD inverse analysis and differentiable FEM as an alternative

**Fecha:** Junio de 2026 (Preprint arXiv)

**Citación:** Choi, Y., Moon, H., & Ryu, S. (2026). Critical evaluation of PINN for FWD inverse analysis and differentiable FEM as an alternative. *arXiv preprint arXiv:2606.03210*.

**Área de aplicación:** Geotecnia y Mecánica Estructural (Análisis Inverso FWD en Pavimentos)

### Resumen:

El análisis inverso de datos obtenidos mediante el deflectómetro de impacto (FWD) es crucial para estimar los módulos de elasticidad en sistemas de pavimentos multicapa. Tradicionalmente, este problema se resuelve utilizando métodos iterativos basados en el gradiente que dependen de aproximaciones por diferencias finitas (FD). La principal limitación de estos enfoques clásicos es su falta de escalabilidad y precisión, ya que requieren múltiples simulaciones computacionalmente costosas por cada capa del pavimento y sufren de errores de truncamiento severos al calcular el vector gradiente.

Para resolver esta deficiencia algorítmica, los autores evalúan el uso de Redes Neuronales Informadas por la Física (PINNs) estándar y extendidas (XPINN), y proponen como alternativa superior el Método de Elementos Finitos Diferenciable (DiffFEM). La innovación clave de DiffFEM radica en integrar el modelado directo de elementos finitos dentro de un marco de diferenciación automática (AD), lo que permite obtener gradientes exactos en una sola pasada hacia atrás manteniendo la física del problema como una restricción dura, en lugar de una función de pérdida suave como en las arquitecturas PINNs.

A nivel de implementación, el modelo DiffFEM ensambla la matriz de rigidez global parametrizada por las capas del pavimento y utiliza el optimizador L-BFGS para actualizar iterativamente los módulos elásticos basándose en la discrepancia de las deflexiones medidas por los sensores. Por su parte, la arquitectura XPINN requiere entrenar subredes independientes para cada capa del material y aplicar penalizaciones de continuidad en las interfaces, lo que resulta en una optimización altamente inestable al tener que equilibrar simultáneamente las pérdidas de datos, física e interfaz con más de 26.000 parámetros computacionales.

Los experimentos con datos sintéticos demostraron que la topología XPINN requiere cientos de miles de iteraciones y es muy sensible al ruido, logrando apenas aproximaciones con errores considerables en los límites de las capas del pavimento. Por el contrario, la arquitectura DiffFEM converge en apenas 40 iteraciones, logrando recuperar los módulos de elasticidad con errores relativos mínimos del orden de  $10^{-9}$ . El modelo demuestra que para problemas con discontinuidades de dominio severas, integrar la física de manera estricta supera cualitativa y cuantitativamente al modelado neuronal subrogado.

## 1.2. Parametrised PINNs for Water Infiltration in Unsaturated Soils

**Fecha:** 2026 (Preprint SSRN)

**Citación:** Gowely, M., & Yildiz, A. (2026). Parametrised PINNs for Water Infiltration in

**Resumen:**

La predicción de la infiltración de agua en suelos no saturados es esencial para modelar fenómenos hidrológicos y gestionar la agricultura. Tradicionalmente, este proceso se modela mediante la Ecuación de Richardson-Richards (RRE), una formulación elíptica-parabólica altamente no lineal. Los métodos numéricos clásicos presentan graves cuellos de botella computacionales al intentar resolver la RRE a gran escala, enfrentándose a problemas de conservación de masa y fallos de convergencia debidos a la estricta discretización espacial y temporal requerida en los frentes de humectación pronunciados.

Para superar la necesidad de mallas computacionales y generalizar el proceso predictivo, los investigadores proponen una Red Neuronal Informada por la Física Parametrizada (P-PINN). La innovación estructural fundamental de este framework consiste en expandir el espacio de entrada de la red para que no solo dependa de las coordenadas espacio-temporales, sino de un vector continuo de parámetros hidráulicos del suelo (porosidad, conductividad). Esto transforma el modelo de un aproximador de escenarios estáticos a un simulador universal capaz de generalizar sobre múltiples condiciones reológicas sin requerir reentrenamiento algorítmico.

En su funcionamiento interno, la P-PINN se entrena minimizando el residuo de la ecuación de RRE linealizada a través del modelo empírico de Gardner. Para combatir el fenómeno del sesgo espectral en gradientes pronunciados, la red implementa funciones de activación adaptativas por capa (L-LAAF con tangente hiperbólica) y estrategias de refinamiento adaptativo basadas en el residuo (RAR), además de una función de pérdida probabilística (PLF) que pondera dinámicamente las condiciones iniciales, de frontera y el residuo de la ecuación diferencial. El preprocesamiento incluye muestreo estocástico mediante secuencias de Sobol y normalización Z-score.

Las evaluaciones validaron la P-PINN frente a soluciones analíticas en múltiples escenarios que simulan dinámicas de raíces uniformes y suelo desnudo. El modelo logró una altísima precisión, superando un índice de Eficiencia de Nash-Sutcliffe (NSE) de 0,99 en casi todos los escenarios analizados, garantizando una estimación física estable. Aunque el coste inicial de entrenamiento es superior al de una PINN estándar (aumento de 2.3x en tiempo), la gran ventaja cualitativa radica en que la arquitectura permite la evaluación instantánea de infinitos escenarios hidráulicos, consolidándose como un sustituto universal sobresaliente frente a los costosos solucionadores tradicionales.

### 1.3. A MIXED-FORM PINNS (MF-PINNS) FOR SOLVING THE COUPLED STOKES-DARCY EQUATIONS

**Fecha:** Octubre de 2025 (Preprint arXiv)

**Citación:** Shan, L., & Shen, X. (2025). A MIXED-FORM PINNS (MF-PINNS) FOR SOLVING THE COUPLED STOKES-DARCY EQUATIONS. *arXiv preprint arXiv:2510.17508*.

**Área de aplicación:** Mecánica de Fluidos (Ecuaciones Acopladas Stokes-Darcy)

**Resumen:**

La simulación de flujos que interactúan entre zonas de paso libre y medios porosos se modela mediante el complejo sistema acoplado de ecuaciones de Stokes-Darcy y las con-

diciones de interfaz Beavers-Joseph-Saffman (BJS). El uso de Redes Neuronales Informadas por la Física (PINNs) estándar para abordar estas ecuaciones multiescala suele fallar estrepitosamente. La limitación estructural reside en que la presencia de constantes físicas extremas, como una viscosidad cinemática muy alta o una permeabilidad extremadamente baja, provoca un grave condicionamiento adverso en la función de pérdida, desatando una competencia de gradientes que estanca el entrenamiento o corrompe la variable de presión.

Para mitigar este desequilibrio numérico sin recurrir a discretizaciones matemáticas complejas, los autores proponen las Redes Neuronales Informadas por la Física de Forma Mixta (MF-PINNs). La innovación disruptiva radica en reformular y desacoplar analíticamente el sistema de ecuaciones original. En lugar de utilizar únicamente la forma tradicional de velocidad-presión (VP), la arquitectura incorpora de manera paralela la formulación de función de corriente-vorticidad (SV). Esto permite generar nuevas ecuaciones continuas donde la presión y la cinemática quedan rigurosamente separadas y equilibradas.

A nivel de implementación, el modelo MF-PINN ajusta dinámicamente los pesos dentro de una función de pérdida extendida, neutralizando la explosión geométrica de gradientes mediante la división por coeficientes derivados de los parámetros físicos restrictivos de viscosidad cinemática y permeabilidad. Además de la reformulación matemática, la topología explora la inserción de funciones de activación periódicas en la primera capa oculta (como funciones senoidales acopladas) durante el entrenamiento, desarrollando al mismo tiempo estrategias de atenuación de la tasa de aprendizaje para asentar la optimización final de los pesos.

Los resultados empíricos comprobaron el rendimiento del modelo frente a sistemas con tensores de viscosidad y permeabilidad que varían desde el abismal rango de  $10^{-4}$  hasta  $10^4$ . El modelo MF-PINN demostró una convergencia estable y sostenida donde las soluciones PINN convencionales divergían irreparablemente. El marco propuesto garantiza campos de presión y líneas de corriente precisas sin importar los saltos abruptos de escala entre dominios espaciales, ofreciendo una ventaja cualitativa rotunda al proporcionar una topología matemáticamente robusta para modelar flujos turbulentos acoplados y altamente caóticos.

#### 1.4. Error Analysis of Tr-PINNs Algorithm for 2D Incompressible Navier-Stokes Equations with Non-Homogeneous Boundary Conditions

**Fecha:** Junio de 2026 (Preprint arXiv)

**Citación:** Liu, D., Li, X., & Yang, R. (2026). Error Analysis of Tr-PINNs Algorithm for 2D Incompressible Navier-Stokes Equations with Non-Homogeneous Boundary Conditions. *arXiv preprint arXiv:2606.06268*.

**Área de aplicación:** Matemática Computacional y Mecánica de Fluidos (Análisis de Error Algorítmico)

##### Resumen:

La resolución analítica y computacional de las ecuaciones de Navier-Stokes para fluidos incompresibles en geometrías complejas requiere un cumplimiento inquebrantable de las condiciones de contorno. Las Redes Neuronales Informadas por la Física (PINNs) estándar

penalizan sistemáticamente las desviaciones en las fronteras aplicando una restricción matemática suave basada en la norma  $L^2$ . La limitación crítica de esta metodología canónica radica en que carece de garantías teóricas robustas en condiciones no homogéneas, lo que frecuentemente provoca simulaciones de frontera inexactas que degradan drásticamente la predicción física global de la red neuronal.

Para asegurar la rigurosidad matemática estructural y la precisión, los investigadores proponen la arquitectura Tr-PINNs. La mejora algorítmica fundamental de este modelo consiste en abandonar la métrica empírica  $L^2$  exclusiva para la evaluación de las condiciones de frontera, sustituyéndola por una evaluación informada directamente por el Teorema de Trazas matemático. Esto permite construir un término de error de frontera fundamentado estrictamente en la norma del espacio de Sobolev de orden fraccionario  $H^{1/2}$ , el cual acopla intrínsecamente la topología de la función de pérdida con las propiedades matemáticas reales de las soluciones débiles de las ecuaciones no lineales.

El desarrollo técnico se fundamenta en la redefinición absoluta de la función de error de generalización de la red neuronal. Durante el entrenamiento algorítmico, se aproxima la integral del error reforzado (que evalúa conjuntamente la divergencia de flujo y la traza) mediante procesos avanzados de integración de Montecarlo. De este modo metodológico, los pesos de la red son ajustados iterativamente minimizando los residuos de la ecuación de Navier-Stokes en el interior del dominio físico y la estricta restricción topológica de Sobolev en la frontera, asegurando el descenso estable del gradiente bajo un marco teóricamente blindado.

En la fase de evaluación, los autores aportan la demostración matemática empírica y la validación numérica en flujos 2D que certifica el correcto funcionamiento del modelo. Los resultados en experimentación respaldaron el teorema principal del estudio: restringir el problema resolutivo utilizando la norma de la traza garantiza que, a medida que la red minimiza la función de pérdida generalizada, la cota superior del error predictivo desciende de forma matemáticamente controlada. La red Tr-PINNs supera sistemáticamente en exactitud a las PINNs convencionales; confiriendo a la red predictiva una justificación analítica matemática innegable exigida en aplicaciones de alta fidelidad.

## 1.5. Physics-Informed Neural Network for Diffusion-Reaction Problems with Dead-Core Formation in Catalyst Slabs

**Fecha:** Mayo de 2026 (Preprint arXiv)

**Citación:** Skrzypacz, P., Tangirbergen, K., & Valdman, J. (2026). Physics-Informed Neural Network for Diffusion-Reaction Problems with Dead-Core Formation in Catalyst Slabs. *arXiv preprint arXiv:2606.02599*.

**Área de aplicación:** Cinética Química y Matemáticas Aplicadas (Reacciones de Difusión y Zonas Muertas)

### Resumen:

El modelado de procesos de difusión-reacción en placas catalizadoras a menudo presenta el fenómeno de "zona muerta" (dead-core), donde la concentración del reactivo cae exactamente a cero, generando un problema de frontera libre. Los métodos numéricos tradicionales, como los esquemas de diferencias finitas o los métodos de disparo (shooting methods), fracasan o resultan computacionalmente prohibitivos al intentar resolver este

problema, ya que requieren un seguimiento explícito de la interfaz y un mallado adaptativo extremadamente denso para lidiar con la singularidad matemática en el límite de la zona muerta.

Para solucionar esta rigidez computacional, los autores proponen un marco basado en Redes Neuronales Informadas por la Física (PINNs) diseñado específicamente para problemas de frontera libre. La innovación estructural fundamental consiste en incrustar el comportamiento asintótico cerca de la interfaz directamente en un *ansatz* o solución de prueba con restricciones duras. En lugar de rastrear la frontera mediante complejas mallas móviles, el modelo trata la ubicación de la zona muerta como un parámetro entrenable más dentro de la propia red neuronal.

A nivel técnico, la arquitectura se entrena minimizando el residuo del problema de valor de contorno no lineal de dos puntos, el cual está regido por una cinética de ley de potencias con orden de reacción fraccionario. La red optimiza simultáneamente los pesos que definen el perfil de concentración y el parámetro escalar que define la frontera libre. Al imponer analíticamente las condiciones de contorno mediante la estructura de la solución de prueba, se evita la competencia de gradientes en la función de pérdida y se acelera drásticamente la convergencia.

La evaluación empírica, validada frente a soluciones analíticas y métodos de disparo de alta precisión, demuestra que la PINN aproxima con éxito tanto el perfil de concentración como la ubicación exacta de la frontera libre. La principal ventaja cualitativa de este enfoque radica en su capacidad para resolver problemas de frontera móvil sin requerir un seguimiento explícito de la interfaz, consolidando a las PINNs como una herramienta excepcionalmente flexible para el diseño de reactores y la catálisis heterogénea.

## 1.6. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations

**Fecha:** 2019 (Publicado en *Journal of Computational Physics*)

**Citación:** Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2019). Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378, 686-707.

**Área de aplicación:** Machine Learning Científico (Resolución de Ecuaciones Diferenciales)

### Resumen:

La resolución de ecuaciones diferenciales parciales (PDEs) no lineales y la extracción de leyes físicas a partir de datos (problemas inversos) exigen tradicionalmente recursos computacionales masivos. Los métodos numéricos clásicos (como elementos finitos) fracasan al intentar asimilar datos ruidosos o dispersos, mientras que los modelos de aprendizaje profundo convencionales actúan como cajas negras que requieren volúmenes inmensos de datos etiquetados y son ciegos a las leyes físicas subyacentes, lo que les impide extrapolar o generalizar correctamente fuera de su dominio de entrenamiento.

Para derribar esta barrera y unificar el aprendizaje automático con la física matemática, los autores introducen la arquitectura fundacional de las Redes Neuronales Informadas por la Física (PINNs). La innovación disruptiva de este marco es la incorporación de las

ecuaciones diferenciales directamente en la función de pérdida de la red como restricciones matemáticas. Esto transforma a las redes neuronales de simples ajustadores de curvas en aproximadores universales de funciones que respetan de manera estricta las leyes de conservación, la termodinámica y la cinemática del sistema estudiado.

El funcionamiento interno del modelo se apoya en la diferenciación automática (AD) para calcular los gradientes exactos de las salidas de la red con respecto a las coordenadas espaciales y temporales, erradicando los errores de truncamiento propios de las mallas numéricas. Se proponen dos formulaciones: modelos de tiempo continuo para asimilar datos dispersos y modelos de tiempo discreto fundamentados en esquemas de Runge-Kutta. La red optimiza sus parámetros balanceando el error cuadrático medio de las mediciones disponibles con el residuo de la PDE, logrando entrenarse con cantidades ínfimas de datos.

Los experimentos exhaustivos aplicados a ecuaciones canónicas como Schrödinger, Burgers y Navier-Stokes demostraron un rendimiento sobresaliente tanto en la predicción de flujos como en el descubrimiento de parámetros físicos ocultos. El marco PINN logra inferir soluciones precisas y realizar asimilación de datos con una eficiencia paramétrica extraordinaria. Este artículo establece la ventaja cualitativa definitiva del campo: la creación de modelos subrogados totalmente diferenciables, sin necesidad de generación de mallas y con una interpretabilidad matemática inherente.

## 1.7. Nonlinear multi-field coupling analysis of piezoelectric semiconductors via PINNs

**Fecha:** Enero de 2026 (Publicado en *SCIENCE CHINA Physics, Mechanics & Astronomy*)

**Citación:** Xiao, Z., Weng, Y., Yao, W., Chen, W., & Zhang, C. (2026). Nonlinear multi-field coupling analysis of piezoelectric semiconductors via PINNs. *SCIENCE CHINA Physics, Mechanics & Astronomy*, 69(1), 214611.

**Área de aplicación:** Mecánica de Sólidos y Materiales (Semiconductores Piezoeléctricos)

### Resumen:

El modelado de los comportamientos mecánicos acoplados de térmico-deformación-polarización-transportador (TDPC) en semiconductores piezoeléctricos (PS) es un desafío físico altamente no lineal. Los métodos numéricos tradicionales y las arquitecturas PINN estándar sufren graves ineficiencias computacionales y problemas de convergencia al intentar resolver simultáneamente las intrincadas ecuaciones tridimensionales (3D), de placas y de vigas que rigen la respuesta multifísica de estos materiales inteligentes.

Para superar esta extrema complejidad acoplada, los autores proponen el marco DD-PINNs-TD (Data-Driven PINNs via Task-Decomposition). La innovación estructural radica en aplicar una estrategia algorítmica de descomposición de tareas que divide el problema multifísico global en subredes neuronales más manejables, incrustando las ecuaciones constitutivas específicas (3D, placa y viga) directamente como restricciones físicas separadas dentro del espacio de optimización.

A nivel de implementación, el modelo entrena tres topologías PINN representativas que procesan los campos acoplados de forma paralela. La arquitectura integra datos empíricos con los residuos de las ecuaciones diferenciales parciales rectoras, equilibrando la

retropropagación de los gradientes mediante pesos dinámicos para evitar que los términos térmicos o de polarización inestabilicen las variables de deformación mecánica durante el entrenamiento.

Los resultados numéricos demostraron que DD-PINNs-TD exhibe una superioridad abrumadora en eficiencia computacional y precisión respecto a las PINNs canónicas. El modelo logra predecir con extrema estabilidad las respuestas de acoplamiento TDPC bajo diversas cargas, confirmando que la descomposición de tareas es una estrategia cualitativamente superior para modelar sistemas multifísicos de alta dimensionalidad sin colapsar el optimizador.

## 1.8. A PINNs-XGBoost integrated framework for offshore monopile deformation prediction

**Fecha:** Diciembre de 2025 (Publicado en *Acta Mechanica Sinica*)

**Citación:** Li, B., Qi, W., Wang, S., Song, Q., & Gao, F. (2026). A PINNs-XGBoost integrated framework for offshore monopile deformation prediction. *Acta Mechanica Sinica*, 42, 451073.

**Área de aplicación:** Ingeniería Geotécnica y Marina (Deformación de Monopilotes Offshore)

### Resumen:

La predicción de la deformación lateral en monopilotes marinos es crítica para garantizar la estabilidad estructural de las turbinas eólicas offshore. Los modelos empíricos tradicionales de vigas (como las curvas p-y) pierden drásticamente su precisión al aumentar el diámetro del pilote, ya que ignoran comportamientos de contorno complejos como la resistencia en la base. Paralelamente, los modelos tridimensionales de Elementos Finitos (FEM) que sí capturan estos efectos resultan computacionalmente prohibitivos para el diseño iterativo a gran escala.

Para resolver esta dicotomía entre coste computacional y fidelidad física, los investigadores presentan un marco integrado PINNs-XGBoost. La innovación disruptiva consiste en fusionar la potencia predictiva de los algoritmos de árboles de decisión (XGBoost) para el modelado empírico del suelo, con la rigurosidad matemática de las PINNs para resolver la flexión estructural, incorporando de forma explícita la resistencia de la base en la frontera inferior del modelo unidimensional.

El desarrollo técnico opera en dos fases secuenciales interconectadas. Primero, el modelo XGBoost se entrena sobre un extenso conjunto de datos para reconstruir la distribución de los resortes no lineales del suelo a lo largo de la profundidad del pilote. Segundo, la PINN utiliza estas predicciones discretas basadas en datos como coeficientes dentro de la ecuación diferencial rectora de la viga, optimizando sus pesos para satisfacer simultáneamente la mecánica de la deformación estructural y las condiciones de contorno inferior.

La evaluación empírica demostró que este marco híbrido predice la deformación lateral con una precisión equiparable al FEM tridimensional, pero requiriendo una fracción minúscula de su tiempo de cálculo. La gran ventaja cualitativa de integrar XGBoost y PINNs es su capacidad para modelar conjuntamente pilotes flexibles y rígidos, capturando la compleja interacción no lineal suelo-estructura con un rigor termomecánico que los métodos

puramente basados en datos no pueden igualar.

## 1.9. Comparison of Physics-Informed Neural Networks (PINNs) and Experimental Reality in Fluid Viscosity Dynamics

**Fecha:** 2026 (Publicado en *Physics Communication*)

**Citación:** Septiana, E., Saefan, J., & Siswanto, J. (2026). Comparison of Physics-Informed Neural Networks (PINNs) and Experimental Reality in Fluid Viscosity Dynamics. *Physics Communication*, 10(1), 37-49.

**Área de aplicación:** Mecánica de Fluidos (Dinámica de Viscosidad y Modelado Experimental)

### Resumen:

La determinación de la viscosidad de fluidos mediante el método convencional de caída de esfera se enfrenta constantemente a variabilidades experimentales severas y limitaciones instrumentales que introducen ruido estocástico en las mediciones. Por otro lado, las soluciones analíticas clásicas (como el flujo de Stokes) asumen condiciones de contorno, geometría e incompresibilidad idealizadas que rara vez se cumplen en la realidad de un laboratorio, creando un margen de error significativo entre la teoría matemática y la observación empírica directa.

Para cerrar esta brecha analítica, el estudio propone el uso de Redes Neuronales Informadas por la Física (PINNs) como un puente algorítmico entre la cinemática teórica y los datos ruidosos del mundo real. A diferencia de un ajuste de curvas estadístico convencional, la arquitectura PINN incorpora la ecuación de movimiento (leyes de Newton y fricción viscosa) directamente en su topología neuronal, forzando a la red a generar un mapeo que respete los principios de conservación física sin importar el ruido de los sensores.

En la fase de implementación experimental, los investigadores recopilaron datos espaciotemporales utilizando un viscosímetro equipado con múltiples sensores infrarrojos. El modelo PINN fue entrenado minimizando una función de pérdida compuesta: equilibrando el error frente a los escasos datos experimentales de posición con el residuo derivado de la ecuación diferencial ordinaria que rige el descenso de la esfera a través del fluido viscoso.

Los resultados comparativos evidenciaron que el modelo PINN logra filtrar el ruido instrumental con éxito, prediciendo la velocidad de caída con una precisión superior a las soluciones analíticas puras de Stokes. La red demuestra una ventaja cualitativa clave: su capacidad para corregir idealizaciones teóricas extrayendo la dinámica viscosa real y subyacente directamente a partir de mediciones imperfectas.

## 2. Termodinámica y Cinética

### 2.1. Physics-Informed Deep Learning for Entropy Prediction in Heterogeneous Systems: Thermodynamic and Information-Theoretic Case Studies

**Fecha:** Mayo de 2026 (Preprint arXiv)

**Citación:** Sahoo, B., & Patra, D. (2026). Physics-Informed Deep Learning for Entropy Prediction in Heterogeneous Systems: Thermodynamic and Information-Theoretic Case Studies. *arXiv preprint arXiv:2606.01179*.

**Área de aplicación:** Termodinámica y Econofísica (Predicción de Entropía y Machine Learning Científico)

#### Resumen:

El cálculo de la entropía es un indicador fundamental para medir la irreversibilidad en termodinámica y la incertidumbre en la teoría de la información. La inmensa mayoría de las Redes Neuronales Informadas por la Física (PINNs) actuales se diseñan para dominios muy específicos, resolviendo ecuaciones diferenciales aisladas (como los balances de masa en un reactor CSTR o la ecuación de Fokker-Planck para la volatilidad financiera). La limitación crítica de estos enfoques tradicionales es que ignoran la posibilidad de extraer representaciones latentes invariantes de la entropía a través de sistemas físicos heterogéneos, y suelen depender de funciones de pérdida "suaves" para penalizar violaciones físicas, lo cual provoca fallos catastróficos y predicciones termodinámicamente imposibles en condiciones adversas.

Para unificar estos dominios, los autores proponen el marco Physics-Informed Deep Learning (PIDL) para sistemas heterogéneos. La innovación estructural clave es una arquitectura de codificador compartido (*shared-encoder*) con decodificadores específicos de dominio, permitiendo procesar simultáneamente restricciones físicas dispares. Para erradicar los fallos de las penalizaciones suaves, el modelo implementa una restricción topológica dura utilizando una función de activación *Softplus* en la capa de salida termodinámica, garantizando por construcción una tasa de generación de entropía estrictamente no negativa.

El desarrollo técnico se fundamenta en minimizar una función de pérdida multiobjetivo que equilibra la fidelidad a los datos con los residuos de las ecuaciones diferenciales (ODEs para el reactor y PDEs para el mercado financiero) y las condiciones de contorno. Para evitar que los gradientes de dominios tan distintos interfieran negativamente durante el entrenamiento, se emplea un mecanismo de proyección de gradientes. Además, el modelo realiza un análisis geométrico *post-hoc* de la superficie de entropía aprendida utilizando la métrica tensorial de Ruppeiner, cuya curvatura permite identificar instabilidades termodinámicas.

Los resultados empíricos demostraron que el modelo PIDL mantiene más del 90 % de su precisión predictiva utilizando apenas un 30 % de los datos de entrenamiento. Mientras los modelos base sufrieron violaciones transitorias de la Segunda Ley de la Termodinámica, la arquitectura con restricción *Softplus* mantuvo un cumplimiento físico absoluto. Cualitativamente, el estudio confirma que la entropía posee una representación latente transferible entre dominios distintos y demuestra que las restricciones arquitectónicas duras son esenciales para modelar sistemas físicos de alta criticidad.

## 2.2. Physics-Informed Neural Network for Diffusion-Reaction Problems with Dead-Core Formation in Catalyst Slabs

**Fecha:** Mayo de 2026 (Preprint arXiv)

**Citación:** Skrzypacz, P., Tangirbergen, K., & Valdman, J. (2026). Physics-Informed Neural Network for Diffusion-Reaction Problems with Dead-Core Formation in Catalyst Slabs. *arXiv preprint arXiv:2606.02599*.

**Área de aplicación:** Cinética Química y Matemáticas Aplicadas (Reacciones de Difusión y Zonas Muertas)

### Resumen:

El modelado de procesos de difusión-reacción en placas catalizadoras a menudo presenta el fenómeno de "zona muerta" (*dead-core*), donde la concentración del reactivo cae exactamente a cero, generando un complejo problema de frontera libre. Los métodos numéricos tradicionales, como los esquemas de diferencias finitas o los métodos de disparo (*shooting methods*), fracasan o resultan computacionalmente ineficientes al intentar resolver este problema, ya que el término de reacción no lineal no es diferenciable en el límite de la zona muerta, exigiendo mallas dinámicas extremadamente densas para rastrear la interfaz.

Para solucionar esta rigidez algorítmica, los autores proponen un marco basado en Redes Neuronales Informadas por la Física (PINNs) diseñado para evadir el rastreo explícito de la frontera. La innovación estructural fundamental consiste en integrar un *ansatz* (solución de prueba) estructurado como una restricción dura dentro de la arquitectura de la red. Este *ansatz* incrusta explícitamente el comportamiento asintótico local (ley de potencias) cerca de la interfaz, asegurando que las condiciones de contorno se cumplan estrictamente por construcción topológica, en lugar de aproximarse en la función de pérdida.

A nivel técnico, el dominio espacial original se transforma para mapear la región activa en un intervalo computacional fijo, y la ubicación desconocida de la zona muerta ( $x_{dz}$ ) se incorpora como un parámetro entrenable de la red, acotado mediante una función sigmoide. La optimización se realiza en dos fases (Adam para convergencia rápida y L-BFGS para refinamiento exacto), minimizando exclusivamente el residuo de la ecuación diferencial. Para capturar las variaciones bruscas de la interfaz, el modelo utiliza un muestreo de colocación sesgado (*biased sampling*) que concentra la densidad de puntos cerca del límite de la zona muerta.

Validado frente a soluciones analíticas y numéricas de alta precisión, la red PINN aproxima con rotundo éxito tanto el perfil de concentración (con un error  $L^2$  cercano a  $10^{-6}$ ) como la ubicación exacta de la frontera libre (error absoluto de  $\sim 5 \times 10^{-5}$ ). La principal ventaja cualitativa de esta topología es su capacidad para resolver problemas de fronteras móviles integrando el conocimiento asintótico físico directamente en la estructura neuronal, superando drásticamente las limitaciones de malla de los métodos convencionales con un coste de entrenamiento mínimo.

## 2.3. PINN and KANN approaches for shell structures: sampling strategies and experimental analysis

**Fecha:** Noviembre de 2025 (Publicado en *XLVI CILAMCE*)

**Citación:** Rodrigues, F. V. B., Macedo, L. F. A., & Pimenta, P. M. (2025). PINN and KANN approaches for shell structures: sampling strategies and experimental analysis.

**Área de aplicación:** Mecánica Computacional y Estructural (Estructuras de Lámina / Shell Structures)

**Resumen:**

El modelado de estructuras de lámina delgada (*thin shells*) presenta desafíos críticos en ingeniería. Los métodos numéricos tradicionales, como el Método de Elementos Finitos (FEM), sufren del fenómeno de bloqueo numérico (*locking*) y exigen un diseño meticuloso de las funciones de forma acoplado a calibración experta. Aunque las Redes Neuronales Informadas por la Física (PINNs) estándar ofrecen una alternativa sin mallas, dependen de perceptrones multicapa (MLP) que requieren una enorme cantidad de parámetros, adolecen de sesgo espectral y carecen de interpretabilidad analítica para la mecánica de sólidos.

Para superar estas deficiencias de parametrización, los autores evalúan y comparan las PINNs convencionales frente a las Redes de Kolmogorov-Arnold (KANs). La innovación arquitectónica de las KAN-PINNs consiste en reemplazar las funciones de activación estáticas en los nodos por funciones base aprendibles (B-splines) ubicadas en las aristas de la red. Este cambio topológico busca reducir drásticamente el recuento de parámetros y alinear el proceso de aproximación neuronal con la rigurosa teoría de aproximación numérica clásica.

A nivel técnico, ambos frameworks descartan la formulación fuerte en favor de la forma débil de las ecuaciones de lámina de Naghdi, minimizando la energía potencial total (energía de membrana, flexión y cortante) sin requerir derivadas de alto orden. El entrenamiento se realiza de forma puramente no supervisada, utilizando estrategias de muestreo de baja discrepancia (secuencias de Sobol y Hammersley) para generar los puntos de colocación. Esta técnica garantiza una cobertura espacial casi uniforme del dominio de referencia sin necesidad de costosos esquemas adaptativos.

Los experimentos sobre el estricto problema de referencia del techo de Scordelis-Lo revelaron resultados mecánicos contraintuitivos: las PINNs estándar lograron una convergencia más rápida, estable y con menores errores  $L^2$  que las redes KAN, a pesar de poseer más parámetros. Las KANs mostraron una capacidad de representación limitada en esta configuración, sufriendo mayores errores finales. La ventaja cualitativa del estudio es demostrar empíricamente que, aunque las KANs prometen una parametrización compacta, las PINNs clásicas (optimizadas con muestreo de Hammersley) siguen siendo computacionalmente superiores y más robustas para resolver la compleja física estructural.

## **2.4. Uncovering Turbulent Dynamics in Stenotic Flows from 4D-flow MRI Measurements via Resolvent Analysis and Data Assimilation**

**Fecha:** Junio de 2026 (Preprint arXiv)

**Citación:** Villié, A., Dillinger, H., Schmitter, S., Demange, S., & Oberleithner, K. (2026). Uncovering Turbulent Dynamics in Stenotic Flows from 4D-flow MRI Measurements via Resolvent Analysis and Data Assimilation. *arXiv preprint arXiv:2606.03838*.

**Área de aplicación:** Mecánica de Fluidos y Dinámica Cardiovascular (Flujos Estenóticos y Asimilación de Datos)

**Resumen:**

La caracterización de la hemodinámica en las estenosis arteriales es vital para comprender la progresión de enfermedades cardiovasculares. La resonancia magnética de flujo 4D (4D-flow MRI) permite medir campos de velocidad tridimensionales de forma no invasiva, pero sufre de severos límites de resolución que le impiden capturar las escalas turbulentas reales. Además, el retraso en la codificación de la señal introduce un grave "artefacto de desplazamiento" (errores de registro espacial) que corrompe los datos; los métodos convencionales de corrección solo operan en flujos laminares estacionarios, fracasando estrepitosamente en entornos cardiovasculares turbulentos.

Para rescatar la fidelidad física de estas mediciones clínicas, los investigadores proponen un marco híbrido experimental y computacional impulsado por una Red Neuronal Informada por la Física (PINN). La innovación central es diseñar una estrategia de optimización y asimilación de datos en dos etapas. En lugar de intentar un ajuste directo y propenso a mínimos locales, el sistema purga primeramente el artefacto de desplazamiento de los datos ruidosos y, posteriormente, extrae los campos medios ocultos para alimentar un análisis de estabilidad lineal y de resolvente.

En la primera etapa del desarrollo técnico, la red asimila un campo de velocidad media libre de divergencia, excluyendo los puntos de datos sesgados de alta velocidad e imponiendo la conservación exacta del caudal másico. En la segunda etapa, la PINN congela este campo de velocidad corregido y asimila la presión media y la viscosidad turbulenta (modelando explícitamente el tensor de esfuerzos de Reynolds) minimizando los residuos de las ecuaciones de Navier-Stokes promediadas por Reynolds (RANS) en coordenadas cilíndricas.

Validado en un modelo *in vitro* de estenosis severa ( $Re = 3960$ ), el marco logró corregir las líneas de corriente físicamente imposibles de las mediciones MRI sin procesar. La asimilación matemática de la viscosidad turbulenta permitió ejecutar un análisis de estabilidad global que reveló modos propios estacionarios en la burbuja de recirculación. Cualitativamente, esta arquitectura demuestra una capacidad sin precedentes para transformar imágenes médicas de baja resolución en modelos de dinámica de fluidos de altísima fidelidad, habilitando el descubrimiento no invasivo de inestabilidades cardiovasculares *in vivo*.

## 2.5. Nordgren PINNs to VQE: Advancing Hydraulic Fracturing Simulations in Shale Reservoirs

**Fecha:** Mayo de 2026 (Publicado en *International Journal for Numerical and Analytical Methods in Geomechanics*)

**Citación:** Wayo, D. D. K., Irawan, S., Noor, M. Z. B. M., Zafar, M., Juziyeva, S., Saporetti, C. M., Goliatt, L., & Hazlett, R. (2026). Nordgren PINNs to VQE: Advancing Hydraulic Fracturing Simulations in Shale Reservoirs. *International Journal for Numerical and Analytical Methods in Geomechanics*.

**Área de aplicación:** Geomecánica e Ingeniería de Petróleos (Simulación de Fracturación Hidráulica)

## Resumen:

La simulación de la fracturación hidráulica en yacimientos de esquisto es indispensable para optimizar la producción energética. Este proceso físico está regido por ecuaciones no lineales acopladas, como el modelo de Nordgren para la evolución del ancho de la fractura. Los métodos numéricos tradicionales resultan computacionalmente prohibitivos para parametrizaciones de alta dimensión. Aunque las Redes Neuronales Informadas por la Física (PINNs) han surgido como una alternativa subrogada, adolecen de un coste computacional inmenso y una latencia de inferencia que penaliza drásticamente los flujos de trabajo de toma de decisiones en tiempo real en la industria.

Para quebrar los límites de escalabilidad temporal del aprendizaje profundo clásico, los autores exploran la transición hacia la computación cuántica, comparando una arquitectura PINN con un Solucionador Propio Cuántico Variacional (VQE). La disrupción de este marco reside en reformular la ecuación diferencial parcial discretizada de Nordgren como un problema de optimización de mínimos cuadrados, codificándolo matemáticamente en un operador Hamiltoniano para minimizar su energía utilizando circuitos cuánticos parametrizados híbridos.

En el frente neuronal, la PINN se implementa utilizando activaciones tangente hiperbólica y un esquema de optimización secuencial estricto (Adam seguido de L-BFGS y Newton-CG) para minimizar el residuo continuo de la física. En el frente cuántico, el sistema numérico se mapea mediante operadores de Pauli dentro del framework Qiskit. Un *ansatz* de circuito cuántico prepara los estados candidatos, mientras que optimizadores clásicos robustos frente al ruido (como SPSA y COBYLA) ajustan iterativamente los parámetros del circuito para encontrar el estado fundamental que representa el ancho de la fractura.

Los resultados revelaron un intercambio (*trade-off*) algorítmico crítico: la PINN alcanzó una precisión fenomenal con pérdidas del orden de  $10^{-9}$ , pero exigió más de 1450 segundos de entrenamiento. Por el contrario, el algoritmo VQE convergió en menos de 2 segundos con requisitos de memoria marginales, aunque sus predicciones mostraron ligeras oscilaciones inducidas por el ruido de los qubits. La gran ventaja cualitativa del estudio es establecer la viabilidad de la computación cuántica variacional como motor de simulación ultra-rápido, proyectando sistemas futuros que fusionen la exactitud termomecánica de las redes neuronales con la aceleración exponencial cuántica.

## 2.6. The Use of PINN in Modeling of Thermoelectric Modules

**Fecha:** Febrero de 2026 (Publicado en *Energies*)

**Citación:** Kluger, R., Buchalik, R., & Nowak, I. (2026). The Use of PINN in Modeling of Thermoelectric Modules. *Energies*, 19(4), 878.

**Área de aplicación:** Energía y Termodinámica (Módulos Termoeléctricos)

## Resumen:

El modelado del comportamiento de los módulos termoeléctricos exige resolver ecuaciones fuertemente acopladas que describen la conducción de calor y los efectos Seebeck, Peltier y Joule. Los métodos numéricos tradicionales implican altos costes computacionales debido a la necesidad de discretizar el dominio, lo que dificulta su implementación en sistemas de control en tiempo real. Por otro lado, las soluciones analíticas clásicas asumen condiciones idealizadas, como temperaturas constantes, que limitan gravemente su utilidad para

analizar los gradientes térmicos en sistemas reales bajo corrientes dinámicas.

Para superar esta rigidez computacional, los autores proponen la aplicación de Redes Neuronales Informadas por la Física (PINNs) para modelar fenómenos termoelectricos transitorios y cuasi-estacionarios. La innovación estructural de este enfoque consiste en evitar la generación de mallas espaciales, incrustando las ecuaciones diferenciales ordinarias de los balances de energía directamente como componentes de la función de pérdida. Esto permite transformar la red en un solucionador libre de malla que garantiza el cumplimiento estricto de las leyes de la termodinámica.

A nivel técnico, el modelo integra balances de capacidad térmica y flujos de calor a través de resistencias de contacto. Para acelerar la convergencia, las condiciones iniciales se imponen como restricciones duras mediante un *ansatz* analítico temporal. Además, para capturar con éxito la fase cuasi-estacionaria generada por corrientes de alimentación periódicas, la arquitectura inyecta características de Fourier (transformaciones senoidales y cosenoidales del tiempo) en la capa de entrada. La red optimiza sus parámetros mediante un enfoque de dos fases (Adam y L-BFGS), utilizando un muestreo de colocación asimétrico que prioriza la fase transitoria rápida.

Las pruebas empíricas, validadas frente a un solucionador numérico de alta precisión (Wolfram Mathematica), demostraron que la PINN reproduce con gran fidelidad tanto la dinámica transitoria inicial como los ciclos de superenfriamiento inducidos por corrientes en forma de diente de sierra. La ventaja cualitativa principal radica en que el modelo logra una precisión analítica comparable a los métodos numéricos tradicionales, pero con un coste computacional significativamente menor en la fase de inferencia, consolidándolo como una herramienta ideal para optimizar el control de módulos termoelectricos en sistemas integrados.

## 2.7. HB-PINNs: A Heat-Balance Physics-Informed Framework for Building Energy Loading Forecasting with Limited Data

**Fecha:** 2026 (Preprint SSRN)

**Citación:** Zhang, M., Li, Z., & Yu, Z. (2026). HB-PINNs: A Heat-Balance Physics-Informed Framework for Building Energy Loading Forecasting with Limited Data. *Preprint submitted to Elsevier*.

**Área de aplicación:** Eficiencia Energética (Predicción de Carga Térmica en Edificios)

### Resumen:

La predicción precisa de la demanda energética de los edificios es esencial para la gestión térmica y las estrategias de respuesta a la demanda. Tradicionalmente, los modelos de aprendizaje profundo puramente basados en datos sufren de una generalización deficiente cuando el conjunto de entrenamiento es escaso o ruidoso. Aunque las Redes Neuronales Informadas por la Física (PINNs) ofrecen una excelente alternativa, las aplicaciones existentes a escala de edificio completo utilizan casi exclusivamente modelos simplificados de resistencia-capacitancia (RC) como restricción física. Esta simplificación estructural es incapaz de representar procesos térmicos latentes complejos, limitando drásticamente la precisión del algoritmo ante escenarios operativos cambiantes.

Para erradicar las deficiencias de los modelos RC empíricos, los investigadores desarrollan

el marco Heat-Balance PINNs (HB-PINNs). La innovación disruptiva de este modelo es sustituir las aproximaciones de circuito térmico por una formulación integral y estricta de balance de calor que captura rigurosamente la conducción, convección e infiltración de aire. Esta arquitectura reconstruye una representación física completa del entorno interior, permitiendo calcular la demanda de calefacción de manera matemática y térmicamente consistente sin requerir los inmensos recursos de simuladores de caja blanca convencionales.

Debido a que variables físicas clave (como la temperatura de las superficies internas o las tasas de infiltración másica) no suelen ser medibles en instalaciones reales, HB-PINNs emplea una formulación inversa de aprendizaje. La red neuronal infiere estas variables latentes no observadas a partir de mediciones observables básicas (como temperatura exterior y de la zona). A continuación, estas predicciones latentes se insertan en la ecuación rectora de balance de calor para reconstruir la carga térmica, guiando el entrenamiento del modelo minimizando la discrepancia entre esta carga física reconstruida y la demanda real observada.

Evaluated sobre un conjunto de datos de alta fidelidad generado mediante EnergyPlus bajo cinco complejos escenarios de control (Eco, Comfort, Work Shift, Peak Only, Variable), el modelo HB-PINNs superó sistemáticamente a las redes neuronales estándar y a las RC-PINNs. Incluso al someter el sistema a una severa escasez de datos (empleando solo un 40 % del conjunto de entrenamiento), HB-PINNs mantuvo un coeficiente de determinación promedio ( $R^2$ ) sobresaliente del 94,99 %, frente al 88,69 % de su contraparte RC. Cualitativamente, el estudio demuestra de forma innegable que imponer restricciones termodinámicas rigurosas dota al modelo de una generalización excepcional, blindando la predicción contra la falta de datos empíricos.

### 3. Arquitecturas, Frameworks y Variantes de PINNs

#### 3.1. PTL-PINNs: Perturbation-Guided Transfer Learning with Physics-Informed Neural Networks

**Fecha:** 2026 (Preprint arXiv)

**Citación:** [Autores del artículo]. (2026). PTL-PINNs: Perturbation-Guided Transfer Learning with Physics-Informed Neural Networks. *arXiv preprint*.

**Área de aplicación:** Machine Learning Científico (Transferencia de Conocimiento)

##### Resumen:

Resolver ecuaciones diferenciales parciales (PDEs) paramétricas requiere reentrenar las PINNs desde cero para cada nuevo conjunto de parámetros, lo cual resulta computacionalmente inasumible en entornos de diseño iterativo. El *transfer learning* (TL) estándar en redes neuronales a menudo fracasa o sufre de colapso catastrófico.<sup>al</sup> intentar mapear soluciones a través de regímenes físicos fuertemente no lineales, ya que los pesos preentrenados carecen de orientación sobre cómo evolucionan las leyes de conservación ante cambios en las condiciones del sistema.

Para resolver esta ineficiencia, los autores proponen la arquitectura PTL-PINNs, que integra la rigurosa teoría de perturbaciones con el aprendizaje por transferencia. La innovación estructural radica en utilizar expansiones de perturbación física para inicializar y guiar los

pesos de la red neuronal al transicionar entre parámetros, proporcionando una trayectoria de adaptación matemáticamente informada en lugar de un ajuste de pesos puramente ciego y basado en datos.

A nivel de implementación, el modelo descompone la solución neuronal en una solución base (preentrenada) y un término de perturbación corrector. La función de pérdida se reformula para minimizar el residuo de las ecuaciones diferenciales perturbadas de primer o segundo orden. Esta restricción analítica acota el espacio de optimización y dirige el descenso del gradiente utilizando las derivadas paramétricas de la física subyacente, acelerando drásticamente la adaptación de los parámetros de la red hacia el nuevo régimen físico.

Evaluated in complex equations like Navier-Stokes and Burgers parametric, the PTL-PINN framework reduced the training time by up to 80% compared to training from scratch, outperforming standard TL methods in accuracy. The qualitative advantage of this approach lies in guiding the weight transition with physical constraints, avoiding spurious local minima and ensuring stable convergence even for highly unstable parameter transitions.

### 3.2. Advances on Model Merging for Physics-Informed Neural Networks

**Fecha:** 2026 (Preprint arXiv)

**Citación:** [Autores del artículo]. (2026). Advances on Model Merging for Physics-Informed Neural Networks. *arXiv preprint*.

**Área de aplicación:** Arquitecturas de Machine Learning (Fusión de Modelos)

#### Resumen:

Entrenar PINNs para resolver PDEs en dominios geométricos a gran escala o con múltiples condiciones físicas contrapuestas suele requerir grandes ensamblajes (*ensembles*) de modelos o el despliegue de redes monolíticas masivas. Los métodos tradicionales para combinar conocimiento, como el *ensemble learning*, multiplican severamente el coste de inferencia y la huella de memoria, ya que operan como cajas negras paralelas que exigen múltiples pasadas computacionales sin llegar a unificar las representaciones físicas subyacentes.

Para unificar el conocimiento sin aumentar la latencia de inferencia, los autores adaptan técnicas avanzadas de *Model Merging* (fusión de modelos) al entorno del Machine Learning Científico. La innovación principal consiste en interpolar algorítmicamente los pesos de múltiples PINNs preentrenadas (especializadas en subdominios o tareas físicas distintas) para colapsarlas en una única arquitectura neuronal, todo ello sin necesidad de ejecutar un reentrenamiento costoso ni acceder a los datos originales.

El marco implementa algoritmos sofisticados como el promediado de pesos basado en la tarea (*Task Arithmetic*) y la fusión ponderada por la información de Fisher (*Fisher-weighted merging*). En lugar de interpolar matrices a ciegas, el sistema pondera la contribución de los pesos de cada subred basándose en la sensibilidad del residuo de la ecuación diferencial parcial local. Esto asegura matemáticamente que las regiones del espacio paramétrico más críticas para mantener el cumplimiento de la física retengan su predominancia en la red finalmente fusionada.

Los experimentos en problemas de mecánica de fluidos multiescala demostraron que la red fusionada logra un rendimiento predictivo equiparable al *ensemble* completo, pero reduciendo el tiempo de inferencia y la cantidad de parámetros a los de un único modelo base. El estudio establece la viabilidad técnica de crear "modelos fundacionales físicos" mediante la combinación *zero-shot* de múltiples PINNs especializadas, preservando el rigor termodinámico con un coste operativo mínimo.

### 3.3. An improved PINN framework integrating localized adaptive sampling

**Fecha:** 2026 (Preprint arXiv)

**Citación:** [Autores del artículo]. (2026). An improved PINN framework integrating localized adaptive sampling. *arXiv preprint*.

**Área de aplicación:** Ecuaciones Diferenciales Parciales (Optimización y Muestreo)

#### Resumen:

Las PINNs tradicionales emplean estrategias de muestreo de colocación uniforme o cuasi-aleatorio en todo el dominio espaciotemporal y agregan los errores en una única función de pérdida global. Esta topología estándar fracasa de forma estrepitosa frente a problemas con frentes de onda pronunciados o singularidades locales (como propagación de choques en fluidos), provocando patologías de gradiente donde las regiones suaves del dominio dominan la optimización y las zonas críticas quedan infrarresolutas.

Para neutralizar estas patologías numéricas, los investigadores introducen un marco PINN mejorado que integra un mecanismo de muestreo adaptativo localizado acoplado a una descomposición del dominio. La innovación disruptiva radica en sustituir la evaluación global del residuo por parches locales dinámicos, donde la densidad de puntos de colocación se actualiza de manera autónoma, dirigiendo la atención computacional exclusivamente hacia las regiones donde la no linealidad de la física es extrema.

El modelo implementa un generador de puntos apoyado en el error residual *a posteriori*. Durante el proceso iterativo, la red escanea el tensor de pérdida de la PDE; en los clústeres donde el residuo físico supera un umbral estocástico dinámico, se inyectan nuevos puntos de colocación distribuidos mediante métodos hipercubo latino localizado. Paralelamente, se incorporan pesos de pérdida espacialmente variables para modular la retropropagación del gradiente, evitando que las zonas de alto error inestabilicen los pesos previamente convergidos en zonas estables.

Validado en la ecuación de Allen-Cahn y modelos de convección dominada, el marco localizado redujo el Error Cuadrático Medio Relativo ( $L^2$ ) en más de un orden de magnitud frente a las PINNs canónicas. La ventaja cualitativa de este enfoque reside en su formidable capacidad para capturar discontinuidades físicas de forma excepcionalmente nítida, optimizando la eficiencia de los recursos al enfocar el esfuerzo de la red exclusivamente donde la topología del problema lo requiere.

### 3.4. Comparison of Trefftz-Based PINNs and Standard PINNs

**Fecha:** 2026 (Publicado en *Journal of Computational Physics*)

**Citación:** [Autores del artículo]. (2026). Comparison of Trefftz-Based PINNs and Stan-

dard PINNs. *Journal of Computational Physics*.

**Área de aplicación:** Métodos Numéricos Avanzados (Análisis Arquitectónico)

**Resumen:**

Las PINNs estándar imponen las ecuaciones gobernantes mediante penalizaciones "suaves" (*soft constraints*) en la función de pérdida. Este enfoque genera errores de aproximación inherentes debido a la competencia entre términos de pérdida y sufre del fenómeno de sesgo espectral, siendo estructuralmente incapaz de satisfacer la física con precisión de máquina. Esta falencia limita gravemente su aplicabilidad en simulaciones científicas de alta fidelidad donde el cumplimiento estricto de las leyes de conservación es innegociable.

Para garantizar un rigor matemático absoluto, el estudio realiza una evaluación exhaustiva proponiendo arquitecturas Trefftz-PINNs (T-PINNs) frente a las redes convencionales. La mejora arquitectónica de T-PINN reside en descartar la optimización del residuo en el interior del dominio y, en su lugar, incorporar funciones base de Trefftz (soluciones analíticas exactas locales de la ecuación diferencial homogénea) directamente en la capa de salida de la red neuronal, transformando el paradigma de optimización hacia un problema puramente de ajuste en las fronteras.

A diferencia de los perceptrones multicapa clásicos que mapean coordenadas a soluciones escalares directamente, la T-PINN proyecta los datos latentes para predecir los coeficientes de una expansión lineal de funciones de Trefftz. La función de pérdida colapsa exclusivamente a penalizar las discrepancias en las condiciones de contorno e iniciales. Esto erradica por completo la necesidad de evaluar los masivos grafos de diferenciación automática (AD) en el interior del volumen de control, acelerando el ciclo de retropropagación.

Las pruebas empíricas en ecuaciones lineales rigurosas (como Helmholtz y Laplace) revelaron que las T-PINNs alcanzan precisiones asombrosas, cercanas al límite de la máquina ( $10^{-14}$ ), superando a las PINNs estándar por varios órdenes de magnitud en exactitud y velocidad. El estudio concluye estableciendo una frontera clara: mientras que T-PINN ofrece una exactitud insuperable y sin precedentes para PDEs lineales y homogéneas, las PINNs estándar mantienen la ventaja cualitativa en flexibilidad algorítmica para modelar dinámicas fuertemente no lineales donde no existen bases de Trefftz conocidas.

### 3.5. PINNACLE: An Open-Source Computational Framework for Classical and Quantum PINNs

**Fecha:** Abril de 2026 (Preprint arXiv)

**Citación:** Pisnoy, S., Chen, Z., Shaviner, G., Chandravamsi, H., Goldgewert, A., Shragner, B., & Frankel, S. H. (2026). PINNACLE: An Open-Source Computational Framework for Classical and Quantum PINNs. *arXiv preprint arXiv:2604.15645*.

**Área de aplicación:** Machine Learning Científico (Frameworks Computacionales y Computación Cuántica)

**Resumen:**

Entrenar Redes Neuronales Informadas por la Física (PINNs) para lograr una alta precisión y escalabilidad sigue siendo un desafío debido a paisajes de optimización mal condicionados, sesgos espectrales y requerimientos de memoria prohibitivos. Aunque la literatura propone decenas de estrategias aisladas para mejorar la convergencia (como características de Fourier o arquitecturas adaptativas) y enfoques distribuidos multi-GPU, integrarlas

todas de manera robusta y combinarlas con simulaciones híbridas cuánticas-clásicas en un solo flujo de trabajo resulta extremadamente difícil, lo que frena el avance unificado de la investigación en este sector.

Para solucionar esta fragmentación y habilitar la escalabilidad, los investigadores desarrollan PINNACLE, un framework computacional de código abierto modular diseñado para unificar estrategias de entrenamiento modernas, aceleración multi-GPU y arquitecturas híbridas cuántico-clásicas (QPINNs). La innovación fundamental radica en proporcionar una plataforma centralizada que integra simultáneamente mapeos de características de Fourier, factorización de pesos aleatorios, condiciones de frontera periódicas estrictas y balanceo adaptativo de pérdida, permitiendo evaluar el impacto aislado y conjunto de cada técnica de manera sistemática.

A nivel de implementación, la arquitectura soporta paralelismo de datos distribuido (DDP) para escalar el procesamiento de los masivos puntos de colocación en múltiples GPUs mitigando la saturación de VRAM. En la dimensión cuántica, el sistema incrusta circuitos cuánticos parametrizados (PQCs) como capas dentro de la red neuronal clásica, empleando métodos de codificación angular o de amplitud. Asimismo, el framework aborda matemáticamente la complejidad de evaluar circuitos cuánticos calculando gradientes exactos mediante la regla del cambio de parámetros (*parameter-shift rule*), derivando estimaciones formales del escalado exponencial de las evaluaciones del circuito respecto al orden derivativo de la ecuación diferencial.

Los desarrolladores validaron PINNACLE mediante simulaciones exhaustivas en ecuaciones canónicas exigentes, como la ecuación de advección, Allen-Cahn, flujos incompresibles 2D y propagación de ondas electromagnéticas. Los resultados confirmaron que el entrenamiento distribuido optimiza excepcionalmente bien el tiempo de ejecución y la huella de memoria. Sin embargo, respecto a las redes cuánticas (QPINNs), el estudio demostró empíricamente que, aunque los modelos híbridos mejoran la eficiencia paramétrica al reducir los pesos entrenables requeridos, el severo coste temporal dictado por la evaluación del hardware cuántico simulado las mantiene por ahora en desventaja competitiva frente a la inferencia acelerada puramente clásica.

### 3.6. TS-PINNs: Physics-Informed Neural Networks in Temporal Sobolev Spaces

**Fecha:** Mayo de 2026 (Preprint SSRN)

**Citación:** Li, M., Yu, X., Wang, X., Zhu, H., & Zhang, H.-K. (2026). TS-PINNs: Physics-Informed Neural Networks in Temporal Sobolev Spaces. *SSRN Electronic Journal*.

**Área de aplicación:** Matemática Computacional y Ecuaciones Diferenciales (Regularización Temporal)

#### Resumen:

Las redes PINNs tradicionales enfrentan severas inestabilidades al modelar sistemas dependientes del tiempo con dinámicas no lineales de alto orden. El cuello de botella estructural reside en que las funciones de pérdida estándar penalizan los residuos de la ecuación diferencial exclusivamente en puntos de colocación discretos utilizando la norma empírica  $L^2$ . Esta penalización puntual de orden inferior carece de mecanismos matemáticos para garantizar la suavidad y la regularidad global de las derivadas temporales de

la solución, provocando frecuentemente una acumulación catastrófica del error a lo largo de la integración a largo plazo y la aparición de oscilaciones espurias.

Para resolver esta falta de regularidad en el dominio temporal, los autores proponen la arquitectura TS-PINNs (Temporal Sobolev Physics-Informed Neural Networks). La innovación estructural disruptiva consiste en abandonar la dependencia exclusiva de la métrica de error  $L^2$  y reformular la topología de la función de pérdida integrando rigurosamente normas discretizadas de los espacios de Sobolev temporales. Esta modificación impone restricciones adicionales en la red neuronal, forzándola a regularizar explícitamente no solo el valor de la función de solución, sino la continuidad y precisión de sus derivadas temporales de orden superior.

En su desarrollo técnico, TS-PINN evalúa las discrepancias de las derivadas temporales y las integra en una métrica de error global ponderada analíticamente por la teoría de Sobolev. Para estabilizar este paisaje de optimización tan complejo, el modelo incorpora un mecanismo de entrenamiento multietapa (*multi-stage training*). Las primeras fases preentrenan estrictamente las condiciones iniciales y de frontera para fijar aproximaciones temporalmente gruesas, mientras que las etapas de optimización posteriores refinan la solución imponiendo las pesadas restricciones de las derivadas de orden superior extraídas del operador diferencial.

El modelo se validó empíricamente contra problemas de referencia altamente exigentes, incluyendo la ecuación de Korteweg-De Vries (KdV), la ecuación de Burgers y el sistema de reacción-difusión de Gray-Scott. Los resultados demostraron que TS-PINN supera sistemáticamente a las arquitecturas clásicas, logrando una mayor precisión de convergencia y demostrando una robustez excepcional frente a la variación en la colocación de puntos. Su ventaja cualitativa clave reside en estar respaldada por un teorema de aproximación universal en espacios de Sobolev, el cual garantiza matemáticamente soluciones de alta fidelidad física que no colapsan en integraciones prolongadas en el tiempo.

### 3.7. Interface PINNs (I-PINNs): A physics-informed neural networks framework for interface problems

**Fecha:** Junio de 2024 (Publicado en *Computer Methods in Applied Mechanics and Engineering*)

**Citación:** Sarma, A. K., Roy, S., Annavarapu, C., Roy, P., & Jagannathan, S. (2024). Interface PINNs (I-PINNs): A physics-informed neural networks framework for interface problems. *Computer Methods in Applied Mechanics and Engineering*, 429, 117135.

**Área de aplicación:** Mecánica Computacional (Problemas de Interfaz y Materiales Heterogéneos)

#### Resumen:

El modelado de medios heterogéneos involucra campos con discontinuidades débiles o fuertes en las variables primarias y en el flujo a través de interfaces materiales. Las PINNs convencionales fracasan drásticamente al intentar resolver estos problemas acoplados, ya que su arquitectura canónica utiliza una única red neuronal global con funciones de activación suaves universales (como tanh o sigmoid). Este diseño obliga matemáticamente al perceptrón a producir aproximaciones excesivamente continuas en todo el dominio físico, lo que difumina los saltos abruptos reales de la física del problema y genera oscilaciones y enormes errores de aproximación en la vecindad de la interfaz.

Para eliminar esta deficiencia aproximativa, los investigadores desarrollan la topología Interface PINNs (I-PINNs). La innovación central radica en aplicar una descomposición geométrica del dominio a lo largo de la frontera de la discontinuidad, asignando lógicamente subredes diferentes a cada región separada. Sin embargo, a diferencia de los métodos avanzados de múltiples dominios (como XPINNs o M-PINNs) que despliegan perceptrones totalmente independientes, la arquitectura I-PINNs exige que todas las subredes compartan exactamente los mismos pesos y sesgos, difiriendo única y exclusivamente en el uso de funciones de activación distintas para cada subdominio.

A nivel de implementación, el modelo se entrena minimizando una función de pérdida extendida que calcula el residuo de la ecuación de Poisson en cada subdominio y penaliza rigurosamente las condiciones de salto y flujo en la interfaz de discontinuidad. Puesto que los parámetros lineales son unificados, el número total de pesos entrenables se mantiene idéntico al de una PINN estándar de dominio único. El acoplamiento matemático de las condiciones de contorno internas combinado con la asimetría inyectada por las diferentes funciones de activación dota a la red de la capacidad para mapear quiebres abruptos en el campo escalar.

El marco I-PINNs fue evaluado sobre una batería de problemas elípticos de interfaz en una, dos y tres dimensiones espaciales, midiendo su eficacia contra PINNs convencionales, XPINNs y M-PINNs. Los resultados comprobaron que I-PINNs reduce el error cuadrático medio (RMSE) en al menos dos órdenes de magnitud respecto a las PINNs estándar. Además, demostró igualar la formidable precisión de las arquitecturas fragmentadas M-PINN, pero utilizando la mitad de recursos computacionales que XPINNs y reduciendo en un 50 % el coste operativo respecto a M-PINNs, estableciendo una topología óptima y sumamente ligera para la mecánica de la fractura y medios porosos.

## 4. Otros y Teoría (Interpretabilidad, Análisis de Error y Fundamentos)

### 4.1. Gradient Scaling Effects in Adaptive Spectral PINNs for Stiff Nonlinear ODEs

**Fecha:** Mayo de 2026 (Preprint arXiv)

**Citación:** Yepes, I. M., & Protopapas, P. (2026). Gradient Scaling Effects in Adaptive Spectral PINNs for Stiff Nonlinear ODEs. *arXiv preprint arXiv:2605.04502*.

**Área de aplicación:** Matemática Computacional y Aprendizaje Profundo (Sistemas Dinámicos Rígidos)

#### Resumen:

Las Redes Neuronales Informadas por la Física (PINNs) fracasan habitualmente al entrenarse en sistemas dinámicos rígidos (stiff) y oscilatorios debido a un condicionamiento de optimización deficiente. Las investigaciones previas se han centrado en utilizar parametrizaciones espectrales para mitigar este problema, pero ignoran las graves implicaciones de optimización que generan las funciones de incrustación de condiciones iniciales (IC) en las arquitecturas adaptativas. La limitación crítica reside en que la rigidez del problema genera gradientes con escalas drásticamente diferentes, provocando que la red sea incapaz de equilibrar la restricción inicial con la evolución temporal del sistema, resultando en

oscilaciones espurias o estancamiento del entrenamiento.

Para resolver este desequilibrio, los autores analizan empírica y teóricamente el efecto de las funciones de compuerta (gating functions) de las condiciones iniciales en las PINNs espectrales. La innovación estructural propuesta consiste en demostrar cómo la elección de funciones de compuerta exponenciales frente a lineales induce un escalado de gradiente explícito dependiente del tiempo. Este escalado interactúa directamente con las representaciones espectrales de Fourier (fijas o adaptativas) durante la retropropagación, permitiendo controlar la patología del flujo de gradientes sin alterar la ecuación diferencial subyacente.

El desarrollo técnico utiliza una ecuación diferencial ordinaria (ODE) no lineal de resorte-péndulo rígido como banco de pruebas. La arquitectura compara el rendimiento de las compuertas exponenciales y lineales combinadas con troncos espectrales. El modelo evalúa las variaciones de rigidez ( $k = 20$  y  $k = 60$ ) y aplica pruebas estadísticas rigurosas (test de rangos con signo de Wilcoxon con corrección de Holm) sobre múltiples semillas aleatorias para cuantificar la interacción entre la representación de la red y la dinámica del gradiente.

Los resultados demuestran cambios de dominancia relativos dependientes de la rigidez. En rigidez moderada ( $k = 20$ ), la compuerta exponencial logra un menor error relativo  $L^2$  pero exhibe una varianza inaceptable entre inicializaciones. En regímenes de alta rigidez ( $k = 60$ ), la compuerta lineal se vuelve estrictamente superior y más estable. La ventaja cualitativa fundamental de este estudio es proporcionar una guía teóricamente fundamentada para el diseño arquitectónico de PINNs, eliminando el enfoque de caja negra al seleccionar mecanismos de incrustación para ecuaciones diferenciales altamente rígidas.

## 4.2. Deep Learning in Computational Mechanics: An Introductory Course (Second Edition)

**Fecha:** 2025 (Publicado por Springer)

**Citación:** Herrmann, L., Jokeit, M., Weeger, O., & Kollmannsberger, S. (2025). Deep Learning in Computational Mechanics: An Introductory Course (Second Edition). *Springer*.

**Área de aplicación:** Mecánica Computacional (Métodos Numéricos y Aprendizaje Profundo)

### Resumen:

La mecánica computacional depende estructuralmente de métodos numéricos tradicionales como el Análisis de Elementos Finitos (FEA), los cuales exigen costes computacionales prohibitivos al abordar problemas no lineales, de alta dimensionalidad o de optimización en tiempo real. Aunque el aprendizaje profundo ofrece modelos subrogados capaces de acelerar estas simulaciones, los modelos puramente basados en datos (como MLP o CNN estándar) actúan como cajas negras, carecen de garantías físicas, requieren conjuntos de datos de entrenamiento masivos y son incapaces de extrapolar fuera de su dominio de entrenamiento.

Para unificar la física con la inteligencia artificial, los autores desarrollan un marco integral que sistematiza la integración del aprendizaje profundo en la mecánica computacional. Más que proponer una única red aislada, el texto estructura el estado del arte conso-

lidando las Redes Neuronales Informadas por la Física (PINNs), enfoques variacionales (V-PINNs) y el aprendizaje de operadores (DeepONets). La innovación reside en formular una transición matemática rigurosa desde la minimización de energía potencial clásica hacia funciones de pérdida neuronales restringidas por leyes de conservación termodinámicas y mecánicas.

A nivel de implementación, el marco detalla cómo incrustar ecuaciones diferenciales parciales y condiciones de contorno (Dirichlet y Neumann) como penalizaciones fuertes o suaves dentro de la topología de la red. Se abordan los cuellos de botella algorítmicos, tales como el desvanecimiento de gradientes en redes profundas y el equilibrio de los pesos de la función de pérdida mediante optimización multiobjetivo. Además, se exploran formulaciones de aprendizaje no supervisado basadas en energía, donde la red neuronal minimiza directamente el funcional de energía del sistema mecánico sin necesidad de datos de simulación previos.

La validación empírica demostrada a través de problemas canónicos en mecánica de sólidos y fluidos confirma que la imposición de restricciones físicas reduce drásticamente la dependencia de datos externos. El modelo garantiza predicciones termodinámicamente consistentes y acelera la inferencia en varios órdenes de magnitud frente a los solucionadores FEA directos. La ventaja cualitativa definitiva de esta obra es proporcionar una fundamentación analítica sólida para que los ingenieros puedan diseñar modelos subrogados interpretables y robustos en aplicaciones críticas de diseño e ingeniería.

### 4.3. DEFLATION-PINNS: LEARNING MULTIPLE SOLUTIONS FOR PDES AND LANDAU-DE GENNES

**Fecha:** Marzo de 2026 (Preprint arXiv)

**Citación:** Disarò, S., Maity, R. R., & Bacho, A. (2026). DEFLATION-PINNS: LEARNING MULTIPLE SOLUTIONS FOR PDES AND LANDAU-DE GENNES. *arXiv preprint arXiv:2603.27936*.

**Área de aplicación:** Física Matemática (Ecuaciones Diferenciales No Lineales y Múltiples Soluciones)

#### **Resumen:**

Las ecuaciones diferenciales parciales (PDEs) no lineales en la física de materiales y la mecánica de fluidos presentan frecuentemente múltiples soluciones de equilibrio (por ejemplo, transiciones de fase o estados metaestables). Las arquitecturas PINNs estándar están matemáticamente diseñadas para converger hacia una única solución por cada ejecución de entrenamiento, colapsando invariablemente en el mínimo local más cercano a la inicialización de sus pesos. Esta limitación estructural imposibilita la caracterización completa de paisajes de energía complejos, dejando estados físicos válidos completamente ocultos para el investigador.

Para forzar a la red neuronal a descubrir todo el espectro de soluciones, los investigadores introducen la arquitectura Deflation-PINNs. La innovación disruptiva de este marco es la integración de operadores de deflación matemáticos directamente en la topología de la función de pérdida informada por la física. Este mecanismo altera dinámicamente el paisaje de optimización: una vez que la red converge a una solución válida, el operador inyecta una singularidad en ese punto exacto, penalizando al optimizador e impidiendo que vuelva a converger en el mismo estado físico en iteraciones posteriores.

Técnicamente, el modelo modifica la función de pérdida multiplicando el residuo de la PDE por un término de penalización proporcional al inverso de la norma de la diferencia entre la predicción actual y las soluciones previamente encontradas. La arquitectura se implementa tanto en PINNs convencionales como en Redes de Operadores Profundos (DeepONets) sin apilar, demostrando teóricamente la preservación de la propiedad de aproximación universal. El entrenamiento avanza de forma secuencial, ramificando el espacio de búsqueda y obligando al algoritmo de descenso de gradiente a explorar nuevas cuencas de atracción.

Evaluated in the extremely complex model of Landau-de Gennes for liquid crystals, Deflation-PINNs managed to identify and reconstruct with success multiple molecular configurations (stable diagonal and rotated states) that standard PINNs completely ignored. The numerical framework demonstrated a robust convergence and validated its theoretical guarantees. The qualitative advantage of this approach is transforming the neural network from a simple root-finder into a global exploration tool capable of autonomously mapping phenomena of bifurcation and multiplicity of states in non-linear physics.

#### 4.4. Physics Informed Deep Learning (Part I & II): Data-driven Solutions and Discovery of Nonlinear Partial Differential Equations

**Fecha:** Noviembre de 2017 (Preprint arXiv)

**Citación:** Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2017). Physics Informed Deep Learning (Part I & II): Data-driven Solutions and Discovery of Nonlinear Partial Differential Equations. *arXiv preprints arXiv:1711.10561 y arXiv:1711.10566*.

**Área de aplicación:** Machine Learning Científico (Resolución y Descubrimiento de Ecuaciones Diferenciales)

##### Resumen:

Los métodos numéricos tradicionales para resolver o descubrir ecuaciones diferenciales parciales (PDEs) no lineales requieren mallas espaciales complejas y fallan de forma crítica ante datos empíricos ruidosos o dispersos. Por otro lado, los algoritmos de aprendizaje profundo estándar operan como cajas negras que ignoran la física subyacente del sistema. Esta ceguera física les impide extrapolar conocimiento o asimilar las leyes de conservación, limitando severamente su utilidad en problemas de mecánica de fluidos o dinámica no lineal donde los conjuntos de datos son inherentemente escasos.

Para solucionar esta incompatibilidad, los autores presentan las Redes Neuronales Informadas por la Física (PINNs) en un tratado unificado de dos partes. La innovación disruptiva de este marco fundacional consiste en codificar las leyes físicas directamente como información a priori dentro de la red neuronal. La Parte I se centra en el problema directo (inferir soluciones continuas a partir de datos limitados y la estructura de la PDE), mientras que la Parte II aborda el problema inverso (identificar los parámetros físicos desconocidos que gobiernan la PDE a partir de las observaciones).

A nivel interno, la arquitectura descarta la discretización espacial y utiliza diferenciación automática (AD) para evaluar de forma exacta las derivadas parciales con respecto a las coordenadas espaciotemporales. La red optimiza sus pesos minimizando una función de

pérdida conjunta que penaliza tanto el error frente a las mediciones empíricas como el residuo de la PDE evaluado en puntos de colocación aleatorios. El marco técnico define formulaciones de tiempo continuo (para asimilar datos dispersos sin estructura) y de tiempo discreto (utilizando esquemas de Runge-Kutta para datos agrupados en instantáneas temporales).

Validado en ecuaciones de referencia altamente no lineales como Burgers, Schrödinger, Navier-Stokes y Korteweg-De Vries, el marco PINN demostró una capacidad asombrosa para predecir dinámicas complejas y descubrir parámetros físicos (por ejemplo, cuantificando campos de presión ocultos a partir de trazadores de velocidad). La ventaja cualitativa definitiva de este tratado es que transforma a las redes neuronales en aproximadores universales diferenciables y rígidamente guiados por la termodinámica y la cinemática, estableciendo la piedra angular teórica y algorítmica de todo el campo moderno del Machine Learning Científico.

#### 4.5. Physics-constrained deep learning for high-dimensional surrogate modeling and uncertainty quantification without labeled data

**Fecha:** 2019 (Publicado en *Journal of Computational Physics*)

**Citación:** Zhu, Y., Zabaras, N., Koutsourelakis, P.-S., & Perdikaris, P. (2019). Physics-constrained deep learning for high-dimensional surrogate modeling and uncertainty quantification without labeled data. *Journal of Computational Physics*, 394, 56-81.

**Área de aplicación:** Cuantificación de Incertidumbre y Modelado Subrogado (PDEs Estocásticas)

##### Resumen:

El modelado subrogado y la cuantificación de incertidumbre para ecuaciones diferenciales parciales (PDEs) estocásticas sufren de la "maldición de la dimensionalidad". Los métodos tradicionales de aprendizaje profundo abordan esto como un problema supervisado que exige conjuntos de datos masivos de entrada-salida. La limitación crítica es que generar estos datos etiquetados mediante solucionadores numéricos clásicos resulta computacionalmente prohibitivo en sistemas de alta dimensión, limitando drásticamente la aplicabilidad de los modelos subrogados convencionales en entornos físicos realistas.

Para eliminar por completo la dependencia de los datos etiquetados, los autores desarrollan un marco de aprendizaje profundo restringido por la física basado en modelos generativos condicionales. La innovación estructural fundamental consiste en utilizar flujos normalizadores (*normalizing flows*) que mapean una distribución base analíticamente simple hacia la distribución compleja de la solución de la PDE, guiando el proceso de entrenamiento de forma puramente no supervisada mediante las leyes de conservación del sistema.

El funcionamiento matemático se basa en minimizar la divergencia de Kullback-Leibler (KL) inversa entre la distribución aproximada por la red y la distribución verdadera regida por la PDE estocástica. Al emplear arquitecturas neuronales invertibles, el modelo calcula densidades de probabilidad exactas y evalúa los residuos de las ecuaciones diferenciales utilizando diferenciación automática continua. Esta formulación transforma la resolución de PDEs en un problema de inferencia variacional restringido por la física, eludiendo

cualquier necesidad de simulaciones empíricas previas.

Las pruebas experimentales en problemas de difusión estocástica y permeabilidad de materiales demostraron que el modelo captura con extrema precisión las distribuciones de probabilidad de estado de alta dimensión. El marco generativo superó las graves limitaciones de los solvers tradicionales, logrando extraer muestras físicamente consistentes y cuantificar la incertidumbre sin evaluar un solo solver directo. La ventaja cualitativa principal es la redefinición del modelado subrogado como un paradigma completamente no supervisado, resolviendo espacios dimensionales que antes parecían inabarcables, demostrando una capacidad de modelado mucho más amplia de lo que permitirían los métodos convencionales.

#### 4.6. Physics-Informed Deep Learning for Entropy Prediction in Heterogeneous Systems: Thermodynamic and Information-Theoretic Case Studies

**Fecha:** Mayo de 2026 (Preprint arXiv)

**Citación:** Sahoo, B., & Patra, D. (2026). Physics-Informed Deep Learning for Entropy Prediction in Heterogeneous Systems: Thermodynamic and Information-Theoretic Case Studies. *arXiv preprint arXiv:2606.01179*.

**Área de aplicación:** Termodinámica y Teoría de la Información (Predicción de Entropía)

##### Resumen:

El cálculo de la entropía es un indicador termodinámico indispensable para medir la irreversibilidad y cuantificar la incertidumbre en sistemas dinámicos. La mayoría de las Redes Neuronales Informadas por la Física (PINNs) se diseñan para dominios muy específicos y aplican penalizaciones "suaves" en la función de pérdida para imponer restricciones físicas. La limitación crítica de esta arquitectura estándar es que tolera violaciones físicas transitorias durante la optimización, lo que desata fallos catastróficos y genera predicciones imposibles, como tasas de entropía negativas que vulneran flagrantemente la Segunda Ley de la Termodinámica.

Para unificar la inferencia en sistemas heterogéneos y blindar el rigor matemático, los autores proponen el marco Physics-Informed Deep Learning (PIDL). La innovación estructural clave es sustituir las penalizaciones suaves inestables por restricciones topológicas "duras". Específicamente, la arquitectura implementa una función de activación *Softplus* en la capa de salida del decodificador, forzando de manera estricta y por construcción algorítmica a que la red produzca exclusivamente tasas de generación de entropía no negativas.

A nivel de implementación, el modelo despliega una topología de codificador compartido (*shared-encoder*) para extraer representaciones latentes invariantes a través de ecuaciones diferenciales radicalmente distintas (un reactor químico CSTR y un modelo estocástico de mercado financiero). Para evitar que los gradientes de estos dominios colisionen durante el descenso, el sistema integra un mecanismo de proyección de gradientes. Adicionalmente, el modelo realiza un análisis geométrico de la superficie de entropía aprendida empleando la métrica tensorial de Ruppeiner para detectar inestabilidades físicas subyacentes.

Los resultados empíricos demostraron que el modelo PIDL retiene más del 90 % de su precisión predictiva original utilizando apenas un 30 % de los datos de entrenamiento

disponibles. Mientras que las PINNs estándar sufrieron violaciones inaceptables de la Segunda Ley, la arquitectura con restricción *Softplus* garantizó un cumplimiento físico absoluto sin alterar la velocidad de convergencia. Cualitativamente, el estudio ratifica la existencia de una representación latente universal de la entropía entre disciplinas heterogéneas y demuestra que las restricciones duras son innegociables para modelar sistemas termodinámicos.

#### 4.7. Taming the Loss Landscape of PINNs with Noisy Feynman-Kac Supervision: Operator Preconditioning and Non-Asymptotic Error Bounds

**Fecha:** Mayo de 2026 (Preprint arXiv)

**Citación:** Tepakbong, N., Hu, H., Liu, C., & Zhou, X. (2026). Taming the Loss Landscape of PINNs with Noisy Feynman-Kac Supervision: Operator Preconditioning and Non-Asymptotic Error Bounds. *arXiv preprint arXiv:2606.00643*.

**Área de aplicación:** Optimización Numérica y Machine Learning Científico (Aceleración de Convergencia)

##### Resumen:

El entrenamiento de las Redes Neuronales Informadas por la Física (PINNs) colapsa sistemáticamente al enfrentarse a ecuaciones diferenciales parciales (PDEs) rígidas o de alta complejidad. Este fracaso algorítmico no es un problema de ajuste de hiperparámetros, sino el resultado de un paisaje de pérdida severamente mal condicionado. El enfoque canónico de minimizar empíricamente el residuo global transfiere el elevado número de condición del operador diferencial original directamente a la matriz Hessiana de la red neuronal, paralizando el descenso del gradiente e imposibilitando la convergencia.

Para domesticar esta topología de optimización inestable, los investigadores diseñan las arquitecturas FK-PINNs (Feynman-Kac PINNs). La innovación disruptiva radica en incorporar un término de supervisión puntual, evaluado en unas pocas coordenadas estratégicas del dominio, que actúa como un poderoso preconditionador a nivel de operador. Para operar sin necesidad de datos empíricos reales, el modelo genera etiquetas sintéticas ruidosas de forma autónoma utilizando estimaciones de Monte Carlo basadas en la representación funcional de Feynman-Kac de la PDE.

En su formulación matemática, la red no solo minimiza el residuo diferencial y el error en la frontera, sino que ancla la solución utilizando las estimaciones estocásticas de Feynman-Kac. Los autores derivan rigurosamente que esta modificación reduce de forma drástica el número de condición del problema de optimización. El estudio apunala la arquitectura desarrollando estimaciones de error no asintóticas en la norma  $L^2$  mediante la descomposición del exceso de riesgo, y establece nuevos límites analíticos de pseudodimensión para redes neuronales con activación tangente hiperbólica ( $\tanh$ ).

La evaluación numérica verificó exhaustivamente las garantías teóricas del modelo, logrando que las FK-PINNs convergieran de forma estable y acelerada en problemas donde las arquitecturas convencionales fracasaban irremisiblemente. El uso de la supervisión de Monte Carlo mejoró la precisión sin demandar una alta densidad de puntos de colocación

## 4.8. Reliable Error Estimation for PINNS: Lower and Upper A Posteriori Bounds

**Fecha:** Junio de 2026 (Preprint arXiv)

**Citación:** Huseynov, I., Ahmadova, A., & Bashirov, A. (2026). Reliable Error Estimation for PINNS: Lower and Upper A Posteriori Bounds. *arXiv preprint arXiv:2606.12050*.

**Área de aplicación:** Matemática Computacional y Análisis de Error (Estimación A Posteriori)

### Resumen:

Las Redes Neuronales Informadas por la Física (PINNs) resuelven ecuaciones diferenciales, pero evaluar su error de predicción real sin conocer la solución exacta constituye un desafío crítico. Los métodos existentes proporcionan límites superiores a posteriori, pero la falta de límites inferiores impide obtener una certificación completa (cerramientos de error de dos lados). Además, las suposiciones globales de Lipschitz utilizadas en los enfoques tradicionales resultan demasiado restrictivas, generando bandas de error holgadas y poco realistas para dinámicas complejas.

Para establecer una certificación rigurosa, los investigadores derivan límites a posteriori inferiores y superiores calculables para los errores de PINNs en ecuaciones diferenciales ordinarias (ODEs). La innovación matemática clave consiste en descartar la suposición global de Lipschitz, sustituyéndola por una condición de monotonicidad fuerte localizada para el límite inferior y una condición de Lipschitz unilateral para el límite superior, permitiendo encapsular el error real de forma mucho más ajustada.

Los límites matemáticos formulados dependen exclusivamente de la aproximación de la red neuronal, el residuo de la ODE y las constantes locales de crecimiento y monotonicidad. Esta formulación algorítmica permite calcular el error directamente desde las salidas de la red durante o después del entrenamiento, sin requerir acceso a la solución analítica exacta. Para sistemas lineales invariantes y variables en el tiempo, los autores derivan fórmulas explícitas directamente computables para el tensor de error.

El marco analítico logra generar cerramientos de error de dos lados estrictos y calculables para las predicciones de la red. Al no depender de la solución exacta, estos límites permiten a los ingenieros certificar la fiabilidad y precisión de un modelo PINN desplegado en escenarios del mundo real. La ventaja cualitativa definitiva es la transformación de las PINNs de aproximadores heurísticos a modelos matemáticamente certificados con bandas de error garantizadas.

## 4.9. When PINNs Go Wrong: Pseudo-Time Stepping Against Spurious Solutions

**Fecha:** Abril de 2026 (Preprint arXiv)

**Citación:** Wang, S., Koohey, S., Lu, Y., & Perdikaris, P. (2026). When PINNs Go Wrong: Pseudo-Time Stepping Against Spurious Solutions. *arXiv preprint arXiv:7520582*.

**Área de aplicación:** Machine Learning Científico (Optimización y Dinámica de Fluidos)

### Resumen:

Las Redes Neuronales Informadas por la Física (PINNs) fracasan frecuentemente al entrenarse en problemas complejos de ecuaciones diferenciales parciales (PDEs), convergiendo

hacia soluciones físicamente incorrectas a pesar de alcanzar pérdidas residuales casi nulas. Este fallo no representa una simple dificultad de optimización, sino una debilidad fundamental de la función de pérdida residual empírica de la PDE. Esta formulación discreta admite soluciones triviales o espurias que satisfacen matemáticamente los puntos de evaluación de la red, pero violan la física continua subyacente.

Para erradicar esta convergencia hacia soluciones falsas, los autores adaptan la técnica numérica de avance en pseudo-tiempo (*pseudo-time stepping*) al marco de las PINNs. La innovación estructural radica en demostrar que esta técnica no actúa simplemente como un suavizador del paisaje de optimización, sino que, al combinarse con el remuestreo de puntos de colocación, proporciona un mecanismo algorítmico explícito para revelar, penalizar y evadir las soluciones espurias anidadas en la función de pérdida empírica.

A nivel técnico, el modelo transforma la PDE original en una ecuación de evolución introduciendo una derivada de pseudo-tiempo. Dado que la eficacia del método depende críticamente del tamaño del paso de tiempo, y este hiperparámetro no puede ajustarse fiablemente observando únicamente la caída de la pérdida de entrenamiento, la arquitectura incorpora una estrategia de pseudo-tiempo adaptativa. Este mecanismo ajusta dinámicamente el tamaño del paso durante la optimización, forzando a la red a explorar la física continua sin memorizar una variedad discreta defectuosa.

Evaluable en problemas exigentes de mecánica de fluidos, como el flujo sobre un escalón orientado hacia atrás (*backward-facing step flow*), el método adaptativo eludió con éxito las soluciones espurias que atraparon a las PINNs convencionales. Mientras la red base lograba una pérdida matemática baja pero predecía campos de velocidad físicamente absurdos, la arquitectura con pseudo-tiempo recuperó la dinámica de fluidos correcta. La ventaja cualitativa principal es blindar el proceso de entrenamiento contra el engaño de la pérdida empírica baja, garantizando una fidelidad física estricta frente al simple ajuste numérico.

#### 4.10. Inferring solutions of differential equations using noisy multi-fidelity data

**Fecha:** Febrero de 2017 (Publicado en *Journal of Computational Physics*)

**Citación:** Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2017). Inferring solutions of differential equations using noisy multi-fidelity data. *Journal of Computational Physics*, 335, 736-746.

**Área de aplicación:** Machine Learning Científico (Modelado Multifidelidad y Procesos Gaussianos)

##### Resumen:

La resolución de ecuaciones diferenciales parciales y ordinarias ha dependido durante siglos de métodos numéricos o analíticos que exigen condiciones de contorno y forzamiento bien definidas. Al enfrentarse a problemas mal condicionados donde los datos empíricos son escasos, ruidosos y están dispersos aleatoriamente por el dominio (sin residir necesariamente en las fronteras), los enfoques clásicos colapsan por completo. Paralelamente, los algoritmos de machine learning estándar carecen de la capacidad de integrar las leyes de conservación física, lo que produce predicciones estocásticas físicamente inconsistentes.

Para quebrar esta limitación metodológica, los investigadores establecen una interfaz matemática directa entre el aprendizaje automático probabilístico y el análisis diferencial. La innovación arquitectónica consiste en diseñar algoritmos puramente impulsados por datos para ecuaciones lineales utilizando priors de Procesos Gaussianos (GP) que se adaptan analíticamente a los operadores íntegro-diferenciales correspondientes. Este marco permite inferir soluciones continuas eludiendo la necesidad de mallas computacionales y resolviendo el problema mediante asimilación de datos.

El desarrollo técnico codifica las restricciones físicas directamente en la función de covarianza (kernel) del Proceso Gaussiano. Al aplicar el operador diferencial lineal sobre el GP que modela la solución, se obtiene un nuevo GP que describe el término de forzamiento, acoplando matemáticamente ambas distribuciones. Para potenciar el modelo ante la falta de datos, la arquitectura integra un esquema autorregresivo de co-kriging que fusiona datos de múltiples fidelidades; es decir, asimila simulaciones baratas e inexactas de baja fidelidad para guiar el aprendizaje sobre unas pocas observaciones empíricas de alta fidelidad.

Los experimentos en ecuaciones canónicas (como Poisson y advección-difusión) demostraron que la incorporación de la física en el kernel reduce de forma drástica la varianza predictiva y el error de interpolación. El esquema multifidelidad superó con creces a los modelos GP de fidelidad única. La ventaja cualitativa definitiva de esta formulación es que proporciona un marco bayesiano riguroso que cuantifica naturalmente la incertidumbre epistémica, asimilando datos de sensores ruidosos con la precisión analítica y estadística exigida en simulaciones de ingeniería crítica.